

Universidad Nacional del Este.
Facultad Politécnica.



Sistema de compra inteligente basado en el histórico de ventas.

Valeria Soledad Arevalos Arevalos
y Marcelo Andrés González Arias

Año 2023.

Universidad Nacional del Este
Facultad Politécnica

Carrera Ingeniería de Sistemas.
Cátedra Trabajo Final de Grado II.

Sistema de compra inteligente basado en el histórico de ventas.

Por: **Valeria Soledad Arevalos Arevalos**
y **Marcelo Andrés González Arias**

Profesor Orientador: **Lic. Roberto Alfredo Demestri Rigoni.**

Trabajo final de grado presentado a la Facultad Politécnica de la Universidad Nacional del Este como parte de los requisitos para optar al título de Ingeniero de Sistemas.

Ciudad del Este, Alto Paraná. Paraguay.

Julio 2023

FICHA CATALOGÁFICA
BIBLIOTECA DE LA FACULTAD POLITÉCNICA
DE LA UNIVERSIDAD NACIONAL DEL ESTE

Arevalos Arevalos, Valeria Soledad 1998.
Sistema de compra inteligente basado en el histórico de ventas
González Arias, Marcelo Andrés 1996
Ciudad del Este, Alto Paraná. Año: 2023.
Páginas: <cantidad de páginas>.

Orientador: Lic. Roberto Alfredo Demestri Rigoni.
Área de estudio: Tecnológica.
Carrera: Ingeniería de Sistemas.
Titulación: Ingeniero de Sistemas.
Trabajo Final de Grado. Universidad Nacional del Este,
Facultad Politécnica.

Descriptores: 1. Valeria Arevalos. 2. Marcelo González
Smart purchasing system based on sales history.
Key words: 1. Input Demand Forecast, 2. Matematical Modelling
3. Artificial Neural network.

Yo, <nombre del Profesor Orientador>, documento de identidad No. <No. de documento de identidad del Profesor Orientador>, Profesor Orientador del TFG titulado “<título del TFG>”, del Alumno <nombre del Alumno>, documento de identidad No. <No. de documento de identidad del Alumno>, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este; certifico que el mencionado Trabajo Final de Grado ha sido realizado por dicho Alumno, de lo cual doy fe y en mi opinión reúne las condiciones para su presentación y defensa ante la Mesa Examinadora designada por la institución.

<fecha>

<nombre del Profesor Orientador>

Nosotros, los miembros de la Mesa Examinadora del Trabajo Final de Grado titulado “<título del TFG>”, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este, hacemos constar que el citado trabajo ha sido evaluado en fondo y forma por esta Mesa, la que por _____ ha resuelto asignar la calificación _____

Ciudad del Este, ____ de _____ de ____

Profesor _____
Presidente de la Mesa Examinadora

Profesor _____

Miembro de la Mesa Examinadora

Profesor _____

Miembro de la Mesa Examinadora

Escribir aquí la dedicatoria.
Su extensión no debería exceder de una página.

<Escribir aquí los agradecimientos.>
<Su extensión no debería exceder de una página.>

<Escribir aquí el epígrafe (frase u oración favorita).>
<Su extensión no debería exceder de una página.>

Resumen

Este trabajo propone el desarrollo de un sistema inteligente de compras para restaurantes, que se basa en un modelo matemático de predicción de la demanda de insumos. Este modelo utiliza técnicas estadísticas avanzadas y métodos de pronóstico para analizar patrones de consumo pasados y prever con precisión las cantidades de insumos necesarias en el futuro. Además, se incorpora una red neuronal entrenada para mejorar aún más las estimaciones de demanda, permitiendo así reducir el desperdicio de alimentos, optimizar los niveles de inventario y mejorar la eficiencia operativa del restaurante. La metodología de investigación involucra la recopilación y análisis de datos históricos de ventas y compras, así como la exploración de diversas técnicas de pronóstico y algoritmos de redes neuronales. Se llevarán a cabo experimentos para evaluar la eficacia del sistema en términos de reducción de costos y gestión de inventario.

En última instancia, esta tesis busca contribuir al desarrollo de un sistema de compras efectivo que permita a los restaurantes tomar decisiones informadas y oportunas en cuanto a la adquisición de insumos. La combinación de un modelo matemático de predicción de demanda con redes neuronales representa un enfoque innovador para abordar los desafíos de la gestión de inventario en la industria gastronómica, con el objetivo de mejorar la eficiencia y sostenibilidad operativa.

Descriptores: 1. Predicción de la demanda de insumos, 2. Modelo matemático, 3. Redes neuronales artificiales.

Abstract

This work proposes the development of an intelligent purchasing system for restaurants, based on a mathematical demand prediction model. This model utilizes advanced statistical techniques and forecasting methods to analyze past consumption patterns and accurately forecast the quantities of inputs needed in the future. Additionally, a trained neural network is incorporated to further enhance demand estimations, thereby allowing for the reduction of food waste, optimization of inventory levels, and improvement in restaurant operational efficiency. The research methodology involves the collection and analysis of historical sales and purchasing data, as well as the exploration of various forecasting techniques and neural network algorithms. Experiments will be conducted to assess the system's effectiveness in terms of cost reduction, inventory management, and overall customer satisfaction.

Ultimately, this thesis aims to contribute to the development of an effective purchasing system that enables restaurants to make informed and timely decisions regarding input procurement. The combination of a mathematical demand prediction model with neural networks represents an innovative approach to addressing inventory management challenges in the gastronomy industry, with the goal of enhancing operational efficiency and sustainability.

Key words: 1. Input Demand Forecast , 2. Matematical Modelling, 3. Artificial Neural network.

Índice general

Resumen	IX
Abstract	X
Índice de figuras	XIV
Índice de tablas	XV
Acrónimos y símbolos	XV
1. Introducción	1
1.1. Motivación	2
1.2. Definición del problema	2
1.3. Objetivos	3
1.3.1. General	3
1.3.2. Específico	3
1.4. Hipótesis	3
1.5. Fundamentación	3
1.6. Impacto de la investigación	4
1.7. Organización del trabajo.	4
2. Conceptos fundamentales, teorías y antecedentes	6
2.1. Predicciones de Compras	6
2.1.1. Relación de Demanda y Gestión de Suministro	6
2.1.2. Importancia de la Predicción de Compra de Insumos	6
2.1.3. Factores que Influyen en la Curva de Insumos Deman- dados	9
2.2. Tiempos Actuales en las Predicciones de Demanda	9
2.3. Sistema de información	10
2.4. Minería de datos	13
2.5. Técnicas de modelado de procesos de ETL	14
2.6. Inteligencia Artificial	14

2.6.1.	El aprendizaje automático (<i>machine learning</i>)	14
2.6.2.	Aprendizaje supervisado	16
2.6.3.	Aprendizaje no supervisado	17
2.6.4.	Aprendizaje de refuerzo	18
2.6.5.	Redes Neuronales Artificiales	18
2.6.6.	Capas de la neurona artificial	20
2.6.7.	Modelo de redes neuronales artificiales	21
2.6.8.	Arquitectura de una red neuronal	22
2.6.9.	Perceptron	23
2.6.10.	Perceptrón multica	23
2.6.11.	Redes neuronales recurrentes (RNN)	24
2.6.12.	Arquitectura básica de una RNN	25
2.6.13.	Redes de Memoria Corta y Larga LSTM	25
2.6.14.	Modelo de Regresión Lineal	27
2.6.15.	Los pesos sinápticos	28
2.7.	Métricas para la evaluación de una red neuronal	28
2.7.1.	El error medio cuadrático (MSE)	28
2.7.2.	Raíz del error medio cuadrático (RMSE)	29
2.7.3.	Error Absoluto Medio (MAE)	29
2.7.4.	Error porcentual absoluto medio (MAPE)	30
2.7.5.	El coeficiente de determinación R^2	30
2.8.	Antecedentes	31
3.	Predicción de la demanda	34
3.1.	Preprocesamiento de datos	34
3.1.1.	Modelado de datos	35
3.1.2.	Escalado de datos	37
3.1.3.	Análisis de los datos	38
3.1.4.	Definición de las variables de entrada y salida	39
3.1.5.	Lectura y escalado del dataset en Python	41
3.1.6.	Distribución del conjunto de datos	43
3.2.	Aplicación y comparación de técnicas ML	44
3.2.1.	Regresión lineal	44
3.2.2.	LSTM	48
4.	Resultados	51
4.1.	Metricas de rendimiento	51
4.1.1.	Modelo de regresión lineal	51
4.1.2.	Modelo LSTM	51
4.2.	Informe de predicción de compras	51

5. Discusión	52
5.1. Logros alcanzados	52
5.2. Solución del problema de investigacin	52
5.3. Sugerencias para futuras investigaciones	52
Anexo A.	53
Glosario	53
Anexos	53
Referencias bibliográficas	54

Índice de figuras

2.1. Predicción de demanda a corto, mediano y largo plazo [1]. . .	7
2.2. Proceso de Optimización de inventario [1].	8
2.3. Arquitectura de un sistema experto [2].	13
2.4. flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo	16
2.5. Aprendizaje supervisado [1].	17
2.6. Componentes de una neurona.	20
2.7. Tipos de neuronas artificiales [3].	20
2.8. Aplicación de la Red Perceptron	23
2.9. La arquitectura básica de una RNN	25
2.10. Representación de una celda LSTM.	26
2.11. Regresión lineal	27
3.1. Estructura inicial de la tabla productos.csv	35
3.2. Estructura inicial de la tabla ventas.csv	35
3.3. Datos de la tabla productos(Los primeros 5 productos)	36
3.4. Datos de la tabla ventas	37
3.5. Datos escalados(muestra de la tabla ventas)	38
3.6. Serie temporal de las ventas totales por día	39
3.7. Tabla resultante con las variables de entrada	41
3.8. Lectura y escalado del dataset en Python	42
3.9. Grafico en violín incluyendo los tres set train, validación y test	42
3.10. Gráfico en violín de los datos de salida escaladas	43
3.11. Algoritmo de distribución de los datos.	44
3.12. Distribución de los datos, ventas totales por día.	44
3.13. Algoritmo de la estructura de regresión lineal.	46
3.14. Metrica de error regresión lineal.	46
3.15. Grafico de predicción con regresión lineal.	47
3.16. Predicción de 7 días con regresión lineal.	47
3.17. Algoritmo de la estructura del LSTM.	48
3.18. Grafico de predicción con LSTM.	49

3.19. Comparativo de desempeños LSTM.	50
3.20. Grafico de perdida(loss) en las épocas LSTM	50

Índice de Tablas

3.1. Descripción de datos de la tabla de productos	36
3.2. Descripción de datos de la tabla ventas	37
3.3. Descripción de datos escalados de la tabla ventas	38
3.4. Variables de entrada	40

Capítulo 1

Introducción

En el dinámico entorno de la industria gastronómica, la gestión eficiente de recursos se erige como una prioridad estratégica para alcanzar el éxito operativo y financiero. Entre estos recursos, los insumos desempeñan un papel fundamental, y su manejo adecuado no solo impacta la calidad y la consistencia de los platillos ofrecidos, sino también la rentabilidad y sostenibilidad del negocio en su conjunto. En este contexto, emerge la necesidad de desarrollar soluciones innovadoras y tecnológicas que permitan anticipar y ajustar la demanda de insumos de manera inteligente y precisa.

La gestión de un restaurante, es la actividad de dirección coordinada, relacionada con la oferta y el servicio de alimentos y bebidas en empresas de restauración, cumpliendo los requisitos que exige dicha actividad, con el objetivo de satisfacer necesidades y expectativas de sus clientes.

En el contexto actual de competitividad, es común que las empresas de servicios busquen mejorar sus sistemas de gestión, y adopten métodos y principios gerenciales de empresas industriales para aumentar su productividad y calidad. Sin embargo, es importante tener en cuenta que cada tipo de empresa tiene sus particularidades y características únicas que deben ser consideradas para una gestión eficiente.

En el caso de las empresas de servicios de restauración, es esencial estudiar y analizar las características de su actividad, y las particularidades del servicio que ofrecen, para poder aplicar los métodos y principios gerenciales de manera efectiva. Esto permitirá una gestión óptima de la entidad, mejorando los resultados económicos y asegurando la permanencia del negocio.

Entre las particularidades de la actividad de restauración, se pueden mencionar la importancia de la atención al cliente, la gestión de la calidad de los alimentos y bebidas, el manejo adecuado de los costos y la gestión de inventarios, entre otros aspectos. Estas características deben ser consideradas al momento de aplicar métodos de mejora de la productividad y calidad, y

adaptarlos a las necesidades específicas de la empresa de servicios de restauración.

Es cierto que las empresas de restauración constituyen un sistema operativo empresarial que se compone de varios subsistemas interrelacionados que trabajan juntos para lograr los objetivos empresariales. Uno de estos subsistemas es el de compras, que es fundamental para garantizar la eficacia del sistema de aprovisionamiento y, por tanto, para la planificación, producción y servicio.

El subsistema de compras tiene la responsabilidad de satisfacer las necesidades del subsistema de aprovisionamiento, asegurándose de que los abastecedores con los que se firma convenios cumplan con las especificaciones de calidad establecidas por la empresa de restauración. Además, es importante que el subsistema de compras garantice el abastecimiento de los productos necesarios y de alta calidad para la empresa de restauración.

Mediante los sistemas computacionales se logran procesar cada vez más cantidad de información, y realizar cálculos y operaciones, complejas por lo que realizar predicciones con estos sistemas resultan más confiables. Esta precisión puede ser mejorada ampliamente utilizando varias técnicas de predicción.

1.1. Motivación

Mediante la aplicación de técnicas avanzadas de análisis de datos y aprendizaje automático, este sistema proporcionará recomendaciones precisas y estratégicas, contribuyendo así al avance de la inteligencia empresarial y ofreciendo una herramienta eficiente para la toma de decisiones informadas y fundamentadas. El objetivo final es mejorar la eficiencia operativa, reducir costos y alcanzar ventajas competitivas, permitiendo a las empresas adaptarse y prosperar en un entorno comercial dinámico y desafiante.

1.2. Definición del problema

Este sistema debe ser capaz de utilizar el histórico de ventas del local para predecir la demanda futura de los productos, y en consecuencia, realizar las compras de manera más eficiente y rentable para la gerencia del local.

Problema de investigación: *Necesidad de optimizar la gestión de compras de materia prima de un local gastronómico en Ciudad del Este, utilizando sistema inteligente computarizado basado en el histórico de ventas.*

1.3. Objetivos

1.3.1. General

Desarrollar un sistema de compra inteligente basado en histórico de ventas para optimizar la gestión de compras de una empresa gastronómica de Ciudad del Este mediante algoritmos y técnicas de análisis de datos para predecir la demanda de productos en función del comportamiento de los clientes.

1.3.2. Específico

1. Comprender en profundidad la lógica de negocio de la empresa gastronómica para identificar los procesos críticos que deben ser incluidos en el sistema informático a desarrollar.
2. Recabar los requisitos del sistema con los usuarios y partes interesadas.
3. Modelar la lógica del sistema informático, utilizando técnicas y herramientas adecuadas, para garantizar su integridad y eficiencia.
4. Codificar el modelo lógico definido en lenguajes de programación Python y PHP.
5. Depurar los datos cuantitativos recopilados sobre el comportamiento del consumidor.
6. Realizar pruebas de usabilidad, accesibilidad, multiplataforma, y escalabilidad.

1.4. Hipótesis

La implementación de un sistema inteligente en un local gastronómico de Ciudad del Este, posibilitará una gestión de compras cuya eficiencia posibilitará reducir el costo de materia prima en al menos 10 % y predecir al menos con 70 % de acierto, la variedad y cantidad de productos a ser comprados.

1.5. Fundamentación

En el entorno comercial actual, la toma de decisiones basada en información histórica puede ser un factor clave para el éxito de una empresa. Sin embargo, en muchos casos, esta información no se explota adecuadamente y la gestión de datos se convierte en una tarea compleja.

En el caso de una empresa gastronómica, es importante conocer el rendimiento en ventas y controlar los índices que reflejen el desempeño del negocio. Sin embargo, la simple gestión de estos índices no es suficiente, ya que la empresa puede planificar una determinada cantidad de ventas y adquirir una cantidad de materia prima en consecuencia, pero luego no lograr vender todo lo adquirido y mantener un exceso de stock, o incluso tener productos en inventario que no se rotan.

Es por eso que se plantea el desarrollo de una aplicación que permita proyectar las ventas, para tener un presupuesto real de compras que se adapte a la demanda del mercado y evite el exceso de stock o la falta de rotación de inventarios. De esta manera, la empresa podrá tomar decisiones informadas y maximizar su rendimiento.

1.6. Impacto de la investigación

La implementación del sistema inteligente de compra basado en el histórico de ventas permitirá al gerente de la empresa tomar decisiones informadas y estratégicas, lo que se traducirá en un mejor desempeño económico y financiero de la empresa gastronómica.

Además, la investigación realizada para el desarrollo del sistema también tendrá un impacto positivo en otros estudiantes y futuros proyectos, ya que se podrán utilizar los conocimientos y experiencias adquiridos para mejorar otros procesos y aplicaciones en el ámbito empresarial y tecnológico. En consecuencia, la investigación tendrá un impacto significativo tanto en la empresa como en el ámbito académico y profesional.

1.7. Organización del trabajo.

El presente trabajo está organizado de la siguiente manera:

Capítulo 1: Este capítulo introductorio presenta la motivación para la investigación, que se enfoca en la gestión eficiente de insumos en la industria gastronómica. El problema de investigación se centra en la optimización de la gestión de compras de materia prima en un restaurante de Ciudad del Este. Se establecen los objetivos, hipótesis y la importancia del estudio, destacando su impacto positivo en la empresa y en futuros proyectos.

Capítulo 2: Se presentan algunos conceptos relacionados con las predicciones de compras de insumos, cómo funciona la relación de demanda y

gestion de suministro de un local gastronómico, por qué es importante la predicción de compra de insumos para el planeamiento futuro tanto a corto, mediano y largo plazo, los factores que influyen en el comportamiento de la curva de insumos demandados y tiempos actuales en las predicciones de demanda.

Capítulo 3: En este capítulo se aborda la afinación de hiperparámetros en un modelo de predicción, utilizando el porcentaje de pérdida Root Mean Square (RMS) como métrica guía para evaluar el rendimiento del modelo. Se describen los procedimientos para ajustar diferentes hiperparámetros, como la tasa de aprendizaje y el número de capas ocultas, con el objetivo de minimizar la pérdida RMS y, por lo tanto, mejorar la precisión y eficiencia del modelo de predicción. Se detalla la metodología empleada en este proceso, incluyendo la utilización de conjuntos de validación y estrategias de búsqueda de hiperparámetros, y se presentan los resultados obtenidos tras la afinación.

Capítulo 4: En este capítulo se presentan y analizan los resultados de las predicciones de compras con los modelos de predicción estudiados.

Capítulo 5: En el último capítulo de esta tesis, se procede a la discusión y análisis de los resultados obtenidos. Se lleva a cabo una evaluación de la eficacia del modelo de predicción y se reflexiona sobre su relevancia en el marco del sistema de compra inteligente basado en el historial de ventas. Además, se destacan áreas potenciales para investigaciones futuras en el contexto de este sistema.

Capítulo 2

Conceptos fundamentales, teorías y antecedentes

2.1. Predicciones de Compras

La predicción es el proceso de anticipar la cantidad y tipo de insumos que un negocio gastronómico necesitará adquirir en el futuro, con el objetivo de asegurar un suministro adecuado y eficiente.

2.1.1. Relación de Demanda y Gestión de Suministro

La relación de demanda y gestión de suministro se refiere a la interacción entre la cantidad de productos o insumos que los clientes requieren (demanda) y cómo la empresa se asegura de tener suficientes suministros disponibles para satisfacer esa demanda de manera eficiente. En un negocio gastronómico, la gestión de suministros es crucial para evitar situaciones en las que falten ingredientes clave, lo que podría afectar negativamente la calidad del servicio y la satisfacción del cliente.

2.1.2. Importancia de la Predicción de Compra de Insumos

La mayoría de las empresas distribuidoras de productos sufren de manera recurrente al no conocer la cantidad o un aproximado de productos que debería mantener en stock ya que, por un lado, si el stock es demasiado grande se pueden producir pérdidas de mercancía y costos innecesarios de transporte y almacenamiento, por el contrario, si el stock es demasiado pequeño, este será insuficiente para cubrir la demanda de los diferentes productos y se verá

reflejado en la pérdida de clientes [4].

La aplicación de un modelo de predicción para planificar la demanda futura es un proceso circular de mejora continua. Eso significa que el modelo es enriquecido constantemente con datos en tiempo real para realizar predicciones más precisas y generar una planificación más acorde a la realidad [1].



Figura 2.1: Predicción de demanda a corto, mediano y largo plazo [1].

1. Utiliza la **Predicción de la demanda a largo plazo para la planificación estratégica**. Simula y compara diferentes escenarios hipotéticos de demanda, anticipa los cambios de mercado y planifica la contratación futura de recursos.
2. Utiliza la **Predicción de la demanda a corto plazo para la planificación operativa**. Planifica semanalmente las operaciones y recursos del día.
3. Utiliza la **Predicción de la demanda a medio plazo para la planificación táctica**. Conoce las capacidades con meses de antelación y compáralas con las actuales para detectar posibles necesidades.

La predicción de compra de insumos es vital para la planificación a corto, mediano y largo plazo en un negocio gastronómico por varias razones:

1. **Optimización de Inventario:** El inventario tiene como propósito fundamental proveer a la empresa de materiales necesarios, para su continuo y regular desenvolvimiento, es decir, el inventario tiene un papel

vital para el funcionamiento acorde y coherente dentro del proceso de producción y de esta forma afrontar la demanda [5].

Al prever la demanda futura, el negocio puede mantener un nivel de inventario óptimo. Comprar en exceso puede llevar al desperdicio de alimentos, mientras que comprar muy poco puede resultar en escasez y pérdida de ventas.



Figura 2.2: Proceso de Optimización de inventario [1].

2. **Reducción de Costos:** Una predicción precisa permite comprar solo lo necesario, lo que reduce los costos asociados con el almacenamiento y la conservación de productos perecederos.

Si se mantienen inventarios demasiado altos, el costo podría llevar a una empresa a tener problemas de liquidez financiera, esto ocurre porque un inventario “parado” inmoviliza recursos que podrían ser mejor utilizados en funciones más productivas de la organización [5].

3. **Eficiencia Operativa:** Saber qué insumos se necesitarán en el futuro permite planificar y programar las operaciones de manera más eficiente, evitando retrasos y problemas logísticos.

Es útil mantener los inventarios en las empresas porque, se tiene en cuenta la capacidad de predicción con el fin de planear la capacidad y establecer un cronograma de producción, también fluctuaciones en la

demanda ósea una reserva de inventarios a la mano que supone protección, inestabilidad de los suministros, protección deprecios, descuentos por cantidad, menores costos de pedidos [5].

4. **Satisfacción del Cliente:** Mantener un suministro constante de productos esencial para el negocio, ya que los clientes esperan encontrar su elección preferida en el menú en todo momento.

2.1.3. Factores que Influyen en la Curva de Insumos Demandados

Varios factores pueden influir en el comportamiento de la curva de insumos demandados:

- **Día de la Semana y Estacionalidad:** Los patrones de consumo pueden variar según el día de la semana y la temporada. Por ejemplo, los fines de semana pueden tener una mayor demanda en comparación con los días laborables.
- **Eventos Especiales:** Eventos como días festivos, celebraciones locales o conciertos cercanos pueden aumentar la demanda de alimentos y bebidas.
- **Tendencias de Consumo:** Las tendencias gastronómicas y las preferencias cambiantes de los consumidores pueden afectar la demanda de ciertos productos.
- **Clima:** Las condiciones climáticas también pueden influir en la demanda. Por ejemplo, un día caluroso podría aumentar la demanda de bebidas frías.
- **Promociones y Ofertas:** Las promociones especiales pueden aumentar temporalmente la demanda de ciertos productos.

2.2. Tiempos Actuales en las Predicciones de Demanda

En la actualidad, las predicciones de demanda se benefician ampliamente de las tecnologías avanzadas y el análisis de datos. Las empresas pueden aprovechar sistemas de gestión de inventario y software de análisis de datos

para recopilar y procesar información histórica y en tiempo real. Estas herramientas les permiten aplicar técnicas estadísticas y modelos de pronóstico para anticipar con mayor precisión los patrones de demanda futura.

En tiempos recientes, se ha observado la aplicación de diversas técnicas en el campo de la inteligencia artificial, como sistemas expertos, y más recientemente, algoritmos genéticos. Sin embargo, a pesar de esta evolución, los modelos que han captado una atención destacada son los basados en Redes Neuronales Artificiales (RNAs). Con el transcurso del tiempo, se han desarrollado múltiples arquitecturas de RNAs para abordar una variedad de problemas en el ámbito de la predicción de demanda.

2.3. Sistema de información

Según [6] el sistema de información *“Es un conjunto de elementos que interactúan entre sí, con el fin de apoyar las actividades de una empresa o negocio”*.

Es importante tener en cuenta que la necesidad de información en las organizaciones es vital para alcanzar el éxito y que un sistema de información debe justificar su implementación desde el punto de vista costo/beneficio, basándose en el valor que se le otorga a la información dentro de la organización [6]. Los beneficios pueden ser tangibles e intangibles, y dependen de los objetivos y necesidades de la organización.

Los sistemas de información se desarrollan para diferentes propósitos, según las necesidades de los usuarios humanos y la empresa. En definitiva, el uso adecuado de la información y la implementación de sistemas de información efectivos pueden marcar una gran diferencia en el éxito de una organización.

paragraph Tipos de sistema de información

El propósito de un sistema de información, puede ser muy amplio, todo depende de las necesidades de la organización. Existen distintos tipos de sistemas de información, entre los que destacan los siguientes [6]:

Sistemas de procesamiento de transacciones Se define como transacción un suceso que implica o afecta a una organización, y que está compuesta por datos referentes a ellas y que son de importancia para la organización [6]. Estos sistemas se encargan del procesamiento de los datos referentes a las transacciones, además de permitir la automatización de tareas y procesos operativos.

La información que se obtiene como salida es utilizada posteriormente por los funcionarios de nivel operativo de la organización en la toma de decisiones.

Las razones para el procesamiento de las transacciones son:

- **Clasificación:** Implica agrupar todos los datos de acuerdo con características comunes.
- **Operaciones de cálculo:** Consiste en realizar alguna operación para obtener resultados útiles.
- **Ordenamiento:** Consiste en disponerlos de alguna forma o secuencia, facilita el procesamiento y la búsqueda.
- **Síntesis:** Reduce los datos en información breve y concisa.
- **Almacenamiento:** Permite el registro de todas y cada una del suceso que afectan a la organización.

Sistema de información administrativa Los sistemas de información administrativa (MIS) no sustituyen a los sistemas de procesamiento de transacciones; más bien, todos los sistemas MIS incluyen el procesamiento de transacciones [6]. Los MIS son sistemas de información computarizados que funcionan debido a la decidida interacción entre las personas y las computadoras.

Al requerir que las personas, el software y el hardware funcionen en conjunto, los sistemas de información administrativa brindan soporte a los usuarios para realizar un espectro más amplio de tareas organizacionales que los sistemas de procesamiento de transacciones, incluyendo los procesos de análisis y toma de decisiones. Para acceder a la información, los usuarios del sistema de información administrativa comparten una base de datos común; esta almacena tanto los datos como los modelos que permiten al usuario interactuar con ellos, interpretarlos y aplicarlos. Los sistemas de información administrativa producen información que se utiliza en el proceso de toma de decisiones. También pueden ayudar a integrar algunas de las funciones de información computarizadas de una empresa.

Sistema de soporte de decisiones DSS Son sistemas de información que tienen como propósito auxiliar al usuario con las decisiones únicas que no se repiten y que no tienen una estructura definida [6]. Además de estar hechos a la medida de la persona o grupo que los usa en comparación con los Sistemas de información Gerencial. El propósito de estos sistemas es el de responder correctamente a condiciones inesperadas y propias de la información. Esto permite que sean empleados en niveles altos de la organización.

Sistema de información gerencial Los Sistemas de Información Gerencial, también llamados Sistemas de Reportes de Gerencia, se dedican al apoyo de decisiones siempre que los requerimientos de información sean identificados, esto es, que la información que necesita para la toma de decisiones haya sido analizada anteriormente, y que esta misma decisión pueda tomarse nuevamente [6]. Estos sistemas pueden extraer la información necesaria de cualquier parte de la organización, por lo que la información necesaria ya se tiene almacenada al ser procesada por un sistema de transacciones.

Sistema experto e inteligencia artificial La inteligencia artificial (IA) puede ser considerada como el campo dominante de los sistemas expertos. La idea general de la IA ha sido desarrollar equipos que se comporten de manera inteligente [6].

Dos ramas de investigación de la IA son:

- La comprensión del lenguaje natural.
- El análisis de la habilidad para razonar un problema y llegar a una conclusión lógica.

Los sistemas expertos utilizan las metodologías de razonamiento de la IA para resolver los problemas que los usuarios de negocios (y otros tipos de usuarios) les presentan. Los sistemas expertos son una clase muy especial de sistema de información que ha demostrado su utilidad comercial gracias a la disponibilidad extendida de hardware y software como las computadoras personales (PC) y las interfaces de sistemas expertos.

Un sistema experto (también conocido como sistema basado en el conocimiento) captura y utiliza en forma efectiva el conocimiento de uno o varios expertos humanos para resolver un problema específico al que una organización se enfrenta. Cabe mencionar que a diferencia de los sistemas DSS, que en última instancia dejan la decisión a la persona encargada de la toma de decisiones, un sistema experto selecciona la mejor solución para un problema o una clase específica de problemas. Los componentes básicos de un sistema experto son la base de conocimiento, un motor de inferencia que conecta al usuario con el sistema mediante el proceso de consultas en lenguajes, como el lenguaje de consulta estructurado (SQL), y la interfaz de usuario. Las personas conocidas como ingenieros del conocimiento capturan la experiencia de los expertos, crean un sistema computacional que incluye este conocimiento y después lo implementan [6].

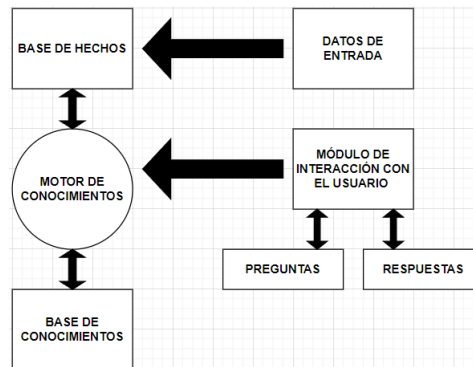


Figura 2.3: Arquitectura de un sistema experto [2].

En los Sistemas Expertos el conocimiento se hace explícito en forma de reglas, en la computación neuronal las ANN generan sus propias reglas aprendiendo de los ejemplos que se les muestran en la fase de entrenamiento [7].

2.4. Minería de datos

La minería de datos puede definirse inicialmente como un proceso de descubrimiento de nuevas y significativas relaciones, patrones y tendencias al examinar grandes cantidades de datos [8].

El análisis de datos, potenciado por herramientas informáticas, ha dado lugar a la minería de datos. Esta disciplina busca descubrir automáticamente conocimiento en grandes bases de datos, identificando patrones, tendencias y perfiles a través de tecnologías avanzadas como el reconocimiento de patrones, redes neuronales y algoritmos genéticos.

Inicialmente, los sistemas de información se centraban en recopilar datos para apoyar la toma de decisiones. Con la informatización de las organizaciones, se amplió su función para respaldar los procesos esenciales. Ahora, se buscan prestaciones adicionales, como sistemas de información para la toma de decisiones.

La Minería de Datos se puede ubicar en el nivel más alto de la evolución de los procesos tecnológicos de análisis de datos [9].

La Minería de Datos involucra e integra técnicas de diferentes disciplinas tales como tecnologías de bases de datos y data warehouse, estadística, aprendizaje de máquina, computación de alta performance, computación evolutiva, reconocimiento de patrones, redes neuronales, visualización de datos, recuperación de información, procesamiento de imágenes y señales, y análisis de datos espaciales o temporales [10].

2.5. Técnicas de modelado de procesos de ETL

Las herramientas de Extracción-Transformación-Carga (ETL) son piezas de software responsables de la extracción de datos de varias fuentes, su limpieza, personalización e inserción en un almacén de datos [11].

El proceso de extracción, transformación y carga – ETL es una de las actividades técnicas más críticas en el desarrollo de soluciones de inteligencia de negocios BI [12].

El proceso de ETL es esencial para garantizar la calidad y la integridad de los datos antes de que se utilicen en aplicaciones analíticas o de toma de decisiones. Permite a las organizaciones transformar datos crudos en información procesable y confiable. Además, con la creciente cantidad de datos disponibles en la actualidad, el ETL se ha vuelto cada vez más importante para integrar datos de diversas fuentes y garantizar que estén listos para su análisis.

Para autores como Ralph Kimball los Almacenes de Datos son “una copia de los datos transaccionales estructurados específicamente para consultas y análisis”, mientras que Bill Inmon define el término Almacén de Datos como: “una colección de datos orientados por temas, integrados, variables en el tiempo y no volátiles para el apoyo de la toma de decisiones”. Los Almacenes de Datos son integradores, ya que su contenido proviene de diversas fuentes de datos como: Sistemas heredados, Archivos de Textos, Base de Datos Relacionales, ERP, entre otras posibilidades. La forma de lograr esta integración es a través del uso y desarrollo de los Procesos ETL. Estos procesos son los encargados de la extracción de los datos desde sus fuentes de origen, de transformarlos a la información deseada, de lograr la limpieza necesaria en aquellos que lo requieran y finalmente cargar al Almacén de Datos deseado, el que será utilizado con alguna finalidad como análisis en un área de las ventas de una corporación o el estudio de tendencias de alguna consultora [13].

2.6. Inteligencia Artificial

2.6.1. El aprendizaje automático (*machine learning*)

Según Arthur Samuel, el aprendizaje automático se define como el campo de estudio que otorga a las computadoras la capacidad de aprender sin ser programadas explícitamente [14].

El aprendizaje automático se utiliza para enseñar a las máquinas a manejar los datos de manera más eficiente. A veces, después de ver los datos, no podemos interpretar la información extraída de los mismos. En ese caso,

aplicamos el aprendizaje automático.

Es decir, el aprendizaje automático como área de las ciencias computacionales aplicadas, desarrolla algoritmos capaces de tomar datos numéricos y alfanuméricos almacenados en un computador [15].

Con la abundancia de conjuntos de datos disponibles, la demanda de aprendizaje automático está en aumento. Muchas industrias aplican el aprendizaje automático para extraer datos relevantes. El propósito del aprendizaje automático es aprender de los datos. Se han realizado muchos estudios sobre cómo hacer que las máquinas aprendan por sí mismas sin ser programadas explícitamente. Muchos matemáticos y programadores aplican varios enfoques para encontrar la solución a este problema que implica conjuntos de datos enormes [14].

El Aprendizaje Automático se basa en diferentes algoritmos para resolver problemas de datos. A los científicos de datos les gusta señalar que no existe un único tipo de algoritmo que sea universal y mejor para resolver todos los problemas. El tipo de algoritmo utilizado depende del tipo de problema que se desee resolver, el número de variables, el tipo de modelo que se adapte mejor, entre otros factores.

Las técnicas de machine learning son necesarias para mejorar la precisión de los modelos predictivos. Dependiendo de la naturaleza del problema empresarial que se está atendiendo, existen diferentes enfoques basados en el tipo y volumen de los datos [16].

En el contexto de la aplicación de algoritmos de Machine Learning en el cálculo de pronósticos de demanda, es esencial comprender que el objetivo principal de estos algoritmos es encontrar una función que tome un conjunto de variables como entrada y produzca una estimación del valor deseado, en este caso, la demanda. Esta función se ajusta a través del aprendizaje a partir de observaciones pasadas donde los datos de demanda son conocidos. Por ejemplo, utilizando datos de demanda de los últimos años, el modelo se entrena para desarrollar una función que pueda hacer predicciones precisas sobre la demanda futura, lo que implica una tarea de regresión, ya que el resultado esperado es un valor numérico real. Esta metodología se basa en el libro “Deep Learning” de Ian Goodfellow, Yoshua Bengio y Aaron Courville [17].

Una forma común de describir a un conjunto de datos u observaciones (dataset) es con una matriz de diseño. Una matriz de diseño es una matriz que contiene un ejemplo diferente en cada fila. Cada columna de la matriz corresponde a una característica diferente. Los algoritmos de aprendizaje se diferencian en función de la forma de operar y procesa los datos contenidos en una matriz de diseño [18].

El siguiente diagrama muestra un flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo [19]:

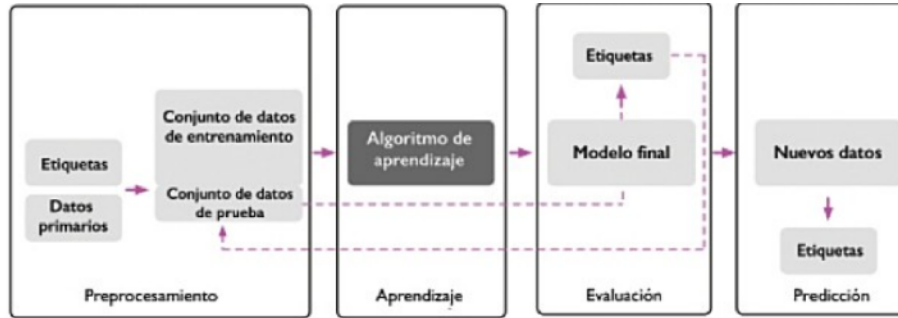


Figura 2.4: flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo

Procesamiento:

- Extracción y escalado de características.
- Selección de características.
- Reducción de la dimensionalidad.
- Muestreo.

Aprendizaje:

- Selección del modelo.
- Validación cruzada.
- Medición del rendimiento.
- Optimización de hiperparametro.

2.6.2. Aprendizaje supervisado

El aprendizaje supervisado comienza típicamente con un conjunto establecido de datos y una cierta comprensión de cómo se clasifican estos datos. El aprendizaje supervisado tiene la intención de encontrar patrones en datos que se pueden aplicar a un proceso de analítica. Estos datos tienen características etiquetadas que definen el significado de los datos. Por ejemplo,

se puede crear una aplicación de machine learning con base en imágenes y descripciones escritas que distinga entre millones de animales [16].

El objetivo principal del aprendizaje supervisado es aprender un modelo, a partir de datos de entrenamiento etiquetados, que nos permite hacer predicciones sobre datos futuros o no vistos [19]. Aquí, el término supervisado se refiere a un conjunto de muestras donde las señales de salida deseadas (etiquetas) ya se conocen.

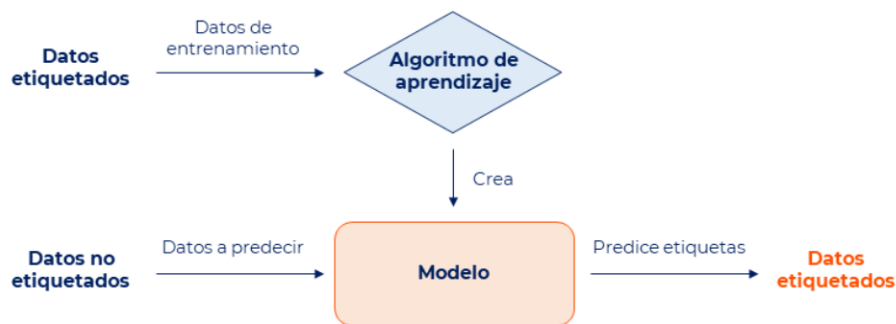


Figura 2.5: Aprendizaje supervisado [1].

2.6.3. Aprendizaje no supervisado

El aprendizaje no supervisado se utiliza cuando el problema requiere una cantidad masiva de datos sin etiquetar. Por ejemplo, las aplicaciones de redes sociales, tales como Twitter, Instagram y Snapchat, tienen grandes cantidades de datos sin etiquetar. La comprensión del significado detrás de estos datos requiere algoritmos que clasifican los datos con base en los patrones o clústeres que encuentra. El aprendizaje no supervisado lleva a cabo un proceso iterativo, analizando los datos sin intervención humana [16].

Los métodos de aprendizaje no supervisados son utilizados durante el preprocesamiento de los datos antes de ser utilizados por algoritmos de característica supervisada. Estos algoritmos también son muy utilizados en la compresión de datos. Todos los métodos son implícita o explícitamente basados en la distribución de probabilidad en el espacio definido por las variables de entrada [20].

2.6.4. Aprendizaje de refuerzo

El aprendizaje de refuerzo es un modelo de aprendizaje conductual. El algoritmo recibe retroalimentación del análisis de datos, conduciendo al usuario hacia el mejor resultado. El aprendizaje de refuerzo difiere de otros tipos de aprendizaje supervisado, porque el sistema no está entrenado con el conjunto de datos de ejemplo. Más bien, el sistema aprende a través de la prueba y el error. Por lo tanto, una secuencia de decisiones exitosas conduce al fortalecimiento del proceso, porque es el que resuelve el problema de manera más efectiva [16].

2.6.5. Redes Neuronales Artificiales

Las Redes Neuronales Artificiales (RNA) son un componente esencial de la Inteligencia Artificial que emula el funcionamiento de las neuronas biológicas. Estas redes, entrenadas con entradas de escenarios internos o externos multiplicadas por pesos aleatorios, destacan en la resolución de funciones altamente no lineales, lo que las convierte en herramientas poderosas para la predicción. Inspiradas en el sistema nervioso biológico, encuentran aplicaciones en áreas como neurociencias, matemáticas, estadísticas y más. Su capacidad para aprender de datos de entrada las hace especialmente valiosas en la predicción de patrones complejos en diversos campos, como finanzas, ciencia de datos y análisis de mercado.

Es un algoritmo basado en una red de alimentación de múltiples capas entrenadas inspirado en las neuronas del cerebro humano, estos sistemas aprenden y se forman a sí mismos ya que sus neuronas artificiales están conectadas, en lugar de ser programados de forma explícita [15].

En el desarrollo de una red neuronal no hay que programar ni el conocimiento ni las reglas del procesamiento del conocimiento. La red neuronal aprende las reglas del procesamiento del conocimiento mediante el ajuste de las conexiones ponderadas entre las neuronas de distintas capas de la red. El aprendizaje se consigue a través de una regla de aprendizaje que adapta o cambia los pesos de las conexiones en respuesta a los ejemplos de entrada, y opcionalmente también en respuesta a las salidas deseadas. Esta característica de las ANN es lo que permite decir que las redes neuronales aprenden de la experiencia [7].

La neurona artificial fue diseñada para “emular” las características del funcionamiento básico de la neurona biológica [21]. En esencia, se aplica un conjunto de entradas a la neurona, cada una de las cuales representa

una salida de otra neurona . Cada entrada se multiplica por su “peso” o ponderación correspondiente análogo al grado de conexión de la sinapsis. Todas las entradas ponderadas se suman y se determina el nivel de excitación o activación de la neurona.

Representación vectorial del funcionamiento básico de una neurona artificial se indica según la siguiente expresión de la ecuación.

$$NET = X \cdot W$$

Siendo NET la salida, X el vector de entrada y W el vector de pesos.

La representación del modelo matemático es el siguiente

$$y = H \left(\sum_{j=1}^n w_j x_j - u \right) \quad (2.1)$$

Donde H es la función de activación (en este caso la función escalón de Heaviside) con el umbral u , x_j es la señal de entrada y w_j es el peso asociado con $j = 1, 2, \dots, n$, donde n corresponde al número de entradas. La salida de esta unidad es 1 cuando la suma está por encima del umbral u , y es 0 en caso contrario [18].

El elemento fundamental de los sistemas neuronales biológicos es la neurona, una célula viva que, como tal contiene todos los elementos que integran las células biológicas, si bien incorpora otros elementos que la diferencian (Figura 2.6). De forma genérica, una neurona consta de un cuerpo celular o soma más o menos esférico (de entre 10 y 80 micras de longitud), del que parten una rama principal o axón (cuya longitud varía desde las 100 micras hasta el metro en el caso de las neuronas motoras que constituyen los nervios) y un denso árbol de ramificaciones más cortas (árbol dendrítico), compuesto por dendritas. A su vez, el axón puede ramificarse en su punto de arranque, y con frecuencia presenta múltiples ramas en su extremo. La forma final de la neurona depende de la función que cumple, esto es, de la posición que ocupa en el conjunto del sistema y de los estímulos que recibe [3].




Figura 2.6: Componentes de una neurona.

2.6.6. Capas de la neurona artificial

Desde un punto de vista funcional, las neuronas constituyen procesadores de información sencillos, integrados por: Un canal de recepción de información, las dendritas, que reciben señales de entrada (inputs) procedentes de otras células (interneuronas) o del exterior (neuronas receptoras o sensoras, como los conos y bastones de la retina) [22].

Un órgano de cómputo, el soma, que combina e integra los inputs recibidos (generalmente a través de funcionales no lineales), emitiendo señales de salida en forma de estímulos nerviosos [22].

Un canal de salida, el axón, que envía la salida generada por el soma a otras neuronas o bien, en el caso de las neuronas motoras, directamente al músculo. Para transmitir la información, el axón se conecta a través de sus ramificaciones a las dendritas de otras neuronas, que reciben las señales y las combinan para producir nuevas salidas. Una neurona del córtex cerebral recibe información, por término medio, de unas 10.000 neuronas (convergencia), y envía impulsos a varios cientos de ellas (divergencia) [22].




Figura 2.7: Tipos de neuronas artificiales [3].

Características de tres tipos de neuronas artificiales: unidades de entrada, de salida y unidades ocultas(Figura 2.7) [3].

- Las neuronas de entrada reciben señales desde el entorno, provenientes de sensores o de otros sectores del sistema (como archivos de almacenamiento de patrones de aprendizaje).
- Las neuronas de salida envían su señal directamente fuera del sistema una vez finalizado el tratamiento de la información (salidas de la red).
- Las neuronas ocultas reciben estímulos y emiten salidas dentro del sistema, sin mantener contacto alguno con el exterior. En ellas se lleva a cabo el procesamiento básico de la información, estableciendo la representación interna de ésta.

2.6.7. Modelo de redes neuronales artificiales

Las redes neuronales artificiales son motivadas por ciertas cualidades de su modelo real, por lo cual el desafío es producir un modelo que tenga [23]:

- Una estructura de procesamiento distribuida y paralela (opuestamente al CPU de una computadora).

La arquitectura de las ANN parte de la organización de los sistemas de procesado en paralelo, es decir, sistemas en los que distintos procesadores están interconectados. No obstante los procesadores son unidades procesadoras simples, diseñadas para la suma de muchas entradas y con un ajuste automático de las conexiones ponderadas.

- Alto grado de conexion entre las unidades basicas.
- Conexiones modificables en funcion de la experiencia.
- Un proceso de aprendizaje constante y de ser posible uno no supervisado
- Aprendizaje basado en informacion local.
- Robustez en la performance si algunas unidades son removidas.

2.6.8. Arquitectura de una red neuronal

La topología o arquitectura hace referencia a la organización y disposición de las neuronas en la red formando capas de procesadores interconectados entre sí a través de sinapsis unidireccionales. La arquitectura de una RNA depende de cuatro parámetros principales [3]:

- el número de capas,
- el número de neuronas por capa,
- el grado de conectividad entre las neuronas y
- el tipo de conexiones neuronales.

Las arquitecturas neuronales pueden clasificarse atendiendo a distintos criterios [3]:

- Según su estructura en capas
 - Redes monocapa, compuestas por una única capa de neuronas, entre las que se establecen conexiones laterales y, en ocasiones, autorrecurrentes. Este tipo de redes suele utilizarse para la resolución de problemas de autoasociación y clusterización.
 - Redes multicapa (layered networks), cuyas neuronas se organizan en varias capas (de entrada, oculta(s) y de salida). La capa a la que pertenece la neurona puede distinguirse mediante la observación del origen de las señales que recibe y el destino de la señal que genera.
- Según el flujo de datos en la red
 - Redes unidireccionales o de propagación hacia adelante (feedforward), en las que ninguna salida neuronal es entrada de unidades de la misma capa o de capas precedentes. La información circula en un único sentido, desde las neuronas de entrada hacia las neuronas de salida de la red.
 - Redes de propagación hacia atrás (feedback), en las que las salidas de las neuronas pueden servir de entradas a unidades del mismo nivel (conexiones laterales) o de niveles previos. Las redes de propagación hacia atrás que presentan lazos cerrados se denominan sistemas recurrentes.

2.6.9. Perceptron

En 1957, Frank Rosenblatt publicó el mayor trabajo de investigación en computación neuronal realizado hasta esas fechas. Su trabajo consistía en el desarrollo de un elemento llamado “Perceptron” [7].

El perceptron es un sistema clasificador de patrones que puede identificar patrones geométricos y abstractos. El primer perceptron era capaz de aprender algo y era robusto, de forma que su comportamiento variaba sólo si resultaban dañados los componentes del sistema. Además presentaba la característica de ser flexible y comportarse correctamente después de que algunas celdas fueran destruidas. El perceptron fue originalmente diseñado para el reconocimiento óptico de patrones. Una rejilla de 400 fotocélulas, correspondientes a las neuronas de la retina sensibles a la luz, recibe el estímulo óptico. Estas fotocélulas están conectadas a elementos asociativos que recogen los impulsos eléctricos emitidos desde las fotocélulas. Las conexiones entre los elementos asociativos y las fotocélulas se realizan de forma aleatoria. Si las células presentan un valor de entrada superior a un umbral predeterminado entonces el elemento asociativo produce una salida [7].




Figura 2.8: Aplicación de la Red Perceptron

2.6.10. Perceptrón multicapa

Una Perceptrón multicapa (MLP) puede ser interpretada como una extensión del algoritmo de regresión logística donde primero la entrada es transformada utilizando una transformación no lineal [20]. El propósito de esta transformación es proyectar los datos de entrada a un espacio donde sean linealmente separables. Esta capa intermedia es conocida como capa oculta

y es característica de una MLP poseer dos o mas de ellas. Una capa oculta única es suficiente para hacer de una MLP un aproximador universal.

2.6.11. Redes neuronales recurrentes (RNN)

Una de las ideas principales que propició el desarrollo de estas redes fue extraída de las técnicas de aprendizaje automático y de los modelos estadísticos encontrados en la década de los 80. Esta idea se basaba en compartir diferentes parámetros a lo largo de diferentes partes de un modelo. Esto permitió generalizar conjuntos de datos que contaban con dependencias temporales entre sus entradas [24].

Un perceptrón multicapa tendría muy difícil el hecho de generalizar sobre una secuencia debido a que, si entrenamos esta red con secuencias de longitud fija, la red tendría parámetros separados para cada una de las características de entrada teniendo que aprender todas las reglas por separado. Sin embargo, la RNNs encontraría esta tarea mucho más fácil debido a que comparte pesos a lo largo del tiempo. Cabe mencionar que cuando mencionamos el tiempo no tiene por que significar literalmente tiempo, puede simplemente significar la posición de un objeto en una secuencia [25].

Las redes neuronales recurrentes tienen caminos de retroalimentación entre todos los elementos que las conforman. Una sola neurona está entonces conectada a las neuronas posteriores en la siguiente capa, las neuronas pasadas de la capa anterior y a ella misma a través de vectores de pesos variables que sufren alteraciones en cada época con el fin de alcanzar los parámetros o metas de operación [26].

Las redes neuronales recurrentes (RNNs) son un tipo de modelo de aprendizaje profundo que se utiliza para analizar datos secuenciales, como el procesamiento del lenguaje natural o la predicción de series de tiempo [27].

A diferencia de las redes neuronales artificiales ya vistas, que asumen la independencia entre los datos de entrada, las RNN capturan activamente sus dependencias secuenciales y temporales [18].

Las RNN generalmente aumentan la arquitectura de red multicapa convencional con la adición de ciclos que conectan nodos adyacentes o pasos de tiempo.

Estos ciclos constituyen la memoria interna de la red que se utiliza para evaluar las propiedades del dato actual con respecto a los datos del pasado inmediato.

Las redes neuronales recurrentes son más eficaces para resolver problemas con no linealidades temporales significativas. Son especialmente útiles en aplicaciones tales como el reconocimiento de patrones secuenciales, cambiantes

en el tiempo, ya que las capacidades de predicción y mapeo de las RNN así lo permiten [26].

Sin embargo, la capacidad de las RNNs para manejar datos a largo plazo se ve comprometida por el problema del gradiente que desaparece, que ocurre cuando el gradiente se hace cada vez más pequeño a medida que se propaga hacia atrás en la red [27].

Para superar este problema, Hochreiter & Schmidhuber, propusieron la memoria a corto y largo plazo (LSTM), una variante de las RNNs que ha demostrado ser efectiva para el procesamiento de datos secuenciales a largo plazo [27].

2.6.12. Arquitectura básica de una RNN

Arquitectura básica de una RNN. Una característica importante es la inclusión de retrasos (z^{-1}) a la salida de las neuronas en las capas intermedias; las salidas parciales $S_{mn}(t+1)$ se convierten en valores $S_{mn}(t)$, un instante de tiempo anterior, y así se retroalimenta a todos los componentes de la red, guardando información de instantes de tiempo anteriores [26]. Se puede apreciar cómo todos los nodos están interconectados entre sí, estableciendo conexiones tanto directas como mediante retardos temporales con los nodos precedentes en cada capa, lo que permite la incorporación de memorias temporales.




Figura 2.9: La arquitectura básica de una RNN

2.6.13. Redes de Memoria Corta y Larga LSTM

Las redes de “larga memoria de corto plazo” (Redes de Memoria Corta y Larga (LSTM)), propuestas por Hochreiter y Schmidhuber. Es una de las arquitecturas de aprendizaje profundo más avanzadas y exitosas para

predicción de series temporales, reconocimiento de escritura y análisis de discurso [28].

El modelo matemático de LSTM se define como una función no lineal que transforma la entrada actual, el estado anterior y la memoria a largo plazo en una salida y un estado actualizado.

El cálculo de esta función implica la operación de multiplicación de matrices y la aplicación de funciones de activación, como la función sigmoide o la tangente hiperbólica [27].

El objetivo es mejorar la memoria de la RNN de los eventos pasados entrenándola para que recuerde lo importante y olvide el resto. Para ello, las LSTM procesan dos versiones del pasado [18].

Las LSTM's Estas se han diseñado para evaluar series de datos donde el pasado es importante para presentar una evaluación futura. tienen un alta sensibilidad a los datos a escala en entrada, más aún cuando las funciones de activación son la tangente hiperbólica y la función sigmoidea. Debido a esto es necesario realizar el escalado de los datos [29].

Las unidades LSTM (Long Short-Term Memory) son unidades utilizadas en la construcción de redes recurrentes. Cada unidad LSTM es una celda con cuatro puertas (gates): la input gate, la external input gate, la forget gate y output gate. Lo más importante de la celda es su estado interno, encargado de recordar valores a lo largo del tiempo [25].




Figura 2.10: Representación de una celda LSTM.

El **estado interno** está representado en el diagrama anterior por C y recorre todas las celdas encadenadas, experimentando pequeños cambios cada vez que pasa por cada una de ellas.

El **estado oculto** (*hidden-state*) es, sin embargo, la salida de cada una de las unidades y se comparte a lo largo de todas las unidades de nuestro modelo. Está representado con la letra h .

El primer cambio que experimenta el estado interno es causado por la forget-gate (f_t). Esta puerta decide si el valor presente en el estado de la celda debe ser olvidado o no [25]. Esta decisión se toma aplicando la función sigmoide sobre la entrada y el estado oculto de la celda anterior, y multiplicando el resultado por el estado interno proveniente de la celda anterior. Dado que esta función toma valores entre 0 y 1, puede dar como resultado 0, lo que significa que se debe olvidar, o dar como resultado 1, lo que indica que el valor anterior debe ser completamente recordado.

$$f(t) = \sigma(b_f + U_f x(t) + W_f h(t-1))$$

2.6.14. Modelo de Regresión Lineal

La siguiente figura 2.11 ilustra el concepto de regresión lineal. Dada una variable predictora x y una variable de respuesta y , aplicamos una línea fina a este dato, que minimiza la distancia normalmente, la distancia cuadrada de promedio entre los puntos de muestra y la línea aplicada. Ahora podemos utilizar la intersección y la pendiente aprendidas de este dato para predecir la variable de resultado del nuevo dato [19]:




Figura 2.11: Regresión lineal

El modelo de regresión lineal es un método estadístico utilizado para modelar la relación entre una variable dependiente (la variable que queremos

predecir) y una o más variables independientes (las variables que se utilizan para predecir la variable dependiente). El objetivo es encontrar una relación lineal que mejor se ajuste a los datos observados [30].

2.6.15. Los pesos sinápticos

A una neurona artificial se le asigna un peso sináptico a las entradas que provienen desde otras neuronas. Este procedimiento es similar al que se realiza en una neurona de un ser humano, a lo que normalmente en la medicina se le conoce como sinapsis. El peso sináptico entonces es un valor numérico y que puede ir cambiando durante la fase de entrenamiento [31]. Este peso hace que la red neural tenga una utilidad y es allí donde se almacena la información.

En una red de neuronas existe un peso o fuerza sináptica que va a ser un valor numérico que pondera las señales que se reciben por sus entradas. Este peso será un valor que determina la fuerza de conexión entre 2 neuronas. Cuando se evalúa una neurona se debe calcular el conjunto de todas las fuerzas o valores (denominado NET) que se reciben por sus entradas. Una vez calculado el valor conjunto de todas las entradas se aplica una función de activación (FA) que determinará el valor del estado interno de la neurona y que será lo que se transmita a su salida [32].

2.7. Métricas para la evaluación de una red neuronal

2.7.1. El error medio cuadrático (MSE)

El MSE es una medida del error cuadrático medio que se utiliza comúnmente para evaluar la precisión de un modelo de predicción [30]. Se define como la media de los errores cuadrados entre los valores observados y los valores predichos por el modelo. Esta métrica calcula el valor promedio de los errores elevados al cuadrado [33].

La expresión matemática es la siguiente:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Donde:

- n : número de observaciones.

- y_i : valor observado de la i-ésima observación.
- \hat{y}_i : valor predicho por el modelo para la i-ésima observación.

2.7.2. Raíz del error medio cuadrático (RMSE)

El RMSE (Error Cuadrático Medio de la Raíz) es una medida utilizada para evaluar la precisión de un modelo de predicción. Representa la raíz cuadrada de la media de los errores cuadrados entre los valores observados y los valores predichos por el modelo. Cuanto menor sea el valor de RMSE, mejor será el ajuste del modelo a los datos [30]. RMSE es una medida absoluta de ajuste y se interpreta como la desviación estándar de la varianza inexplicada. Es especialmente útil cuando se busca evaluar la precisión de la predicción en el contexto de un modelo.

La expresión matemática es la siguiente:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Donde:

- $RMSE$ es el Error Cuadrático Medio de la Raíz.
- n es el número de observaciones.
- y_i es el valor observado de la i-ésima observación.
- \hat{y}_i es el valor predicho por el modelo para la i-ésima observación.
- $\sqrt{}$ es la función que calcula la raíz cuadrada.
- \sum es la función que suma los términos.

2.7.3. Error Absoluto Medio (MAE)

Es una medida que calcula la diferencia promedio absoluta entre los valores pronosticados y los valores reales en un pronóstico [33]. El MAE es útil para evaluar cuán cerca están los pronósticos de los valores reales. Su fórmula es la siguiente:

$$MAE = \frac{SAE}{N} = \frac{\sum_{i=1}^N |y_i - \hat{y}_i|}{N}$$

Donde:

- MAE es el Error Absoluto Medio.
- N es el número de puntos de datos no faltantes.
- y_i corresponde a la información actual de la serie de tiempo.
- \hat{y}_i corresponde a la serie de tiempo pronosticada.
- \sum es la función que realiza la suma.
- SAE Corresponde a la sumatoria de errores absolutos o desviaciones
- $||$ representa el valor absoluto.

2.7.4. Error porcentual absoluto medio (MAPE)

Permite calcular la dimensión del error de tipo absoluto expresado en porcentajes, y su fórmula es la siguiente [33]:

$$MAPE = \frac{1}{N} \sum_{t=1}^N \frac{|X_t - Y_t|}{|X_t|}$$

Donde:

- X_t : Valor real.
- Y_t : Valor de pronóstico.
- N : Número de puntos de datos no faltantes.

2.7.5. El coeficiente de determinación R^2

Es una medida que resume la capacidad explicativa de un modelo de regresión. Describe la proporción de la varianza en la variable dependiente que puede ser explicada por el modelo de regresión [33]. Su fórmula es:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

De lo cual:

- SST : Corresponde a la Suma de Cuadrados Total.
- SSR : Corresponde a la Suma de Cuadrados de Regresión.
- SSE : Corresponde a la Suma de Cuadrados de Error.

2.8. Antecedentes

En el proyecto titulado ***“Desarrollo de un Sistema de Control de Inventario para la Gestión de Compras de Materia Prima en el Rubro de Restaurantes”*** [34].

Este antecedente presenta un estudio de caso relevante en el ámbito de la gestión de inventario y compras en la industria de restaurantes. Se describe cómo se implementó con éxito un sistema de control de inventario utilizando el modelo de desarrollo de ciclo de vida en cascada. El objetivo principal de esta implementación fue mejorar la gestión de los procesos de almacén y reducir los tiempos innecesarios en la entrega de productos a los clientes. El sistema se dividió en módulos específicos, centrándose en el almacén y ofreciendo diversas funcionalidades para la gestión eficiente del restaurante. Los resultados obtenidos demuestran una modernización efectiva de los procesos de la empresa en el rubro de restaurantes, con mejoras significativas en la gestión y una reducción sustancial de los tiempos de almacenamiento. Este antecedente sirve como base para la presente tesis, que se enfoca en el desarrollo de un sistema de compra inteligente basado en el historial de ventas, aprovechando la experiencia exitosa de la implementación previa para impulsar la eficiencia operativa en la industria de alimentos

En el trabajo titulado ***“Optimización de la cadena de abastecimiento a través de un sistema inteligente de pronósticos de demanda y gestión de inventario multiproducto”*** [35].

El objetivo principal del proyecto fue desarrollar una aplicación web que automatizara parcialmente las actividades del área de compras y mejorara la cadena de abastecimiento mediante un sistema inteligente de pronósticos de demanda y gestión de inventario multiproducto. Este antecedente se presenta como una sólida prueba de concepto para la implementación de sistemas inteligentes de gestión de compras basados en pronósticos de demanda en la industria gastronómica, lo que respalda y valida la relevancia de la presente tesis sobre un sistema de compra inteligente basado en historial de ventas.

En el artículo titulado ***“Plan de gestión para la creación de una plataforma tecnológica en un establecimiento gastronómico”*** [36]. Los autores proponen la implementación de una plataforma tecnológica en un restaurante, combinando metodologías de gestión tradicionales y ágiles. El objetivo es mejorar la eficiencia y eficacia en las tareas de atención, supervisión, control y administración del establecimiento gastronómico. La metodología SCRUM se utilizará para la gestión del desarrollo, utilizando las estimaciones previas como métricas de evolución para identificar posibles re-

trasos e inconvenientes. El plan de proyecto estima los alcances, costos y duración de las tareas de desarrollo, definiendo planes de gestión de calidad y mitigación de riesgos. La combinación de metodologías utilizada busca generar una solución eficiente para la administración del desarrollo de la plataforma tecnológica.

El artículo ***“Reducing Food Waste in the Food Industry with Deep Learning”*** [37].

El autor, Esteban David Romero Pérez, se centra en la importante tarea de ayudar a la industria alimentaria a anticipar con precisión la demanda de sus productos y, por lo tanto, reducir los excedentes no vendidos, lo que está alineado con el Objetivo de Desarrollo Sostenible número 12 de las Naciones Unidas. Los resultados obtenidos en este estudio demuestran de manera convincente que la aplicación de Deep Learning puede conducir a una disminución sustancial en la cantidad de alimentos desperdiciados en la industria alimentaria, contribuyendo significativamente a un futuro más sostenible y eficiente en el uso de recursos. Este antecedente resalta la relevancia de la tecnología de aprendizaje profundo en la optimización de procesos en la industria alimentaria, lo que puede ser de gran utilidad para el enfoque de la presente tesis.

En un estudio llevado a cabo en Móstoles, España titulado ***“Un análisis de sentimiento en Twitter con Machine Learning: Identificando el sentimiento sobre las ofertas de #BlackFriday”*** [38]. Se estableció una conexión con la API de Twitter para recopilar un total de 2204 tweets relacionados con los comentarios e interacciones de los usuarios acerca de las ofertas proporcionadas por empresas en la muestra. Posteriormente, se aplicó un algoritmo de análisis de sentimiento desarrollado en Python utilizando la biblioteca MonkeyLearn para categorizar estos tweets en positivos y negativos. Se centró en evaluar la percepción de los usuarios sobre las ofertas del Black Friday a través del análisis automatizado de los comentarios en Twitter.

Tesis ***“Predicción de la demanda usando modelos de machine Learning”*** [39] Para aquellas empresas dedicadas a la venta en retail o venta directa donde su portafolio de productos es muy amplio, la planeación de la demanda se convierte en un área determinante para la correcta administración del flujo de caja, rentabilidad y efectividad en ventas por varias razones: la primera de ellas es la gestión de compra de insumos por medio de negociación de precio por volumen con sus proveedores; el control de inventario donde se cuida un equilibrio entre uso efectivo del espacio de almacenamiento

y reducción de obsolescencia contra la disponibilidad para distribución y por último en la venta efectiva respetando las estacionalidades, tendencias del mercado y satisfacción del cliente.

Trabajo final de grado titulado ***“Estudios de predicción en series temporales de datos meteorológicos utilizando redes neuronales recurrentes”*** [26] En los últimos años, en el campo de las energías renovables, la energía eólica ha sido una de las que mas se ha desarrollado e invertido. La importancia de las predicciones de viento radica en la ayuda que aportan para planificar y anticiparse a los valores futuros que afectarán al sistema, ayudando a gestionar la adquisición de los recursos necesarios con antelación suficiente. Recientemente se han desarrollado nuevas arquitecturas de redes recurrentes que resultan muy prometedoras para realizar predicción. En este trabajo se probará y experimentará con dichas arquitecturas para realizar distintas predicciones de la velocidad del viento en un horizonte de corto y muy corto plazo a partir de datos de series temporales de viento.

Capítulo 3

Predicción de la demanda

En esta sección, se describirán los métodos utilizados para llevar a cabo la investigación sobre la predicción de compras a partir de un historial de ventas.

3.1. Preprocesamiento de datos

Los datos usados para generar el modelo fueron proporcionados por la empresa gastronómica. La misma proporcionó el dataset para ser usado con fines académicos, los datos presentan las ventas diarias para los diferentes productos cuenta con 6 meses de registro desde el 17 de abril del 2023 hasta el 15 de octubre del 2023.

Los datos originales suministrados están conformados por los siguientes datasets:

- productos.csv
- ventas.csv

Los datos vienen organizados en forma tabular, cada archivo presenta información separada relacionada con los diferentes productos y el registro de ventas histórico.

productos.csv

Estructura inicial de la tabla de productos (información de los 5 primeros productos(Fig. 3.3)).

Método

id	codigo	id_categoria	producto	marca	descripcion	precio_costo	precio_minorista
1	992856	1	Simple	1		0	14000
2	815013	1	Hamburguesa doble	1		0	22000
3	560531	1	Simple	1		0	18000
4	446168	2	Hamburguesa doble bacon	1		0	27000
5	864790	2	Papa pequeña	1		0	10000

Figura 3.1: Estructura inicial de la tabla productos.csv

ventas.csv

Estructura inicial de la tabla de ventas(con información de 6 registros (Fig. 3.2)).

id	id_presupuesto	id_cliente	id_vendedor	id_producto	observacion	precio_venta	cantidad	fecha_presupuesto
2	2	0	37	69	NULL	28000	1	2023-04-17 18:38:00
3	2	0	37	59	NULL	22000	2	2023-04-17 18:38:00
4	2	0	37	54	NULL	17000	1	2023-04-17 18:38:00
5	3	0	37	91	NULL	13000	1	2023-04-17 18:43:00
6	3	0	37	95	NULL	17000	1	2023-04-17 18:43:00
7	3	0	37	94	NULL	11000	1	2023-04-17 18:43:00

Figura 3.2: Estructura inicial de la tabla ventas.csv

3.1.1. Modelado de datos

En el siguiente apartado se estara realizando el proceso de limpieza de los datos para la opción de los parametros a utilizar.

Se obtuvieron las columnas necesarias de la tabla productos para el desarrollo del proyecto, desde la base de datos MySQL herramienta utilizada para el almacenamiento de los datos, mediante la ejecución de los siguientes SQL query:

La siguiente consulta SQL selecciona las columnas `id` y `producto` de la tabla `productos`, donde la columna `anulado` tiene un valor nulo (NULL)(Figura:3.3):

```
SELECT id, producto
FROM productos
WHERE anulado IS NULL;
```

id	producto
1	Hamburguesa Simple
2	Hamburguesa doble
3	Hamburguesa triple
4	Hamburguesa doble bacon
5	Papa pequeña

Figura 3.3: Datos de la tabla productos(Los primeros 5 productos)

En la tabla 3.1 se muestra una descripción de cada una de las columnas de productos.

Columna	Descripción
id	el id del producto (identificador unico)
producto	el nombre del producto

Tabla 3.1: Descripción de datos de la tabla de productos

La consulta SQL a continuación selecciona las columnas `id_producto`, `cantidad`, y `fecha_venta` de la tabla `ventas` para las transacciones que tuvieron lugar en el período desde el 17 de abril de 2023 hasta el 15 de octubre de 2023 donde la columna `anulado` tiene un valor nulo (NULL)(Figura:3.4):

```
SELECT id_producto, cantidad, fecha_venta
FROM ventas
WHERE fecha_venta BETWEEN '2023-04-17' AND '2023-10-15' AND anulado IS NUL;
```

id_producto	cantidad	fecha_venta
45	12	2023-04-17 17:58:00
37	1	2023-04-17 17:58:00
13	1	2023-04-17 17:58:00
36	1	2023-04-17 17:58:00
26	1	2023-04-17 17:58:00
9	1	2023-04-17 17:58:00
66	1	2023-04-17 17:59:00

Figura 3.4: Datos de la tabla ventas

En la tabla 3.2 se muestra una descripción de cada una de las columnas de productos.

Columna	Descripción
id_producto	el id del producto (identificador unico)
catidad	cantidad de venta
fecha_venta	fecha de la venta

Tabla 3.2: Descripción de datos de la tabla ventas

3.1.2. Escalado de datos

El escalado de datos es un proceso esencial en el análisis de datos y la estadística que ajusta los valores de las variables para que compartan una misma escala o propiedades específicas.

La consulta SQL se enfoca en el escalado de datos de ventas de productos durante un periodo del 17 de abril al 15 de octubre, excluyendo ventas anuladas. La consulta agrupa los resultados por producto y fecha de venta, permitiendo así obtener una visión escalada de la cantidad total vendida de cada producto a lo largo del tiempo, lo que facilita la identificación de tendencias y patrones en las ventas.

```
SELECT id_producto, SUM(cantidad) AS Cantidad, fecha_venta
FROM ventas
WHERE fecha_venta BETWEEN '2023-04-17' AND '2023-10-15'
AND anulado IS NULL
GROUP BY id_producto, fecha_venta;
```

id_producto	Cantidad	fecha_venta
49	13	2023-04-17
54	13	2023-04-17
59	3	2023-04-17
69	4	2023-04-17
75	1	2023-04-17
87	3	2023-04-17
91	1	2023-04-17
92	2	2023-04-17
93	5	2023-04-17

Figura 3.5: Datos escalados(muestra de la tabla ventas)

Columna	Descripción
id_producto	el id del producto
cantidad	suma de la cantidad de ventas por fecha y producto
fecha_venta	fecha de la venta

Tabla 3.3: Descripción de datos escalados de la tabla ventas

3.1.3. Análisis de los datos

El objetivo principal de esta etapa es explorar y comprender en profundidad los datos, lo que resulta fundamental para una sólida preparación y análisis de los mismos. Esta comprensión más profunda del problema de negocio nos permitirá seleccionar modelos de predicción y tomar decisiones más fundamentadas. Durante el proceso de limpieza y preparación de los datos, se han identificado características relevantes que proporcionarán información valiosa para las fases posteriores del análisis y la toma de decisiones.

Como se observa(Figura: 3.4), la base de datos de entrenamiento es limitada en términos de variables disponibles. En este escenario, se ha seleccionado exclusivamente la fecha como variable de entrada y se ha focalizado en un producto específico, en este caso, la “Hamburguesa simple” con id_producto 49, debido a su alta demanda. Se han recopilado 182 registros ya agrupados por día, lo que equivale a 182 días de datos. El propósito de este enfoque es analizar el comportamiento de las ventas de dicho producto en relación

al tiempo y buscar patrones que puedan mejorar la precisión del modelo de predicción.




Figura 3.6: Serie temporal de las ventas totales por día

3.1.4. Definición de las variables de entrada y salida

Se han considerado estas variables como variables de entrada debido a que, a través del análisis de la serie temporal de ventas, se han identificado patrones y tendencias significativas que impactan en las ventas del producto. El mes, el día del mes, el día de la semana, la presencia de días festivos y la estación del año influyen directamente en el comportamiento de las ventas. El promedio de venta mensual varía, lo que indica una estacionalidad en la demanda. Las ventas tienden a aumentar hacia el final e inicio del mes, posiblemente relacionado con el ciclo de pagos de los consumidores. La influencia de los días de la semana sugiere que los fines de semana son momentos clave para las ventas. La presencia de días festivos genera picos en las ventas, lo que puede estar vinculado a la celebración y al aumento de la demanda en esas fechas. Por último, la estación del año también desencadena cambios en las ventas, con un aumento en verano, lo que respalda la necesidad de considerar esta variable en el modelo para una predicción más precisa. Teniendo

todas estas informaciones, se procede a la conversión de estas características en variables de entrada y salida para el aprendizaje del modelo, y se asegura de que estén representadas en formato numérico.

Columna	Descripción	Dato numerico
mes	variable mes Rango	1-12
dia	variable dias del mes Rango	1-31
dia_semana	variable dia de la semana Rango	0-6
dia_festivo	variable dia festivo Rango	0-1
estacion	variable estaciones del año Rango	0-3

Tabla 3.4: Variables de entrada

La siguiente consulta SQL realiza un análisis de ventas de un producto con id_producto igual a 49. Agrupa los datos por fecha de venta y calcula diversas métricas relacionadas con la fecha, como el mes, el día, el día de la semana y si la fecha es un día festivo. También determina la estación correspondiente a cada fecha y agrega información sobre la cantidad total de ventas y la suma de las cantidades vendidas para cada día. En resumen, esta consulta proporciona un resumen detallado de las ventas del producto 49, organizado por fecha y con métricas relacionadas con la fecha para su posterior utilización.

```
SELECT MONTH(fecha_venta) AS mes,
DAY(fecha_venta) AS dia,
DAYOFWEEK(fecha_venta) AS dia_semana,
IFNULL((SELECT 1 FROM dias_festivos df
WHERE CAST(v.fecha_venta AS date) = df.fecha),0) AS dia_festivo,
(SELECT estacion FROM estaciones e
WHERE cast(v.fecha_venta AS date)
BETWEEN e.fecha_inicio AND e.fecha_fin) AS estacion,
COUNT(id_venta) AS cantidad_ventas,
SUM(v.cantidad) AS cantidad
FROM ventas v
WHERE id_producto = 49
GROUP BY CAST(fecha_venta AS date)
```

Tabla (3.7)resultante en formato .csv con el exportador de MySQL

mes	dia	dia_semana	dia_festivo	estacion	cantidad
4	17	2	0	2	13
4	18	3	0	2	25
4	19	4	0	2	15
4	20	5	0	2	45
4	21	6	0	2	34
4	22	7	0	2	63
4	23	1	0	2	44

Figura 3.7: Tabla resultante con las variables de entrada

3.1.5. Lectura y escalado del dataset en Python

En este trabajo se realiza todo el proceso en el software Python.

La elección de Python como lenguaje de programación se fundamenta en su destacado uso en el campo de la inteligencia artificial, respaldado por una amplia gama de bibliotecas y una comunidad activa [19]. En cuanto al entorno de pruebas, se ha optado por Google Colab debido a su facilidad de uso y su gratuidad, lo que lo convierte en una opción conveniente para el desarrollo y la prueba de modelos de inteligencia artificial.

Los datos se preparan de manera similar tanto para las pruebas de regresión lineal como para las de LSTM, lo que implica el proceso de escalado y la división en variables de entrada y salida. En Python, se emplea la biblioteca pandas para la lectura de archivos CSV, y para el escalado, se recurre al MinMaxScaler de la librería sklearn (Figura: 3.8).


```
import numpy as np
import pandas as pd
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_squared_error, mean_absolute_error
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
import matplotlib.pyplot as plt
import tensorflow as tf
from tensorflow import keras
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense

# Cargar el conjunto de datos
data = pd.read_csv('dataset12.csv')

# Elegir las características y el objetivo
features = ['mes', 'dia', 'dia_semana', 'dia_festivo', 'estacion', 'cantidad']
target = 'cantidad'

X = data[features].values
Y = data[target].values

# Normalizar los datos
scaler_X = MinMaxScaler()
scaler_Y = MinMaxScaler()

X_scaled = scaler_X.fit_transform(X)
Y_scaled = scaler_Y.fit_transform(Y.reshape(-1, 1))
```

Figura 3.8: Lectura y escalado del dataset en Python

En el grafico 3.9 se puede observar que todas las variables de entrada estan escaladas entre 0 y 1 incluyendo el set train, validación y test.




Figura 3.9: Grafico en violín incluyendo los tres set train, validación y test

En el gráfico 3.10 se puede observar que los datos de salida también estén escalados correctamente.




Figura 3.10: Gráfico en violín de los datos de salida escaladas

3.1.6. Distribución del conjunto de datos

En el proceso de entrenamiento, es fundamental dividir el conjunto de datos en tres conjuntos distintos:

- **Conjunto de Entrenamiento (Train):** Este conjunto se utiliza para entrenar el modelo, lo que significa que el modelo aprenderá de estos datos durante el proceso de entrenamiento.
- **Conjunto de Validación (Val):** El conjunto de validación se emplea para evaluar si el modelo está sobreajustando los datos de entrenamiento. Ayuda a ajustar parámetros y prevenir el sobreajuste.
- **Conjunto de Prueba (Test):** Este conjunto no se utiliza durante el entrenamiento del modelo y contiene datos con valores desconocidos. Se utiliza al final para evaluar la precisión del modelo en un entorno real, ya que no ha tenido acceso a estos datos previamente.

Se toma inicialmente 70 % train, 15 % val y 15 % test, como valores comúnmente utilizados para estos casos.

Método

```
# Dividir los datos en conjuntos de entrenamiento, validación y prueba
train_size = int(0.7 * len(X_seq))
val_size = int(0.15 * len(X_seq))
test_size = len(X_seq) - train_size - val_size

X_train, X_val, X_test = X_seq[:train_size], X_seq[train_size:train_size + val_size], X_seq[train_size + val_size:]
Y_train, Y_val, Y_test = Y_seq[:train_size], Y_seq[train_size:train_size + val_size], Y_seq[train_size + val_size:]

print('Tamaños entrada (BATCHES x INPUT_LENGTH x FEATURES) y de salida (BATCHES x OUTPUT_LENGTH x FEATURES)')
print(f'Set de entrenamiento - x_tr: {X_train.shape}, y_tr: {Y_train.shape}')
print(f'Set de validación - x_vl: {X_val.shape}, y_vl: {Y_val.shape}')
print(f'Set de prueba - x_ts: {X_test.shape}, y_ts: {Y_test.shape}')

Tamaños entrada (BATCHES x INPUT_LENGTH x FEATURES) y de salida (BATCHES x OUTPUT_LENGTH x FEATURES)
Set de entrenamiento - x_tr: (107, 23, 6), y_tr: (107, 7, 1)
Set de validación - x_vl: (22, 23, 6), y_vl: (22, 7, 1)
Set de prueba - x_ts: (24, 23, 6), y_ts: (24, 7, 1)
```

Figura 3.11: Algoritmo de distribución de los datos.




Figura 3.12: Distribución de los datos, ventas totales por día.

3.2. Aplicación y comparación de técnicas ML

3.2.1. Regresión lineal

Para la implementación de regresión lineal, se ha optado por utilizar el SGDRegressor de la biblioteca sklearn. En lo que respecta a la elección de hiperparámetros, se han seleccionado valores comunes para un modelo de regresión lineal implementado a través del algoritmo de Descenso de Gradiente Estocástico (SGD). Estos hiperparámetros son los siguientes:

- `loss=\squaredro _loss"`: Se ha elegido la función de pérdida de error cuadrático medio (MSE) debido a la naturaleza de un problema de

regresión. La función MSE evalúa la discrepancia al cuadrado entre las predicciones y los valores reales, y se minimiza durante el proceso de entrenamiento.

- `penalty='l2'`: Se ha especificado la regularización Ridge, que es una técnica comúnmente utilizada para abordar problemas de regresión. La regularización Ridge ayuda a prevenir el sobreajuste incorporando un término de penalización en la función de pérdida.
- `alpha=0.0001`: El hiperparámetro de regularización controla la intensidad de la regularización. En este caso, se ha optado por un valor pequeño (0.0001) para evitar una regularización excesiva y permitir que el modelo se ajuste de manera adecuada a los datos.
- `max_iter=1000`: Se ha establecido el número máximo de iteraciones permitidas para el descenso de gradiente en 1000, un valor suficientemente amplio para asegurar la convergencia del modelo.
- `tol=1e-3`: La tolerancia se utiliza para determinar cuándo se ha alcanzado la convergencia. Si el cambio en la pérdida entre iteraciones sucesivas es menor que $1e-3$, el algoritmo se detendrá. Este valor de tolerancia es apropiado para garantizar una convergencia razonable.
- `learning_rate='constant'`: Se ha configurado la tasa de aprendizaje como constante a lo largo del proceso de entrenamiento.

```
# Crea el modelo de regresión lineal con SGD
model = SGDRegressor(
    loss="squared_error",
    penalty="l2", # Regularización Ridge
    alpha=0.0001, # Hiperparámetro de regularización
    max_iter=1000, # Número máximo de iteraciones
    tol=1e-3, # Tolerancia para la convergencia
    learning_rate="constant",
    eta=0.01 # Tasa de aprendizaje inicial
)
model.fit(X_train, Y_train)

# Realizar predicciones en el conjunto de prueba
Y_train_pred = model.predict(X_train)
Y_train_pred = Y_train_pred.ravel()
Y_val_pred = model.predict(X_val)
Y_val_pred = Y_val_pred.ravel()
Y_test_pred = model.predict(X_test)
Y_test_pred = Y_test_pred.ravel()
```

Figura 3.13: Algoritmo de la estructura de regresión lineal.

A pesar de que tanto el Error Cuadrático Medio (MSE) como el Error Absoluto Medio (MAE) proporcionan indicadores favorables, el valor de R-cuadrado (R^2) indica que el modelo se encuentra notablemente alejado de la excelencia representada por un valor de 1, ya que $R^2 = 1$ constituye la condición ideal (Figura 3.10) .

```
MSE en conjunto de validación: 0.05
MSE en conjunto de prueba: 0.03
MAE en conjunto de validación: 0.17
MAE en conjunto de prueba: 0.16
R^2 en conjunto de validación: 0.03
R^2 en conjunto de prueba: -0.02
```

Figura 3.14: Métrica de error regresión lineal.




Figura 3.15: Grafico de predicción con regresión lineal.




Figura 3.16: Predicción de 7 días con regresión lineal.

3.2.2. LSTM

La red neuronal LSTM se modela con ayuda de la librería keras, es una librería de código abierto de redes neuronales, que se implementa sobre otros frameworks de aprendizaje automático como Tensorflow, CNTK o theano. Apareció en 2015 y fue creada por François Chollet. Tal y como se menciona en su documentación [?], Keras se guía por cuatro principios. Ser amigable para el usuario, modular, fácilmente extensible e implementada en python.

```
# Crear y compilar el modelo LSTM
model = Sequential()
model.add(LSTM(neuronas, activation=activacion, return_sequences=False,
               input_shape=(input_length, len(features))))
model.add(Dropout(0.3))
model.add(Dense(output_length, activation='linear'))
model.compile(optimizer=custom_RMS, loss='mean_squared_error')
```

Figura 3.17: Algoritmo de la estructura del LSTM.

Al configurar una red neuronal LSTM, es común considerar varios hiperparámetros clave (Codigo 3.19):

- **Unidades de LSTM:** Por lo general, se comienza con un número moderado de unidades en las capas LSTM, como 64 o 128. Aumentar el número de unidades puede ayudar a capturar patrones más complejos, aunque conlleva un mayor riesgo de sobreajuste. En este caso, se obtuvieron los mejores resultados con 64 neuronas.
- **Número de capas LSTM:** Para problemas más complejos, es posible agregar capas adicionales. Las arquitecturas con dos capas LSTM son comunes y funcionan bien en muchas aplicaciones. Sin embargo, en este caso, se determinó que una sola capa oculta era la mejor opción.
- **Función de Activación:** Para las capas LSTM, la función de activación predeterminada suele ser “tanh”. No obstante, se pueden explorar otras funciones como “relu” o “sigmoid” según las necesidades del problema. En este caso, se lograron buenos resultados utilizando “relu” en la capa oculta y “linear” en la salida.
- **Función de Pérdida:** En problemas de regresión, es común utilizar el “mean squared error” (MSE) como función de pérdida. No obstante, la elección puede variar según el problema en particular. En este caso, se optó por el MSE debido a su versatilidad en problemas de regresión.

- **Optimizador:** El “Adam” es un optimizador sólido y ampliamente utilizado en problemas de aprendizaje profundo. Aunque existen otras opciones como “RMSprop,” la elección depende en gran medida del contexto. En esta configuración, se prefirió “RMSprop” por su relevancia en predicciones de demanda.
- **Tasa de Aprendizaje:** La tasa de aprendizaje es un hiperparámetro crucial. Por lo general, se comienza con un valor bajo, como 0.001, y se ajusta según la convergencia del modelo. En este caso, una tasa de aprendizaje de 0.01 resultó óptima.
- **Dropout:** La técnica de dropout, aplicada en un porcentaje determinado de neuronas durante el entrenamiento, puede ayudar a prevenir el sobreajuste. Se recomienda iniciar con un valor del 20 % y ajustar según las necesidades del problema. Para esta configuración, un dropout del 20 % fue suficiente.




Figura 3.18: Grafico de predicción con LSTM.

Los tres valores muestran una proximidad aceptable, lo que indica que el modelo tiene una capacidad de generalización satisfactoria (Figura 3.19).

Comparativo desempeños:

RMS train: 0.020

RMS val: 0.039

RMS test: 0.026

Figura 3.19: Comparativo de desempeños LSTM.

En este trabajo para evaluar el rendimiento de una red neuronal LSTM se hace uso de la gráfica de pérdidas loss. Esta permite evaluar cómo es su evolución de los datos en un modelo. Según la literatura entre más grandes las pérdidas las predicciones van a estar alejadas del valor real. En la (Figura 3.20) se puede observar la evolución de pérdidas a través de las épocas, se evidencia dos señales que corresponden a entrenamiento y validación marcados con los colores azul y naranja respectivamente, se infiere que los valores decrecen con una alta tasa hasta la época 5 aproximadamente y luego no presentan cambios significativos. Las pérdidas son de 0.020 y 0.039 para entrenamiento y test respectivamente.

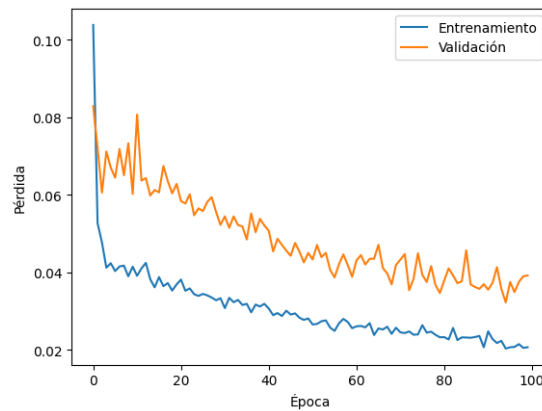


Figura 3.20: Grafico de perdida(loss) en las épocas LSTM .

Capítulo 4

Resultados

4.1. Metricas de rendimiento

4.1.1. Modelo de regresión lineal

4.1.2. Modelo LSTM

4.2. Informe de predicción de compras

Capítulo 5

Discusión

- 5.1. Logros alcanzados
- 5.2. Solución del problema de investigacin
- 5.3. Sugerencias para futuras investigaciones

Anexo A.

Los apéndices y anexos resultan útiles para describir con mayor profundidad ciertos materiales, sin distraer la lectura del texto principal del reporte o evitar que rompan con el formato de éste. Algunos ejemplos serían el cuestionario utilizado, un código de programa computacional, análisis estadísticos adicionales, la demostración matemática de un teorema complicado, fotografías testimoniales, etc.

Referencias bibliográficas

- [1] [En línea]. Disponible: <https://decidesoluciones.es/modelo-de-prediccion-de-demanda-aplicacion-y-beneficios/>
- [2] Raúl Pino Díez, Alberto Gómez Gómez, y Nicolás de Abajo Martínez, *Introducción a la inteligencia artificial: sistemas expertos, redes neuronales artificiales y computación evolutiva*. Universidad de Oviedo, 2001.
- [3] Raquel Flórez López y José Miguel Fernández Fernández, *Las redes neuronales artificiales*. Netbiblo, 2008.
- [4] Jimmy Alexander Romero Miranda, Víctor Alberto Lizcano Portilla *et al.*, “Predicción de ventas futuras,” 2021.
- [5] Ana Ortega Marqués, Sandy Patricia Padilla Domínguez, Johana Isabel Torres Durán, y Alexander Ruz Gómez, “Nivel de importancia del control interno de los inventarios dentro del marco conceptual de una empresa,” *Liderazgo estratégico*, vol. 7, no. 1, pp. 71–82, 2017.
- [6] Kenneth E Kendall y Julie E Kendall, *Análisis y diseño de sistemas*. Pearson educación, 2005, obtenido el 20 de mayo de 2023 de. [En línea]. Disponible: https://scholar.google.es/scholar?hl=es&as_sdt=0%2C5&q=K.+E.+Kendall+y+J.+E.+Kendall%2C+An%C2%B4alisis+y+dise%C2%B4on%2C+2005&btnG=
- [7] Xabier Basogain Olabe, “Redes neuronales artificiales y sus aplicaciones,” *Publicaciones de la Escuela de Ingenieros*, 1998.
- [8] César Pérez López y Daniel Santin González, *Minería de datos. Técnicas y herramientas: técnicas y herramientas*. Ediciones Paraninfo, SA, 2007.
- [9] Beatriz Beltrán Martínez, “Minería de datos,” *Cómo hallar una aguja en un pajar. Ingenierías*, vol. 14, no. 53, pp. 53–66, 2001.

- [10] Esteban Schab, Ramiro Rivera, Luciana Bracco, Facundo Coto, Patricia Cristaldo, Lautaro Ramos, Natalia Rapesta, Juan Pablo Núñez, Soledad Retamar, Carlos Casanova *et al.*, “Minería de datos y visualización de información,” in *XX Workshop de Investigadores en Ciencias de la Computación (WICC 2018, Universidad Nacional del Nordeste).*, 2018.
- [11] Alkis Simitsis y Panos Vassiliadis, “A method for the mapping of conceptual designs to logical blueprints for etl processes,” *Decision Support Systems*, vol. 45, no. 1, pp. 22–40, 2008, data Warehousing and OLAP. [En línea]. Disponible: <https://www.sciencedirect.com/science/article/pii/S0167923606002065>
- [12] Alexander Bustamante Martínez, Ernesto Amaru Galvis Lista, y Luis Carlos Gómez Flórez, “Técnicas de modelado de procesos de etl: una revisión de alternativas y su aplicación en un proyecto de desarrollo de una solución de bi,” *Scientia et technica*, vol. 18, no. 1, pp. 185–191, 2013.
- [13] Rodolfo H Villarroel, Yessica M Gómez, y Constanza B Krause, “Incorporación de seguridad en el modelado conceptual de procesos extracción-transformación-carga,” *Información tecnológica*, vol. 24, no. 6, pp. 101–110, 2013.
- [14] Batta Mahesh, “Machine learning algorithms-a review,” *International Journal of Science and Research (IJSR)*. [Internet], vol. 9, no. 1, pp. 381–386, 2020. [En línea]. Disponible: https://scholar.google.es/scholar?hl=es&as_sdt=0%2C5&q=+machine+learning&btnG=
- [15] Dennys Fabian Herrera Cofre *et al.*, “Predicción para el mercado de acciones con redes neuronales lstm,” 2020.
- [16] I.B.M. Staff(es). (2017) Machine learning. [En línea]. Disponible: <https://www.ibm.com/mx-es/analytics/machine-learning>
- [17] Ian Goodfellow, Yoshua Bengio, y Aaron Courville, *Deep learning*. MIT press, 2016.
- [18] Carlos Arana, “Redes neuronales recurrentes: Análisis de los modelos especializados en datos secuenciales,” Serie Documentos de Trabajo, Tech. Rep., 2021.
- [19] Vahid Mirjalili y Sebastian Raschka, *Python machine learning*. Marcombo, 2020.

- [20] E De la Rosa Montero, “El aprendizaje profundo para la identificación de sistemas no lineales,” *Centro de Investigación y de estudios avanzados del Instituto Politécnico nacional*, 2014.
- [21] Xavier Basogain, “Redes neuronales artificiales y sus aplicaciones,” *Dpto. Ingeniería de Sistemas y Automática, Escuela Superior de Ingeniería Bilbao. Open Course Ware.*[En línea] disponible en http://ocw.ehu.es/enseñanzas-tecnicas/redes-neuronales-artificiales-y-sus-aplicaciones/Course_listing. [Consultada 20-09-2012], 2008.
- [22] Nicolás Sánchez Anzola, “Máquinas de soporte vectorial y redes neuronales artificiales en la predicción del movimiento usd/cop spot intradiario.” *ODEON-Observatorio de Economía y Operaciones Numéricas*, no. 9, 2015.
- [23] Andres Nacelle y E Mizraji, “Redes neuronales artificiales,” *Núcleo de ingeniería biomédica–Universidad de la Republica Uruguay*, 2009.
- [24] Ian Goodfellow, Yoshua Bengio, y Aaron Courville, *Deep Learning*. MIT Press, 2016, <http://www.deeplearningbook.org>.
- [25] Javier Román Morales *et al.*, “Redes recurrentes para el análisis de series temporales,” B.S. thesis, 2018.
- [26] Besay Montesdeoca Santana, “Estudios de predicción en series temporales de datos meteorológicos utilizando redes neuronales recurrentes,” B.S. thesis, 2016.
- [27] Samuel Tomas, Oliver Saavedra, y Israel Espinoza, “Predicción del ciclo solar 25 mediante modelos arima y redes neuronales lstm,” *Revista de la Academia Colombiana de Ciencias Exactas, Físicas y Naturales*, 2023.
- [28] Juan José De Lucio Fernández, “Estimación adelantada del crecimiento regional mediante redes neuronales lstm,” *Investigaciones Regionales= Journal of Regional Research*, no. 49, pp. 45–64, 2021.
- [29] FABIO ALEJANDRO ESCOBAR GOMEZ y JOHAN YESID CORRAL MUESES, “Evaluación de redes neuronales recurrentes lstm en la predicción de fatiga muscular,” Ph.D. dissertation, AUNAR, 2022.
- [30] Carlos Andrés Sepúlveda Calle y Milton Tarsicio Benavides Posso, “Análisis predictivo de demanda de servicios bajo series temporales,” 2023.

- [31] Eder Acevedo, Alexei Serna, y Edgar Serna, “Principios y características de las redes neuronales artificiales,” *Desarrollo e innovación en ingeniería*, vol. 173, 2017.
- [32] M Gestal Pose, “Introducción a las redes de neuronas artificiales,” *Departamento de Tecnologías de la Información y las Comunicaciones. Universidad da Coruña*, 2009.
- [33] Haward Miguel Chang Hidalgo, “Comparación de técnicas de estimación basadas en machine learning para predecir costos en los planes de adquisiciones de las entidades públicas del Perú,” 2023.
- [34] Víctor Marcial Condorena Rondón, “Desarrollo de un sistema de control de inventario, para la gestión de compras de materia prima en el rubro de restaurantes,” 2017.
- [35] Nicole Pacheco Allende, “Rediseño del proceso de abastecimiento en el área de compras en dos empresas dedicadas al equipamiento gastronómico,” 2015.
- [36] Gabriel Vinicio Moreano Sánchez, Víctor Hugo Benítez Bravo, Wilmer Albarracín, y Álvaro Gabriel Benítez Bravo, “Sistemas inteligentes y colaborativos de administración global: Caso de estudio; establecimiento gastronómico,” *revistapuce*, 2018.
- [37] María Afanador Jiménez, Silvia Juliana Casadiegos Chaparro, Isabella Campo Maichel, Juan Sebastián Casallas Estrella *et al.*, “Diseño de un modelo de pronóstico de demanda basado en machine learning y un modelo multi-objetivo para planeación de la producción en una industria panificadora,” 2022.
- [38] Jose R SAURA, Ana Reyes-Menéndez, y Pedro PALOS-SANCHEZ, “Un análisis de sentimiento en twitter con machine learning: Identificando el sentimiento sobre las ofertas de# blackfriday,” *Revista Espacios*, vol. 39, no. 42, 2018.
- [39] Edwar Andrés Hincapié Herrera, “Predicción de la demanda usando modelos de machine learning,” 2021.