

Universidad Nacional del Este.  
Facultad Politécnica.

---



# Sistema de compra inteligente basado en el histórico de ventas.

Valeria Soledad Arevalos Arevalos  
y Marcelo Andrés González Arias

Año 2023.

Universidad Nacional del Este  
Facultad Politécnica

---

Carrera Ingeniería de Sistemas.  
Cátedra Trabajo Final de Grado II.

# Sistema de compra inteligente basado en el histórico de ventas.

Por: **Valeria Soledad Arevalos Arevalos**  
y **Marcelo Andrés González Arias**

Profesor Orientador: **Lic. Roberto Alfredo Demestri Rigoni.**

Trabajo final de grado presentado a la Facultad Politécnica de la Universidad Nacional del Este como parte de los requisitos para optar al título de Ingeniero de Sistemas.

Ciudad del Este, Alto Paraná. Paraguay.

Julio 2023

FICHA CATALOGÁFICA  
BIBLIOTECA DE LA FACULTAD POLITÉCNICA  
DE LA UNIVERSIDAD NACIONAL DEL ESTE

Arevalos Arevalos, Valeria Soledad 1998.  
Sistema de compra inteligente basado en el histórico de ventas  
González Arias, Marcelo Andrés 1996  
Ciudad del Este, Alto Paraná. Año: 2023.  
Páginas: <cantidad de páginas>.

Orientador: Lic. Roberto Alfredo Demestri Rigoni.  
Área de estudio: Tecnológica.  
Carrera: Ingeniería de Sistemas.  
Titulación: Ingeniero de Sistemas.  
Trabajo Final de Grado. Universidad Nacional del Este,  
Facultad Politécnica.

Descriptores: 1. Valeria Arevalos. 2. Marcelo González  
Smart purchasing system based on sales history.  
Key words: 1. \*, 2. \*  
3. \*.

Yo, <nombre del Profesor Orientador>, documento de identidad No. <No. de documento de identidad del Profesor Orientador>, Profesor Orientador del TFG titulado “<título del TFG>”, del Alumno <nombre del Alumno>, documento de identidad No. <No. de documento de identidad del Alumno>, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este; certifico que el mencionado Trabajo Final de Grado ha sido realizado por dicho Alumno, de lo cual doy fe y en mi opinión reúne las condiciones para su presentación y defensa ante la Mesa Examinadora designada por la institución.

<fecha>

---

<nombre del Profesor Orientador>

Nosotros, los miembros de la Mesa Examinadora del Trabajo Final de Grado titulado “<título del TFG>”, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este, hacemos constar que el citado trabajo ha sido evaluado en fondo y forma por esta Mesa, la que por \_\_\_\_\_ ha resuelto asignar la calificación \_\_\_\_\_

Ciudad del Este, \_\_\_\_ de \_\_\_\_\_ de \_\_\_\_

---

Profesor \_\_\_\_\_  
Presidente de la Mesa Examinadora

---

Profesor \_\_\_\_\_

Miembro de la Mesa Examinadora

---

Profesor \_\_\_\_\_

Miembro de la Mesa Examinadora

*Escribir aquí la dedicatoria.*  
*Su extensión no debería exceder de una página.*

*<Escribir aquí los agradecimientos.>*  
*<Su extensión no debería exceder de una página.>*

*<Escribir aquí el epígrafe (frase u oración favorita).>*  
*<Su extensión no debería exceder de una página.>*

# Resumen

Este trabajo propone el desarrollo de un sistema inteligente de compras para restaurantes, que se basa en un modelo matemático de predicción de la demanda de insumos. Este modelo utiliza técnicas estadísticas avanzadas y métodos de pronóstico para analizar patrones de consumo pasados y prever con precisión las cantidades de insumos necesarias en el futuro. Además, se incorpora una red neuronal entrenada para mejorar aún más las estimaciones de demanda, permitiendo así reducir el desperdicio de alimentos, optimizar los niveles de inventario y mejorar la eficiencia operativa del restaurante. La metodología de investigación involucra la recopilación y análisis de datos históricos de ventas y compras, así como la exploración de diversas técnicas de pronóstico y algoritmos de redes neuronales. Se llevarán a cabo experimentos para evaluar la eficacia del sistema en términos de reducción de costos y gestión de inventario.

En última instancia, esta tesis busca contribuir al desarrollo de un sistema de compras efectivo que permita a los restaurantes tomar decisiones informadas y oportunas en cuanto a la adquisición de insumos. La combinación de un modelo matemático de predicción de demanda con redes neuronales representa un enfoque innovador para abordar los desafíos de la gestión de inventario en la industria gastronómica, con el objetivo de mejorar la eficiencia y sostenibilidad operativa.

**Descriptores:** 1. Predicción de la demanda de insumos, 2. Modelo matemático, 3. Redes neuronales artificiales.



# Abstract

This work proposes the development of an intelligent purchasing system for restaurants, based on a mathematical demand prediction model. This model utilizes advanced statistical techniques and forecasting methods to analyze past consumption patterns and accurately forecast the quantities of inputs needed in the future. Additionally, a trained neural network is incorporated to further enhance demand estimations, thereby allowing for the reduction of food waste, optimization of inventory levels, and improvement in restaurant operational efficiency. The research methodology involves the collection and analysis of historical sales and purchasing data, as well as the exploration of various forecasting techniques and neural network algorithms. Experiments will be conducted to assess the system's effectiveness in terms of cost reduction, inventory management, and overall customer satisfaction.

Ultimately, this thesis aims to contribute to the development of an effective purchasing system that enables restaurants to make informed and timely decisions regarding input procurement. The combination of a mathematical demand prediction model with neural networks represents an innovative approach to addressing inventory management challenges in the gastronomy industry, with the goal of enhancing operational efficiency and sustainability.

**Key words:** 1. Input Demand Forecast , 2. Matematical Modelling, 3. Artificial Neural network.

# Índice general

<b>Resumen</b>	<b>IX</b>
<b>Abstract</b>	<b>X</b>
<b>Índice de figuras</b>	<b>XIII</b>
<b>Índice de tablas</b>	<b>XIV</b>
<b>Acrónimos y símbolos</b>	<b>XIV</b>
<b>1. Introducción</b>	<b>1</b>
1.1. Motivación . . . . .	2
1.2. Definición del problema . . . . .	2
1.3. Objetivos . . . . .	3
1.3.1. General . . . . .	3
1.3.2. Específico . . . . .	3
1.4. Hipótesis . . . . .	3
1.5. Fundamentación . . . . .	3
1.6. Impacto de la investigación . . . . .	4
1.7. Organización del trabajo. . . . .	4
<b>2. Conceptos fundamentales, teorías y antecedentes</b>	<b>5</b>
2.1. Predicciones de Compras . . . . .	5
2.1.1. Relación de Demanda y Gestión de Suministro . . . . .	5
2.1.2. Importancia de la Predicción de Compra de Insumos . . . . .	5
2.1.3. Factores que Influyen en la Curva de Insumos Deman- dados . . . . .	8
2.2. Tiempos Actuales en las Predicciones de Demanda . . . . .	8
2.3. Sistema de información . . . . .	9
2.4. Minería de datos . . . . .	12
2.5. Técnicas de modelado de procesos de ETL . . . . .	12
2.6. Inteligencia Artificial . . . . .	13

2.6.1.	El aprendizaje automático ( <i>machine learning</i> ) . . . . .	13
2.6.2.	Aprendizaje supervisado . . . . .	15
2.6.3.	Aprendizaje no supervisado . . . . .	16
2.6.4.	Redes Neuronales Artificiales . . . . .	17
2.6.5.	Capas de la neurona artificial . . . . .	19
2.6.6.	Modelo de redes neuronales artificiales . . . . .	20
2.6.7.	Arquitectura de una red neuronal . . . . .	20
2.6.8.	Redes neuronales recurrentes (RNN) . . . . .	21
2.6.9.	Arquitectura básica de una RNN . . . . .	22
2.6.10.	Redes de Memoria Corta y Larga LSTM . . . . .	23
2.6.11.	Modelo de Regresión Lineal . . . . .	23
2.6.12.	Los pesos sinápticos . . . . .	23
2.6.13.	Perceptron . . . . .	24
2.6.14.	Perceptrón multica . . . . .	25
2.7.	Series de Tiempo . . . . .	25
2.8.	Antecedentes . . . . .	25
<b>3.</b>	<b>Predicción de la demanda</b>	<b>29</b>
3.1.	Preprocesamiento de datos . . . . .	30
3.2.	Análisis de los datos . . . . .	30
3.3.	Definición de variables de entrada y salida . . . . .	30
3.4.	Lectura y escalado del dataset en Python . . . . .	30
3.5.	Distribución del conjunto de datos . . . . .	30
3.6.	Aplicación y comparación de técnicas ML . . . . .	30
3.6.1.	Regresión lineal . . . . .	30
3.6.2.	LSTM . . . . .	30
3.7.	Afinación de hiperparámetros con base en porcentaje de pérdida RMS . . . . .	30
<b>4.</b>	<b>Resultados</b>	<b>38</b>
4.1.	Métricas de rendimiento . . . . .	38
4.1.1.	Modelo de regresión lineal . . . . .	38
4.1.2.	Modelo LSTM . . . . .	38
4.2.	Informe de predicción de compras . . . . .	38
<b>5.</b>	<b>Discusión</b>	<b>42</b>
5.1.	Logros alcanzados . . . . .	42
5.2.	Solución del problema de investigación . . . . .	42
5.3.	Sugerencias para futuras investigaciones . . . . .	42
<b>Anexo A.</b>		<b>43</b>

<b>Glosario</b>	<b>43</b>
<b>Anexos</b>	<b>43</b>
<b>Referencias bibliográficas</b>	<b>44</b>

# Índice de figuras

2.1. Predicción de demanda a corto, mediano y largo plazo [1]. . .	6
2.2. Proceso de Optimización de inventario [1]. . . . .	7
2.3. Arquitectura de un sistema experto [2]. . . . .	12
2.4. flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo . . . . .	15
2.5. Aprendizaje supervisado [1]. . . . .	16
2.6. Componentes de una neurona. . . . .	18
2.7. Tipos de neuronas artificiales [3]. . . . .	19
2.8. La arquitectura básica de una RNN . . . . .	23
2.9. Aplicación de la Red Perceptron . . . . .	25
3.1. productos.csv(Los primeros 5 productos) . . . . .	31
3.2. ventas.csv(Los primeros 25 registros) . . . . .	32
3.3. Grafico en violín incluyendo los tres set train, validación y test	33
3.4. Gráfico en violín de los datos de salida escaladas . . . . .	34
3.5. Serie temporal de las ventas totales por día . . . . .	34
3.6. Distribución de los datos, ventas totales por día. . . . .	35
3.7. Diseño procedural. . . . .	36
4.1. Huella dactilar. . . . .	39
4.2. Ejemplificacin de diagrama en blanco y negro. . . . .	40

# Índice de Tablas

3.1. Descripción columnas productos.csv . . . . .	31
3.2. Descripción columnas ventas.csv . . . . .	33
4.1. Inventario de animales. . . . .	40
4.2. Clasificación de la muestra, por edad. . . . .	41
4.3. Imagen de tabla, en reemplazo de la tabla anterior. . . . .	41

# Capítulo 1

## Introducción

En el dinámico entorno de la industria gastronómica, la gestión eficiente de recursos se erige como una prioridad estratégica para alcanzar el éxito operativo y financiero. Entre estos recursos, los insumos desempeñan un papel fundamental, y su manejo adecuado no solo impacta la calidad y la consistencia de los platillos ofrecidos, sino también la rentabilidad y sostenibilidad del negocio en su conjunto. En este contexto, emerge la necesidad de desarrollar soluciones innovadoras y tecnológicas que permitan anticipar y ajustar la demanda de insumos de manera inteligente y precisa.

La gestión de un restaurante, es la actividad de dirección coordinada, relacionada con la oferta y el servicio de alimentos y bebidas en empresas de restauración, cumpliendo los requisitos que exige dicha actividad, con el objetivo de satisfacer necesidades y expectativas de sus clientes.

En el contexto actual de competitividad, es común que las empresas de servicios busquen mejorar sus sistemas de gestión, y adopten métodos y principios gerenciales de empresas industriales para aumentar su productividad y calidad. Sin embargo, es importante tener en cuenta que cada tipo de empresa tiene sus particularidades y características únicas que deben ser consideradas para una gestión eficiente.

En el caso de las empresas de servicios de restauración, es esencial estudiar y analizar las características de su actividad, y las particularidades del servicio que ofrecen, para poder aplicar los métodos y principios gerenciales de manera efectiva. Esto permitirá una gestión óptima de la entidad, mejorando los resultados económicos y asegurando la permanencia del negocio.

Entre las particularidades de la actividad de restauración, se pueden mencionar la importancia de la atención al cliente, la gestión de la calidad de los alimentos y bebidas, el manejo adecuado de los costos y la gestión de inventarios, entre otros aspectos. Estas características deben ser consideradas al momento de aplicar métodos de mejora de la productividad y calidad, y

adaptarlos a las necesidades específicas de la empresa de servicios de restauración.

Es cierto que las empresas de restauración constituyen un sistema operativo empresarial que se compone de varios subsistemas interrelacionados que trabajan juntos para lograr los objetivos empresariales. Uno de estos subsistemas es el de compras, que es fundamental para garantizar la eficacia del sistema de aprovisionamiento y, por tanto, para la planificación, producción y servicio.

El subsistema de compras tiene la responsabilidad de satisfacer las necesidades del subsistema de aprovisionamiento, asegurándose de que los abastecedores con los que se firma convenios cumplan con las especificaciones de calidad establecidas por la empresa de restauración. Además, es importante que el subsistema de compras garantice el abastecimiento de los productos necesarios y de alta calidad para la empresa de restauración.

Mediante los sistemas computacionales se logran procesar cada vez más cantidad de información, y realizar cálculos y operaciones, complejas por lo que realizar predicciones con estos sistemas resultan más confiables. Esta precisión puede ser mejorada ampliamente utilizando varias técnicas de predicción.

### 1.1. Motivación

Mediante la aplicación de técnicas avanzadas de análisis de datos y aprendizaje automático, este sistema proporcionará recomendaciones precisas y estratégicas, contribuyendo así al avance de la inteligencia empresarial y ofreciendo una herramienta eficiente para la toma de decisiones informadas y fundamentadas. El objetivo final es mejorar la eficiencia operativa, reducir costos y alcanzar ventajas competitivas, permitiendo a las empresas adaptarse y prosperar en un entorno comercial dinámico y desafiante.

### 1.2. Definición del problema

Este sistema debe ser capaz de utilizar el histórico de ventas del local para predecir la demanda futura de los productos, y en consecuencia, realizar las compras de manera más eficiente y rentable para la gerencia del local.

Problema de investigación: *Necesidad de optimizar la gestión de compras de materia prima de un local gastronómico en Ciudad del Este, utilizando sistema inteligente computarizado basado en el histórico de ventas.*



## **1.3. Objetivos**

### **1.3.1. General**

Desarrollar un sistema de compra inteligente basado en histórico de ventas para optimizar la gestión de compras de una empresa gastronómica de Ciudad del Este mediante algoritmos y técnicas de análisis de datos para predecir la demanda de productos en función del comportamiento de los clientes.

### **1.3.2. Específico**

1. Comprender en profundidad la lógica de negocio de la empresa gastronómica para identificar los procesos críticos que deben ser incluidos en el sistema informático a desarrollar.
2. Recabar los requisitos del sistema con los usuarios y partes interesadas.
3. Modelar la lógica del sistema informático, utilizando técnicas y herramientas adecuadas, para garantizar su integridad y eficiencia.
4. Codificar el modelo lógico definido en lenguajes de programación Python y PHP.
5. Depurar los datos cuantitativos recopilados sobre el comportamiento del consumidor.
6. Realizar pruebas de usabilidad, accesibilidad, multiplataforma, y escalabilidad.

## **1.4. Hipótesis**

La implementación de un sistema inteligente en un local gastronómico de Ciudad del Este, posibilitará una gestión de compras cuya eficiencia posibilitará reducir el costo de materia prima en al menos 10 % y predecir al menos con 70 % de acierto, la variedad y cantidad de productos a ser comprados.

## **1.5. Fundamentación**

En el entorno comercial actual, la toma de decisiones basada en información histórica puede ser un factor clave para el éxito de una empresa. Sin embargo, en muchos casos, esta información no se explota adecuadamente y la gestión de datos se convierte en una tarea compleja.

En el caso de una empresa gastronómica, es importante conocer el rendimiento en ventas y controlar los índices que reflejen el desempeño del negocio. Sin embargo, la simple gestión de estos índices no es suficiente, ya que la empresa puede planificar una determinada cantidad de ventas y adquirir una cantidad de materia prima en consecuencia, pero luego no lograr vender todo lo adquirido y mantener un exceso de stock, o incluso tener productos en inventario que no se rotan.

Es por eso que se plantea el desarrollo de una aplicación que permita proyectar las ventas, para tener un presupuesto real de compras que se adapte a la demanda del mercado y evite el exceso de stock o la falta de rotación de inventarios. De esta manera, la empresa podrá tomar decisiones informadas y maximizar su rendimiento.

### **1.6. Impacto de la investigación**

La implementación del sistema inteligente de compra basado en el histórico de ventas permitirá al gerente de la empresa tomar decisiones informadas y estratégicas, lo que se traducirá en un mejor desempeño económico y financiero de la empresa gastronómica.

Además, la investigación realizada para el desarrollo del sistema también tendrá un impacto positivo en otros estudiantes y futuros proyectos, ya que se podrán utilizar los conocimientos y experiencias adquiridos para mejorar otros procesos y aplicaciones en el ámbito empresarial y tecnológico. En consecuencia, la investigación tendrá un impacto significativo tanto en la empresa como en el ámbito académico y profesional.

### **1.7. Organización del trabajo.**

El presente trabajo está organizado de la siguiente manera:

Capítulo 2: Se presentan algunos conceptos relacionados con las predicciones de compras de insumos, cómo funciona la relación de demanda y gestión de suministro de un local gastronómico, por qué es importante la predicción de compra de insumos para el planeamiento futuro tanto a corto, mediano y largo plazo, los factores que influyen en el comportamiento de la curva de insumos demandados y tiempos actuales en las predicciones de demanda.

# Capítulo 2

## Conceptos fundamentales, teorías y antecedentes

### 2.1. Predicciones de Compras

La predicción es el proceso de anticipar la cantidad y tipo de insumos que un negocio gastronómico necesitará adquirir en el futuro, con el objetivo de asegurar un suministro adecuado y eficiente.

#### 2.1.1. Relación de Demanda y Gestión de Suministro

La relación de demanda y gestión de suministro se refiere a la interacción entre la cantidad de productos o insumos que los clientes requieren (demanda) y cómo la empresa se asegura de tener suficientes suministros disponibles para satisfacer esa demanda de manera eficiente. En un negocio gastronómico, la gestión de suministros es crucial para evitar situaciones en las que falten ingredientes clave, lo que podría afectar negativamente la calidad del servicio y la satisfacción del cliente.

#### 2.1.2. Importancia de la Predicción de Compra de Insumos

La mayoría de las empresas distribuidoras de productos sufren de manera recurrente al no conocer la cantidad o un aproximado de productos que debería mantener en stock ya que, por un lado, si el stock es demasiado grande se pueden producir pérdidas de mercancía y costos innecesarios de transporte y almacenamiento, por el contrario, si el stock es demasiado pequeño, este será insuficiente para cubrir la demanda de los diferentes productos y se verá

reflejado en la pérdida de clientes [4].

La aplicación de un modelo de predicción para planificar la demanda futura es un proceso circular de mejora continua. Eso significa que el modelo es enriquecido constantemente con datos en tiempo real para realizar predicciones más precisas y generar una planificación más acorde a la realidad [1].



Figura 2.1: Predicción de demanda a corto, mediano y largo plazo [1].

1. Utiliza la **Predicción de la demanda a largo plazo para la planificación estratégica**. Simula y compara diferentes escenarios hipotéticos de demanda, anticipa los cambios de mercado y planifica la contratación futura de recursos.
2. Utiliza la **Predicción de la demanda a corto plazo para la planificación operativa**. Planifica semanalmente las operaciones y recursos del día.
3. Utiliza la **Predicción de la demanda a medio plazo para la planificación táctica**. Conoce las capacidades con meses de antelación y compáralas con las actuales para detectar posibles necesidades.

La predicción de compra de insumos es vital para la planificación a corto, mediano y largo plazo en un negocio gastronómico por varias razones:

1. **Optimización de Inventario:** El inventario tiene como propósito fundamental proveer a la empresa de materiales necesarios, para su continuo y regular desenvolvimiento, es decir, el inventario tiene un papel

vital para el funcionamiento acorde y coherente dentro del proceso de producción y de esta forma afrontar la demanda [5].

Al prever la demanda futura, el negocio puede mantener un nivel de inventario óptimo. Comprar en exceso puede llevar al desperdicio de alimentos, mientras que comprar muy poco puede resultar en escasez y pérdida de ventas.



Figura 2.2: Proceso de Optimización de inventario [1].

2. **Reducción de Costos:** Una predicción precisa permite comprar solo lo necesario, lo que reduce los costos asociados con el almacenamiento y la conservación de productos perecederos.

Si se mantienen inventarios demasiado altos, el costo podría llevar a una empresa a tener problemas de liquidez financiera, esto ocurre porque un inventario “parado” inmoviliza recursos que podrían ser mejor utilizados en funciones más productivas de la organización [5].

3. **Eficiencia Operativa:** Saber qué insumos se necesitarán en el futuro permite planificar y programar las operaciones de manera más eficiente, evitando retrasos y problemas logísticos.

Es útil mantener los inventarios en las empresas porque, se tiene en cuenta la capacidad de predicción con el fin de planear la capacidad y establecer un cronograma de producción, también fluctuaciones en la

demanda ósea una reserva de inventarios a la mano que supone protección, inestabilidad de los suministros, protección deprecios, descuentos por cantidad, menores costos de pedidos [5].

4. **Satisfacción del Cliente:** Mantener un suministro constante de productos esencial para el negocio, ya que los clientes esperan encontrar su elección preferida en el menú en todo momento.

### 2.1.3. Factores que Influyen en la Curva de Insumos Demandados

Varios factores pueden influir en el comportamiento de la curva de insumos demandados:

- **Día de la Semana y Estacionalidad:** Los patrones de consumo pueden variar según el día de la semana y la temporada. Por ejemplo, los fines de semana pueden tener una mayor demanda en comparación con los días laborables.
- **Eventos Especiales:** Eventos como días festivos, celebraciones locales o conciertos cercanos pueden aumentar la demanda de alimentos y bebidas.
- **Tendencias de Consumo:** Las tendencias gastronómicas y las preferencias cambiantes de los consumidores pueden afectar la demanda de ciertos productos.
- **Clima:** Las condiciones climáticas también pueden influir en la demanda. Por ejemplo, un día caluroso podría aumentar la demanda de bebidas frías.
- **Promociones y Ofertas:** Las promociones especiales pueden aumentar temporalmente la demanda de ciertos productos.

## 2.2. Tiempos Actuales en las Predicciones de Demanda

En la actualidad, las predicciones de demanda se benefician ampliamente de las tecnologías avanzadas y el análisis de datos. Las empresas pueden aprovechar sistemas de gestión de inventario y software de análisis de datos

para recopilar y procesar información histórica y en tiempo real. Estas herramientas les permiten aplicar técnicas estadísticas y modelos de pronóstico para anticipar con mayor precisión los patrones de demanda futura.

En tiempos recientes, se ha observado la aplicación de diversas técnicas en el campo de la inteligencia artificial, como sistemas expertos, y más recientemente, algoritmos genéticos. Sin embargo, a pesar de esta evolución, los modelos que han captado una atención destacada son los basados en Redes Neuronales Artificiales (RNAs). Con el transcurso del tiempo, se han desarrollado múltiples arquitecturas de RNAs para abordar una variedad de problemas en el ámbito de la predicción de demanda.

## 2.3. Sistema de información

Según [6] el sistema de información *“Es un conjunto de elementos que interactúan entre sí, con el fin de apoyar las actividades de una empresa o negocio”*.

Es importante tener en cuenta que la necesidad de información en las organizaciones es vital para alcanzar el éxito y que un sistema de información debe justificar su implementación desde el punto de vista costo/beneficio, basándose en el valor que se le otorga a la información dentro de la organización [6]. Los beneficios pueden ser tangibles e intangibles, y dependen de los objetivos y necesidades de la organización.

Los sistemas de información se desarrollan para diferentes propósitos, según las necesidades de los usuarios humanos y la empresa. En definitiva, el uso adecuado de la información y la implementación de sistemas de información efectivos pueden marcar una gran diferencia en el éxito de una organización.

paragraph Tipos de sistema de información

El propósito de un sistema de información, puede ser muy amplio, todo depende de las necesidades de la organización. Existen distintos tipos de sistemas de información, entre los que destacan los siguientes [6]:

**Sistemas de procesamiento de transacciones** Se define como transacción un suceso que implica o afecta a una organización, y que está compuesta por datos referentes a ellas y que son de importancia para la organización [6]. Estos sistemas se encargan del procesamiento de los datos referentes a las transacciones, además de permitir la automatización de tareas y procesos operativos.

La información que se obtiene como salida es utilizada posteriormente por los funcionarios de nivel operativo de la organización en la toma de decisiones.

Las razones para el procesamiento de las transacciones son:

- Clasificación: Implica agrupar todos los datos de acuerdo con características comunes.
- Operaciones de cálculo: Consiste en realizar alguna operación para obtener resultados útiles.
- Ordenamiento: Consiste en disponerlos de alguna forma o secuencia, facilita el procesamiento y la búsqueda.
- Síntesis: Reduce los datos en información breve y concisa.
- Almacenamiento: Permite el registro de todas y cada una del suceso que afectan a la organización.

**Sistema de información administrativa** Los sistemas de información administrativa (MIS) no sustituyen a los sistemas de procesamiento de transacciones; más bien, todos los sistemas MIS incluyen el procesamiento de transacciones [6]. Los MIS son sistemas de información computarizados que funcionan debido a la decidida interacción entre las personas y las computadoras.

Al requerir que las personas, el software y el hardware funcionen en conjunto, los sistemas de información administrativa brindan soporte a los usuarios para realizar un espectro más amplio de tareas organizacionales que los sistemas de procesamiento de transacciones, incluyendo los procesos de análisis y toma de decisiones. Para acceder a la información, los usuarios del sistema de información administrativa comparten una base de datos común; esta almacena tanto los datos como los modelos que permiten al usuario interactuar con ellos, interpretarlos y aplicarlos. Los sistemas de información administrativa producen información que se utiliza en el proceso de toma de decisiones. También pueden ayudar a integrar algunas de las funciones de información computarizadas de una empresa.

**Sistema de soporte de decisiones DSS** Son sistemas de información que tienen como propósito auxiliar al usuario con las decisiones únicas que no se repiten y que no tienen una estructura definida [6]. Además de estar hechos a la medida de la persona o grupo que los usa en comparación con los Sistemas de información Gerencial. El propósito de estos sistemas es el de responder correctamente a condiciones inesperadas y propias de la información. Esto permite que sean empleados en niveles altos de la organización.



**Sistema de información gerencial** Los Sistemas de Información Gerencial, también llamados Sistemas de Reportes de Gerencia, se dedican al apoyo de decisiones siempre que los requerimientos de información sean identificados, esto es, que la información que necesita para la toma de decisiones haya sido analizada anteriormente, y que esta misma decisión pueda tomarse nuevamente [6]. Estos sistemas pueden extraer la información necesaria de cualquier parte de la organización, por lo que la información necesaria ya se tiene almacenada al ser procesada por un sistema de transacciones.

**Sistema experto e inteligencia artificial** La inteligencia artificial (IA) puede ser considerada como el campo dominante de los sistemas expertos. La idea general de la IA ha sido desarrollar equipos que se comporten de manera inteligente [6].

Dos ramas de investigación de la IA son:

- La comprensión del lenguaje natural.
- El análisis de la habilidad para razonar un problema y llegar a una conclusión lógica.

Los sistemas expertos utilizan las metodologías de razonamiento de la IA para resolver los problemas que los usuarios de negocios (y otros tipos de usuarios) les presentan. Los sistemas expertos son una clase muy especial de sistema de información que ha demostrado su utilidad comercial gracias a la disponibilidad extendida de hardware y software como las computadoras personales (PC) y las interfaces de sistemas expertos.

Un sistema experto (también conocido como sistema basado en el conocimiento) captura y utiliza en forma efectiva el conocimiento de uno o varios expertos humanos para resolver un problema específico al que una organización se enfrenta. Cabe mencionar que a diferencia de los sistemas DSS, que en última instancia dejan la decisión a la persona encargada de la toma de decisiones, un sistema experto selecciona la mejor solución para un problema o una clase específica de problemas. Los componentes básicos de un sistema experto son la base de conocimiento, un motor de inferencia que conecta al usuario con el sistema mediante el proceso de consultas en lenguajes, como el lenguaje de consulta estructurado (SQL), y la interfaz de usuario. Las personas conocidas como ingenieros del conocimiento capturan la experiencia de los expertos, crean un sistema computacional que incluye este conocimiento y después lo implementan [6].




Figura 2.3: Arquitectura de un sistema experto [2].

En los Sistemas Expertos el conocimiento se hace explícito en forma de reglas, en la computación neuronal las ANN generan sus propias reglas aprendiendo de los ejemplos que se les muestran en la fase de entrenamiento [7].

## 2.4. Minería de datos

La minería de datos puede definirse inicialmente como un proceso de descubrimiento de nuevas y significativas relaciones, patrones y tendencias al examinar grandes cantidades de datos [8].

El análisis de datos, potenciado por herramientas informáticas, ha dado lugar a la minería de datos. Esta disciplina busca descubrir automáticamente conocimiento en grandes bases de datos, identificando patrones, tendencias y perfiles a través de tecnologías avanzadas como el reconocimiento de patrones, redes neuronales y algoritmos genéticos.

Inicialmente, los sistemas de información se centraban en recopilar datos para apoyar la toma de decisiones. Con la informatización de las organizaciones, se amplió su función para respaldar los procesos esenciales. Ahora, se buscan prestaciones adicionales, como sistemas de información para la toma de decisiones.

La Minería de Datos se puede ubicar en el nivel más alto de la evolución de los procesos tecnológicos de análisis de datos [9].

## 2.5. Técnicas de modelado de procesos de ETL

Las herramientas de Extracción-Transformación-Carga (ETL) son piezas de software responsables de la extracción de datos de varias fuentes, su lim-

pieza, personalización e inserción en un almacén de datos [10].

El proceso de extracción, transformación y carga – ETL es una de las actividades técnicas más críticas en el desarrollo de soluciones de inteligencia de negocios BI [11].

El proceso de ETL es esencial para garantizar la calidad y la integridad de los datos antes de que se utilicen en aplicaciones analíticas o de toma de decisiones. Permite a las organizaciones transformar datos crudos en información procesable y confiable. Además, con la creciente cantidad de datos disponibles en la actualidad, el ETL se ha vuelto cada vez más importante para integrar datos de diversas fuentes y garantizar que estén listos para su análisis.

Para autores como Ralph Kimball los Almacenes de Datos son “una copia de los datos transaccionales estructurados específicamente para consultas y análisis”, mientras que Bill Inmon define el término Almacén de Datos como: “una colección de datos orientados por temas, integrados, variables en el tiempo y no volátiles para el apoyo de la toma de decisiones”. Los Almacenes de Datos son integradores, ya que su contenido proviene de diversas fuentes de datos como: Sistemas heredados, Archivos de Textos, Base de Datos Relacionales, ERP, entre otras posibilidades. La forma de lograr esta integración es a través del uso y desarrollo de los Procesos ETL. Estos procesos son los encargados de la extracción de los datos desde sus fuentes de origen, de transformarlos a la información deseada, de lograr la limpieza necesaria en aquellos que lo requieran y finalmente cargar al Almacén de Datos deseado, el que será utilizado con alguna finalidad como análisis en un área de las ventas de una corporación o el estudio de tendencias de alguna consultora [12].

## 2.6. Inteligencia Artificial

### 2.6.1. El aprendizaje automático (*machine learning*)

*Según Arthur Samuel, el aprendizaje automático se define como el campo de estudio que otorga a las computadoras la capacidad de aprender sin ser programadas explícitamente* [13].

El aprendizaje automático se utiliza para enseñar a las máquinas a manejar los datos de manera más eficiente. A veces, después de ver los datos, no podemos interpretar la información extraída de los mismos. En ese caso, aplicamos el aprendizaje automático.

Es decir, el aprendizaje automático como área de las ciencias computacionales aplicadas, desarrolla algoritmos capaces de tomar datos numéricos y alfanuméricos almacenados en un computador [14].

Con la abundancia de conjuntos de datos disponibles, la demanda de aprendizaje automático está en aumento. Muchas industrias aplican el aprendizaje automático para extraer datos relevantes. El propósito del aprendizaje automático es aprender de los datos. Se han realizado muchos estudios sobre cómo hacer que las máquinas aprendan por sí mismas sin ser programadas explícitamente. Muchos matemáticos y programadores aplican varios enfoques para encontrar la solución a este problema que implica conjuntos de datos enormes [13].

El Aprendizaje Automático se basa en diferentes algoritmos para resolver problemas de datos. A los científicos de datos les gusta señalar que no existe un único tipo de algoritmo que sea universal y mejor para resolver todos los problemas. El tipo de algoritmo utilizado depende del tipo de problema que se desee resolver, el número de variables, el tipo de modelo que se adapte mejor, entre otros factores.

Las técnicas de machine learning son necesarias para mejorar la precisión de los modelos predictivos. Dependiendo de la naturaleza del problema empresarial que se está atendiendo, existen diferentes enfoques basados en el tipo y volumen de los datos [15].

En el contexto de la aplicación de algoritmos de Machine Learning en el cálculo de pronósticos de demanda, es esencial comprender que el objetivo principal de estos algoritmos es encontrar una función que tome un conjunto de variables como entrada y produzca una estimación del valor deseado, en este caso, la demanda. Esta función se ajusta a través del aprendizaje a partir de observaciones pasadas donde los datos de demanda son conocidos. Por ejemplo, utilizando datos de demanda de los últimos años, el modelo se entrena para desarrollar una función que pueda hacer predicciones precisas sobre la demanda futura, lo que implica una tarea de regresión, ya que el resultado esperado es un valor numérico real. Esta metodología se basa en el libro “Deep Learning” de Ian Goodfellow, Yoshua Bengio y Aaron Courville [16].

Una forma común de describir a un conjunto de datos u observaciones (dataset) es con una matriz de diseño. Una matriz de diseño es una matriz que contiene un ejemplo diferente en cada fila. Cada columna de la matriz corresponde a una característica diferente. Los algoritmos de aprendizaje se diferencian en función de la forma de operar y procesa los datos contenidos en una matriz de diseño [17].

El siguiente diagrama muestra un flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo [18]:




Figura 2.4: flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo

### Procesamiento:

- Extracción y escalado de características.
- Selección de características.
- Reducción de la dimensionalidad.
- Muestreo.

### Aprendizaje:

- Selección del modelo.
- Validación cruzada.
- Medición del rendimiento.
- Optimización de hiperparametro.

## 2.6.2. Aprendizaje supervisado

El aprendizaje supervisado comienza típicamente con un conjunto establecido de datos y una cierta comprensión de cómo se clasifican estos datos. El aprendizaje supervisado tiene la intención de encontrar patrones en datos que se pueden aplicar a un proceso de analítica. Estos datos tienen características etiquetadas que definen el significado de los datos. Por ejemplo, se puede crear una aplicación de machine learning con base en imágenes y descripciones escritas que distinga entre millones de animales [15].

El objetivo principal del aprendizaje supervisado es aprender un modelo, a partir de datos de entrenamiento etiquetados, que nos permite hacer predicciones sobre datos futuros o no vistos [18]. Aquí, el término supervisado se refiere a un conjunto de muestras donde las señales de salida deseadas (etiquetas) ya se conocen.

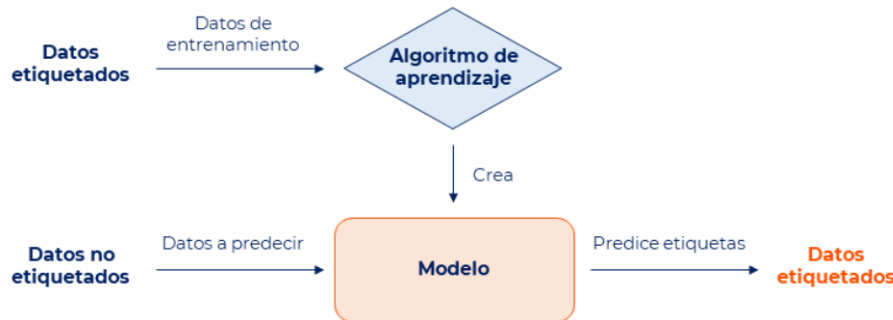


Figura 2.5: Aprendizaje supervisado [1].

### 2.6.3. Aprendizaje no supervisado

El aprendizaje no supervisado se utiliza cuando el problema requiere una cantidad masiva de datos sin etiquetar. Por ejemplo, las aplicaciones de redes sociales, tales como Twitter, Instagram y Snapchat, tienen grandes cantidades de datos sin etiquetar. La comprensión del significado detrás de estos datos requiere algoritmos que clasifican los datos con base en los patrones o clústeres que encuentra. El aprendizaje no supervisado lleva a cabo un proceso iterativo, analizando los datos sin intervención humana [15].

Los métodos de aprendizaje no supervisados son utilizados durante el preprocesamiento de los datos antes de ser utilizados por algoritmos de característica supervisada. Estos algoritmos también son muy utilizados en la compresión de datos. Todos los métodos son implícita o explícitamente basados en la distribución de probabilidad en el espacio definido por las variables de entrada [19].

#### 2.6.3.1. Aprendizaje de refuerzo

El aprendizaje de refuerzo es un modelo de aprendizaje conductual. El algoritmo recibe retroalimentación del análisis de datos, conduciendo el usuario hacia el mejor resultado. El aprendizaje de refuerzo difiere de otros tipos de aprendizaje supervisado, porque el sistema no está entrenado con el conjunto

de datos de ejemplo. Más bien, el sistema aprende a través de la prueba y el error. Por lo tanto, una secuencia de decisiones exitosas conduce al fortalecimiento del proceso, porque es el que resuelve el problema de manera más efectiva [15].

#### **2.6.4. Redes Neuronales Artificiales**

Las Redes Neuronales Artificiales (RNA) son un componente esencial de la Inteligencia Artificial que emula el funcionamiento de las neuronas biológicas. Estas redes, entrenadas con entradas de escenarios internos o externos multiplicadas por pesos aleatorios, destacan en la resolución de funciones altamente no lineales, lo que las convierte en herramientas poderosas para la predicción. Inspiradas en el sistema nervioso biológico, encuentran aplicaciones en áreas como neurociencias, matemáticas, estadísticas y más. Su capacidad para aprender de datos de entrada las hace especialmente valiosas en la predicción de patrones complejos en diversos campos, como finanzas, ciencia de datos y análisis de mercado.

Es un algoritmo basado en una red de alimentación de múltiples capas entrenadas inspirado en las neuronas del cerebro humano, estos sistemas aprenden y se forman a sí mismos ya que sus neuronas artificiales están conectadas, en lugar de ser programados de forma explícita [14].

En el desarrollo de una red neuronal no hay que programar ni el conocimiento ni las reglas del procesamiento del conocimiento. La red neuronal aprende las reglas del procesamiento del conocimiento mediante el ajuste de las conexiones ponderadas entre las neuronas de distintas capas de la red. El aprendizaje se consigue a través de una regla de aprendizaje que adapta o cambia los pesos de las conexiones en respuesta a los ejemplos de entrada, y opcionalmente también en respuesta a las salidas deseadas. Esta característica de las ANN es lo que permite decir que las redes neuronales aprenden de la experiencia [7].

La neurona artificial fue diseñada para “emular” las características del funcionamiento básico de la neurona biológica [20]. En esencia, se aplica un conjunto de entradas a la neurona, cada una de las cuales representa una salida de otra neurona. Cada entrada se multiplica por su “peso” o ponderación correspondiente análogo al grado de conexión de la sinapsis. Todas las entradas ponderadas se suman y se determina el nivel de excitación o activación de la neurona.

Representación vectorial del funcionamiento básico de una neurona artificial se indica según la siguiente expresión de la ecuación.

$$NET = X \cdot W$$

Siendo NET la salida, X el vector de entrada y W el vector de pesos.

La representación del modelo matemático es el siguiente

$$y = H \left( \sum_{j=1}^n w_j x_j - u \right) \quad (2.1)$$

Donde  $H$  es la función de activación (en este caso la función escalón de Heaviside) con el umbral  $u$ ,  $x_j$  es la señal de entrada y  $w_j$  es el peso asociado con  $j = 1, 2, \dots, n$ , donde  $n$  corresponde al número de entradas. La salida de esta unidad es 1 cuando la suma está por encima del umbral  $u$ , y es 0 en caso contrario [17].

El elemento fundamental de los sistemas neuronales biológicos es la neurona, una célula viva que, como tal contiene todos los elementos que integran las células biológicas, si bien incorpora otros elementos que la diferencian (Figura 2.6). De forma genérica, una neurona consta de un cuerpo celular o soma más o menos esférico (de entre 10 y 80 micras de longitud), del que parten una rama principal o axón (cuya longitud varía desde las 100 micras hasta el metro en el caso de las neuronas motoras que constituyen los nervios) y un denso árbol de ramificaciones más cortas (árbol dendrítico), compuesto por dendritas. A su vez, el axón puede ramificarse en su punto de arranque, y con frecuencia presenta múltiples ramas en su extremo. La forma final de la neurona depende de la función que cumple, esto es, de la posición que ocupa en el conjunto del sistema y de los estímulos que recibe [3].




Figura 2.6: Componentes de una neurona.



### 2.6.5. Capas de la neurona artificial

**Desde un punto de vista funcional**, las neuronas constituyen procesadores de información sencillos, integrados por: Un canal de recepción de información, las dendritas, que reciben señales de entrada (inputs) procedentes de otras células (interneuronas) o del exterior (neuronas receptoras o sensoras, como los conos y bastones de la retina) [21].

**Un órgano de cómputo**, el soma, que combina e integra los inputs recibidos (generalmente a través de funcionales no lineales), emitiendo señales de salida en forma de estímulos nerviosos [21].

**Un canal de salida**, el axón, que envía la salida generada por el soma a otras neuronas o bien, en el caso de las neuronas motoras, directamente al músculo. Para transmitir la información, el axón se conecta a través de sus ramificaciones a las dendritas de otras neuronas, que reciben las señales y las combinan para producir nuevas salidas. Una neurona del córtex cerebral recibe información, por término medio, de unas 10.000 neuronas (convergencia), y envía impulsos a varios cientos de ellas (divergencia) [21].




Figura 2.7: Tipos de neuronas artificiales [3].

Características de tres tipos de neuronas artificiales: unidades de entrada, de salida y unidades ocultas(Figura 2.7) [3].

- Las neuronas de entrada reciben señales desde el entorno, provenientes de sensores o de otros sectores del sistema (como archivos de almacenamiento de patrones de aprendizaje).
- Las neuronas de salida envían su señal directamente fuera del sistema una vez finalizado el tratamiento de la información (salidas de la red).
- Las neuronas ocultas reciben estímulos y emiten salidas dentro del sistema, sin mantener contacto alguno con el exterior. En ellas se lleva a

cabo el procesamiento básico de la información, estableciendo la representación interna de ésta.

### **2.6.6. Modelo de redes neuronales artificiales**

Las redes neuronales artificiales son motivadas por ciertas cualidades de su modelo real, por lo cual el desafío es producir un modelo que tenga [22]:

- Una estructura de procesamiento distribuida y paralela (opuestamente al CPU de una computadora).

La arquitectura de las ANN parte de la organización de los sistemas de procesamiento en paralelo, es decir, sistemas en los que distintos procesadores están interconectados. No obstante los procesadores son unidades procesadoras simples, diseñadas para la suma de muchas entradas y con un ajuste automático de las conexiones ponderadas.

- Alto grado de conexión entre las unidades básicas.
- Conexiones modificables en función de la experiencia.
- Un proceso de aprendizaje constante y de ser posible uno no supervisado
- Aprendizaje basado en información local.
- Robustez en la performance si algunas unidades son removidas.

### **2.6.7. Arquitectura de una red neuronal**

La topología o arquitectura hace referencia a la organización y disposición de las neuronas en la red formando capas de procesadores interconectados entre sí a través de sinapsis unidireccionales. La arquitectura de una RNA depende de cuatro parámetros principales [3]:

- el número de capas,
- el número de neuronas por capa,
- el grado de conectividad entre las neuronas y
- el tipo de conexiones neuronales.

Las arquitecturas neuronales pueden clasificarse atendiendo a distintos criterios [3]:

- Según su estructura en capas
  - Redes monocapa, compuestas por una única capa de neuronas, entre las que se establecen conexiones laterales y, en ocasiones, autorrecurrentes. Este tipo de redes suele utilizarse para la resolución de problemas de autoasociación y clusterización.
  - Redes multicapa (layered networks), cuyas neuronas se organizan en varias capas (de entrada, oculta(s) y de salida). La capa a la que pertenece la neurona puede distinguirse mediante la observación del origen de las señales que recibe y el destino de la señal que genera.
- Según el flujo de datos en la red
  - Redes unidireccionales o de propagación hacia adelante (feedforward), en las que ninguna salida neuronal es entrada de unidades de la misma capa o de capas precedentes. La información circula en un único sentido, desde las neuronas de entrada hacia las neuronas de salida de la red.
  - Redes de propagación hacia atrás (feedback), en las que las salidas de las neuronas pueden servir de entradas a unidades del mismo nivel (conexiones laterales) o de niveles previos. Las redes de propagación hacia atrás que presentan lazos cerrados se denominan sistemas recurrentes.

### 2.6.8. Redes neuronales recurrentes (RNN)

Las redes neuronales recurrentes tienen caminos de retroalimentación entre todos los elementos que las conforman [23]. Una sola neurona está entonces conectada a las neuronas posteriores en la siguiente capa, las neuronas pasadas de la capa anterior y a ella misma a través de vectores de pesos variables que sufren alteraciones en cada época con el fin de alcanzar los parámetros o metas de operación.

Las redes neuronales recurrentes (RNNs) son un tipo de modelo de aprendizaje profundo que se utiliza para analizar datos secuenciales, como el procesamiento del lenguaje natural o la predicción de series de tiempo [24].

A diferencia de las redes neuronales artificiales ya vistas, que asumen la independencia entre los datos de entrada, las RNN capturan activamente sus dependencias secuenciales y temporales [17].

Las RNN generalmente aumentan la arquitectura de red multicapa convencional con la adición de ciclos que conectan nodos adyacentes o pasos de tiempo.

Estos ciclos constituyen la memoria interna de la red que se utiliza para evaluar las propiedades del dato actual con respecto a los datos del pasado inmediato.

Las redes neuronales recurrentes son más eficaces para resolver problemas con no linealidades temporales significativas. Son especialmente útiles en aplicaciones tales como el reconocimiento de patrones secuenciales, cambiantes en el tiempo, ya que las capacidades de predicción y mapeo de las RNN así lo permiten [23].

Sin embargo, la capacidad de las RNNs para manejar datos a largo plazo se ve comprometida por el problema del gradiente que desaparece, que ocurre cuando el gradiente se hace cada vez más pequeño a medida que se propaga hacia atrás en la red [24].

Para superar este problema, Hochreiter & Schmidhuber, propusieron la memoria a corto y largo plazo (LSTM), una variante de las RNNs que ha demostrado ser efectiva para el procesamiento de datos secuenciales a largo plazo [24].

### 2.6.9. Arquitectura básica de una RNN

Arquitectura básica de una RNN. Una característica importante es la inclusión de retrasos ( $z^{-1}$ ) a la salida de las neuronas en las capas intermedias; las salidas parciales  $S_{mn}(t+1)$  se convierten en valores  $S_{mn}(t)$ , un instante de tiempo anterior, y así se retroalimenta a todos los componentes de la red, guardando información de instantes de tiempo anteriores [23]. Se puede apreciar cómo todos los nodos están interconectados entre sí, estableciendo conexiones tanto directas como mediante retardos temporales con los nodos precedentes en cada capa, lo que permite la incorporación de memorias temporales.




Figura 2.8: La arquitectura básica de una RNN

### 2.6.10. Redes de Memoria Corta y Larga LSTM

Las redes de “larga memoria de corto plazo” (Redes de Memoria Corta y Larga (LSTM)), propuestas por Hochreiter y Schmidhuber. Es una de las arquitecturas de aprendizaje profundo más avanzadas y exitosas para predicción de series temporales, reconocimiento de escritura y análisis de discurso [25].

El modelo matemático de LSTM se define como una función no lineal que transforma la entrada actual, el estado anterior y la memoria a largo plazo en una salida y un estado actualizado.

El cálculo de esta función implica la operación de multiplicación de matrices y la aplicación de funciones de activación, como la función sigmoide o la tangente hiperbólica [24].

El objetivo es mejorar la memoria de la RNN de los eventos pasados entrenándola para que recuerde lo importante y olvide el resto. Para ello, las LSTM procesan dos versiones del pasado [17].

### 2.6.11. Modelo de Regresión Lineal

cargar aquí [26]. [27]

### 2.6.12. Los pesos sinápticos

A una neurona artificial se le asigna un peso sináptico a las entradas que provienen desde otras neuronas. Este procedimiento es similar al que se realiza en una neurona de un ser humano, a lo que normalmente en la medicina se le conoce como sinapsis. El peso sináptico entonces es un valor numérico y que puede ir cambiando durante la fase de entrenamiento [28].

Este peso hace que la red neural tenga una utilidad y es allí donde se almacena la información.

En una red de neuronas existe un peso o fuerza sináptica que va a ser un valor numérico que pondera las señales que se reciben por sus entradas. Este peso será un valor que determina la fuerza de conexión entre 2 neuronas. Cuando se evalúa una neurona se debe calcular el conjunto de todas las fuerzas o valores (denominado NET) que se reciben por sus entradas. Una vez calculado el valor conjunto de todas las entradas se aplica una función de activación (FA) que determinará el valor del estado interno de la neurona y que será lo que se transmita a su salida [29].

### **2.6.13. Perceptron**

En 1957, Frank Rosenblatt publicó el mayor trabajo de investigación en computación neuronal realizado hasta esas fechas. Su trabajo consistía en el desarrollo de un elemento llamado “Perceptron” [7].

El perceptron es un sistema clasificador de patrones que puede identificar patrones geométricos y abstractos. El primer perceptron era capaz de aprender algo y era robusto, de forma que su comportamiento variaba sólo si resultaban dañados los componentes del sistema. Además presentaba la característica de ser flexible y comportarse correctamente después de que algunas celdas fueran destruidas. El perceptron fue originalmente diseñado para el reconocimiento óptico de patrones. Una rejilla de 400 fotocélulas, correspondientes a las neuronas de la retina sensibles a la luz, recibe el estímulo óptico. Estas fotocélulas están conectadas a elementos asociativos que recogen los impulsos eléctricos emitidos desde las fotocélulas. Las conexiones entre los elementos asociativos y las fotocélulas se realizan de forma aleatoria. Si las células presentan un valor de entrada superior a un umbral predeterminado entonces el elemento asociativo produce una salida [7].




Figura 2.9: Aplicación de la Red Perceptron

#### 2.6.14. Perceptrón multicapa

Una Perceptrón multicapa (MLP) puede ser interpretada como una extensión del algoritmo de regresión logística donde primero la entrada es transformada utilizando una transformación no lineal [19]. El propósito de esta transformación es proyectar los datos de entrada a un espacio donde sean linealmente separables. Esta capa intermedia es conocida como capa oculta y es característica de una MLP poseer dos o más de ellas. Una capa oculta única es suficiente para hacer de una MLP un aproximador universal.

### 2.7. Series de Tiempo

Las series de tiempo, son datos estadísticos que se recopilan, observan o registran en intervalos de tiempo regulares (diario, semanal, semestral, anual, entre otros) [14].

Conviene recalcar que una serie de tiempo es un conjunto ordenado de valores, no una función, y que no debe ser tratada como tal [30].

### 2.8. Antecedentes

En el proyecto titulado *“Desarrollo de un Sistema de Control de Inventario para la Gestión de Compras de Materia Prima en el Rubro de Restaurantes”* [31].

Este antecedente presenta un estudio de caso relevante en el ámbito de la gestión de inventario y compras en la industria de restaurantes. Se describe

cómo se implementó con éxito un sistema de control de inventario utilizando el modelo de desarrollo de ciclo de vida en cascada. El objetivo principal de esta implementación fue mejorar la gestión de los procesos de almacén y reducir los tiempos innecesarios en la entrega de productos a los clientes. El sistema se dividió en módulos específicos, centrándose en el almacén y ofreciendo diversas funcionalidades para la gestión eficiente del restaurante. Los resultados obtenidos demuestran una modernización efectiva de los procesos de la empresa en el rubro de restaurantes, con mejoras significativas en la gestión y una reducción sustancial de los tiempos de almacenamiento. Este antecedente sirve como base para la presente tesis, que se enfoca en el desarrollo de un sistema de compra inteligente basado en el historial de ventas, aprovechando la experiencia exitosa de la implementación previa para impulsar la eficiencia operativa en la industria de alimentos

En el trabajo titulado ***“Optimización de la cadena de abastecimiento a través de un sistema inteligente de pronósticos de demanda y gestión de inventario multiproducto”*** [32].

El objetivo principal del proyecto fue desarrollar una aplicación web que automatizara parcialmente las actividades del área de compras y mejorara la cadena de abastecimiento mediante un sistema inteligente de pronósticos de demanda y gestión de inventario multiproducto. Este antecedente se presenta como una sólida prueba de concepto para la implementación de sistemas inteligentes de gestión de compras basados en pronósticos de demanda en la industria gastronómica, lo que respalda y valida la relevancia de la presente tesis sobre un sistema de compra inteligente basado en historial de ventas.

En el artículo titulado ***“Plan de gestión para la creación de una plataforma tecnológica en un establecimiento gastronómico”*** [33]. Los autores proponen la implementación de una plataforma tecnológica en un restaurante, combinando metodologías de gestión tradicionales y ágiles. El objetivo es mejorar la eficiencia y eficacia en las tareas de atención, supervisión, control y administración del establecimiento gastronómico. La metodología SCRUM se utilizará para la gestión del desarrollo, utilizando las estimaciones previas como métricas de evolución para identificar posibles retrasos e inconvenientes. El plan de proyecto estima los alcances, costos y duración de las tareas de desarrollo, definiendo planes de gestión de calidad y mitigación de riesgos. La combinación de metodologías utilizada busca generar una solución eficiente para la administración del desarrollo de la plataforma tecnológica.

El artículo ***“Reducing Food Waste in the Food Industry with***



***Deep Learning***” [34].

El autor, Esteban David Romero Pérez, se centra en la importante tarea de ayudar a la industria alimentaria a anticipar con precisión la demanda de sus productos y, por lo tanto, reducir los excedentes no vendidos, lo que está alineado con el Objetivo de Desarrollo Sostenible número 12 de las Naciones Unidas. Los resultados obtenidos en este estudio demuestran de manera convincente que la aplicación de Deep Learning puede conducir a una disminución sustancial en la cantidad de alimentos desperdiciados en la industria alimentaria, contribuyendo significativamente a un futuro más sostenible y eficiente en el uso de recursos. Este antecedente resalta la relevancia de la tecnología de aprendizaje profundo en la optimización de procesos en la industria alimentaria, lo que puede ser de gran utilidad para el enfoque de la presente tesis.

En un estudio llevado a cabo en Móstoles, España titulado ***“Un análisis de sentimiento en Twitter con Machine Learning: Identificando el sentimiento sobre las ofertas de #BlackFriday”*** [35]. Se estableció una conexión con la API de Twitter para recopilar un total de 2204 tweets relacionados con los comentarios e interacciones de los usuarios acerca de las ofertas proporcionadas por empresas en la muestra. Posteriormente, se aplicó un algoritmo de análisis de sentimiento desarrollado en Python utilizando la biblioteca MonkeyLearn para categorizar estos tweets en positivos y negativos. Se centró en evaluar la percepción de los usuarios sobre las ofertas del Black Friday a través del análisis automatizado de los comentarios en Twitter.

Tesis ***“Predicción de la demanda usando modelos de machine Learning”*** [36] Para aquellas empresas dedicadas a la venta en retail o venta directa donde su portafolio de productos es muy amplio, la planeación de la demanda se convierte en un área determinante para la correcta administración del flujo de caja, rentabilidad y efectividad en ventas por varias razones: la primera de ellas es la gestión de compra de insumos por medio de negociación de precio por volumen con sus proveedores; el control de inventario donde se cuida un equilibrio entre uso efectivo del espacio de almacenamiento y reducción de obsolescencia contra la disponibilidad para distribución y por último en la venta efectiva respetando las estacionalidades, tendencias del mercado y satisfacción del cliente.

Trabajo final de grado titulado ***“Estudios de predicción en series temporales de datos meteorológicos utilizando redes neuronales recurrentes”*** [23] En los últimos años, en el campo de las energías reno-

vables, la energía eólica ha sido una de las que mas se ha desarrollado e invertido. La importancia de las predicciones de viento radica en la ayuda que aportan para planificar y anticiparse a los valores futuros que afectarán al sistema, ayudando a gestionar la adquisición de los recursos necesarios con antelación suficiente. Recientemente se han desarrollado nuevas arquitecturas de redes recurrentes que resultan muy prometedoras para realizar predicción. En este trabajo se probará y experimentará con dichas arquitecturas para realizar distintas predicciones de la velocidad del viento en un horizonte de corto y muy corto plazo a partir de datos de series temporales de viento.

## Capítulo 3

# Predicción de la demanda

En esta sección, se describirán los métodos utilizados para llevar a cabo la investigación sobre la predicción de compras a partir de un historial de ventas.

- 3.1. Preprocesamiento de datos**
- 3.2. Análisis de los datos**
- 3.3. Definición de variables de entrada y salida**
- 3.4. Lectura y escalado del dataset en Python**
- 3.5. Distribución del conjunto de datos**
- 3.6. Aplicación y comparación de técnicas ML**
  - 3.6.1. Regresión lineal**
  - 3.6.2. LSTM**
- 3.7. Afinación de hiperparámetros con base en porcentaje de pérdida RMS**

Los datos originales suministrados están conformados por los siguientes datasets:

- productos.csv
- ventas.csv

Los datos vienen organizados en forma tabular, cada archivo presenta información separada relacionada con los diferentes productos y el registro de ventas histórico, a continuación se describirán cada uno por separado.

**productos.csv**

Proporciona información de 5 productos, el dataset contiene 2 columnas: id, producto. El primero representa un identificador único para cada producto que posteriormente me permitirá relacionarlo con otras tablas, el segundo indica el nombre del producto.

id	producto
1	Hamburguesa Simple
2	Hamburguesa doble
3	Hamburguesa triple
4	Hamburguesa doble bacon
5	Papa pequeña

Figura 3.1: productos.csv(Los primeros 5 productos)

En la tabla 3.1 se muestra una descripción de cada una de las columnas de productos.

Columna	Descripción
id	el id del producto (identificador unico)
producto	el nombre del producto

Tabla 3.1: Descripción columnas productos.csv

### **ventas.csv**

Cuenta con 3.840 registros de ventas que agrupados por fecha dan un total de 185 registros, que corresponden a la cantidad de ventas diarias del producto mencionado organizados por fechas desde el 17 de abril de 2023 hasta el 15 de octubre de 2023.

registro	mes	dia	dia_semana	dia_festivo	estacion	cantidad_ventas	cantidad
1	4	17	2	0	2	8	13
2	4	18	3	0	2	15	25
3	4	19	4	0	2	10	15
4	4	20	5	0	2	28	45
5	4	21	6	0	2	17	34
6	4	22	7	0	2	40	63
7	4	23	1	0	2	22	44
8	4	24	2	0	2	6	46
9	4	25	3	0	2	14	26
10	4	26	4	0	2	16	36
11	4	27	5	0	2	14	21
12	4	28	6	0	2	25	48
13	4	29	7	0	2	40	72
14	4	30	1	0	2	26	49
15	5	1	2	1	2	20	41
16	5	2	3	0	2	9	17
17	5	3	4	0	2	7	15
18	5	4	5	0	2	22	41
19	5	5	6	0	2	16	31
20	5	6	7	0	2	35	59
21	5	7	1	0	2	26	51
22	5	8	2	0	2	19	25
23	5	9	3	0	2	11	20
24	5	10	4	0	2	14	27
25	5	11	5	0	2	14	21

Figura 3.2: ventas.csv(Los primeros 25 registros)

## Método

En la tabla 3.2 se muestra una descripción de cada una de las columnas de ventas.

Columna	Descripción
mes	variable mes Rango(1-12)
dia	variable dias del mes Rango(1-31)
dia_semana	variable dia de la semana Rango(0-6)
dia_festivo	variable dia festivo Rango(0-1)
estacion	variable estaciones del año Rango(0-3)
producto	el id del producto

Tabla 3.2: Descripción columnas ventas.csv

El objetivo principal de esta etapa es explorar y comprender en profundidad los datos, lo que resulta fundamental para una sólida preparación y análisis de los mismos. Esta comprensión más profunda del problema de negocio nos permitirá seleccionar modelos de predicción y tomar decisiones más fundamentadas. Durante el proceso de limpieza y preparación de los datos, se han identificado características relevantes que proporcionarán información valiosa para las fases posteriores del análisis y la toma de decisiones.

Grafico en violín 3.3 para asegurar que todas las variables de entrada estén escaladas entre 0 y 1 incluyendo el set train, validación y test.




Figura 3.3: Grafico en violín incluyendo los tres set train, validación y test

Gráfico en violín 3.4 para asegurar que los datos de salida también estén escalados correctamente




Figura 3.4: Gráfico en violín de los datos de salida escaladas

Se empleó un conjunto de datos recopilados a partir del número diario de productos vendidos, obtenido de la empresa gastronómica que provee los datos para el análisis y predicción de la misma, es importante destacar que el conjunto de datos es continuamente actualizado, sin embargo, para los propósitos de esta investigación, se consideró un conjunto de datos con 180 registros que cubren el período desde 17 de Abril del 2023 hasta 15 de Octubre del 2023 de un producto en específico “hamburguesa simple”.

Como el objetivo de este proyecto consiste en predecir las ventas del día, se realiza una gráfica 3.5, la cual nos permite ver la serie temporal de las ventas del producto mencionado.




Figura 3.5: Serie temporal de las ventas totales por día

Posteriormente, se dividió el conjunto de datos en tres grupos: entrenamiento, validación y prueba. El grupo de entrenamiento comprendió 148 registros que cubren desde 17 de abril hasta el 9 de septiembre. El grupo de validación incluyó 18 registros, desde 10 de septiembre hasta el 29 de sep-



tiembre y el conjunto de prueba 19 registros desde el 30 de septiembre hasta 18 de octubre.




Figura 3.6: Distribución de los datos, ventas totales por día.

### Lista de requisitos:

- Registro de productos (Alta, Baja, Modificaciones).
- Registro de insumos(materia prima) (Alta, Baja,Modificaciones).
- Registro de pedidos/ventas (Alta, Baja, Modificaciones).
- Generación de Informes Personalizados: Debe permitir la creación de informes personalizados que muestren datos específicos para análisis.
- Análisis de Tendencias: Debe ser capaz de identificar tendencias y patrones en las ventas de insumos, lo que facilita la toma de decisiones basadas en datos.

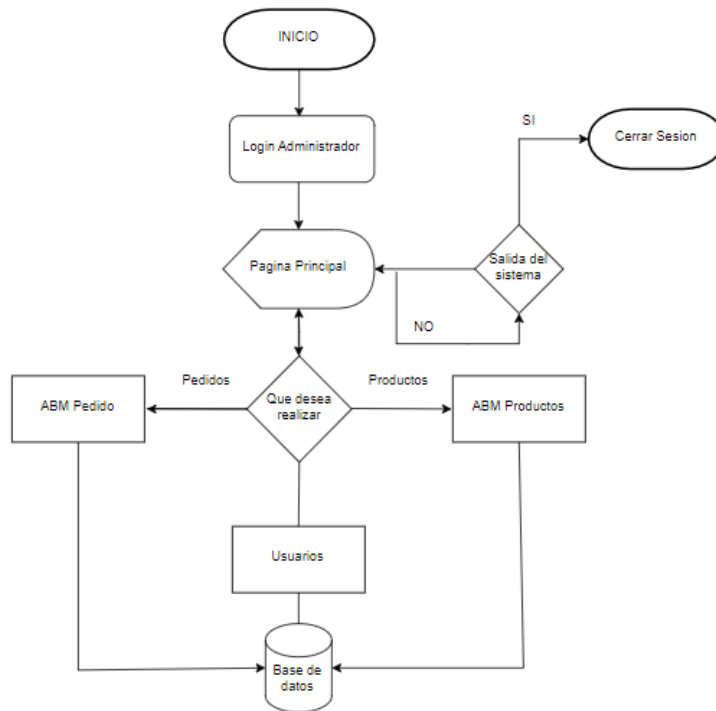


Figura 3.7: Diseño procedural.

A continuación se instalara y actualizaran las principales librerias mas utilizadas cuando se realizan programas de inteligencia artificial.

- **TensorFlow:** Es una plataforma de código abierto de un extremo a otro para el aprendizaje automático. Tiene un ecosistema integral y flexible de herramientas, bibliotecas y recursos comunitarios que permite a los investigadores impulsar lo último en ML y a los desarrolladores crear e implementar fácilmente aplicaciones basadas en ML. Es ampliamente utilizada para desarrollar y entrenar modelos de redes neuronales, incluyendo modelos LSTM (Long Short-Term Memory).
- **Keras:** Es una interfaz de alto nivel para TensorFlow que facilita la construcción, entrenamiento y evaluación de modelos de redes neuronales, incluyendo modelos LSTM.

La función de activación utilizada para modelar la no linealidad suele ser la Unidad Lineal Rectificada (ReLU), que puede calcularse más rápido que las funciones tangentes sigmoideas o hiperbólicas utilizadas tradicionalmente y también ofrece interesantes propiedades de convergencia.

## Método

---

Para su comprensión el trabajo se divide en cinco partes o etapas:

- Etapa de estudio,
- Etapa de diseño.<sup>1</sup>
- Etapa de elaboración de la solicitud de oferta y selección del vendedor,
- Etapa de instalación y puesta en funcionamiento,
- Etapa de análisis de las prestaciones y evaluación de los resultados.

---

<sup>1</sup>Solo se desarrolla esta etapa.

# Capítulo 4

## Resultados

### 4.1. Métricas de rendimiento

#### 4.1.1. Modelo de regresión lineal

#### 4.1.2. Modelo LSTM

### 4.2. Informe de predicción de compras

Este capítulo presenta el producto del análisis de los datos. Los resultados compendian el eventual tratamiento estadístico que se dio a los datos. Regularmente el orden es: a) análisis descriptivo de los datos, b) análisis inferenciales para responder a las preguntas de investigación y/o probar hipótesis. Según [37], la American Psychological Association recomienda que primero se describa de manera breve la idea principal que resume los descubrimientos, y posteriormente se los reporten con detalle. Es importante destacar que en este capítulo no se incluyen conclusiones ni sugerencias, tampoco se deben explicar las implicaciones de la investigación. Esto se hace en el capítulo dedicado a la interpretación de los resultados, que en esta plantilla se denomina “Discusión”.

Aquí el investigador se limita a describir sus hallazgos. Una manera típica de hacerlo es mediante elementos como tablas, gráficas, dibujos, diagramas, mapas y figuras generados por el análisis. Son elementos que sirven para organizar datos, de tal manera que el lector los pueda leer y entender las relaciones entre las variables. Cada uno de dichos elementos debe ir enumerado. Una buena regla para elaborar una tabla es organizarla lógicamente y eliminar la información que pudiera confundir al lector.

Es conveniente brindar una sencilla explicación de las pruebas realizadas y presentar los resultados de la manera más comprensible posible. En este caso

las tablas deben ser descritas. Los diagramas, figuras, mapas cognoscitivos, esquemas, matrices y otros elementos grficos tambien deben ser numerados segn una lgica secuencial. Se debe observar el principio bsico: una buena figura es sencilla, clara y no estorba la continuidad de la lectura. Las tablas, las figuras y los grficos deben enriquecer el texto; en lugar de duplicarlos, deben comunicar los hechos esenciales, ser coherentes y fciles de leer y comprender.

### **Figuras y Tablas**

Las figuras y tablas deben insertarse en el punto apropiado dentro del texto.

Cada figura debe estar seguida de un epgrafe que la identifique, enumere y describa brevemente. Cada figura debe ser referenciada al menos una vez, a travs de su nmero (Fig. 4.1).



Figura 4.1: Huella dactilar.

Es deseable que las figuras puedan ser interpretadas satisfactoriamente an cuando sean impresas en blanco y negro. Esto se facilita mucho haciendo uso inteligente de la combinacin de colores de forma que se consiga buen contraste entre los colores empleados, mxime si se trata de diagramas, en que a menudo es posible prescindir por completo de otros colores que el blanco y el negro, (como en la figura 4.2).




Figura 4.2: Ejemplificacin de diagrama en blanco y negro.

Las tablas deberan contener datos representativos que sinteticen informacin significativa del trabajo, evitando mostrar datos intermedios que pudieran dificultar la interpretacin del mismo.

Cada tabla debe estar antecedida de un epgrafe que la identifique, enumere y describa brevemente.

Cada tabla debe ser referenciada al menos una vez, a travs de su nmero, de preferencia antes de que aparezca en el documento, como en este caso (tabla 4.1).

Tabla 4.1: Inventario de animales.

Especie	Sexo	Cantidad
palomas	jvenes	20
	adultas	18
conejos	jvenes	5
	adultos	5
gallinas	jvenes	50
	adultas	50
Total		148

Otro ejemplo de tabla en el cual se observa el empleo de color, adem's de la combinacin de columnas se observa en la tabla 4.2

Tabla 4.2: Clasificación de la muestra, por edad.

Edad	Tamaño de las muestras			
	San Lorenzo	Asunción	Villarrica	Encarnación
$e < 20$	93	74	68	87
$19 < e < 40$	52	48	69	70
$39 < e < 60$	47	85	81	64
$59 < e < 80$	28	36	16	23
$79 < e$	9	5	6	12

A veces, como en el caso de la tabla 4.2, el código se vuelve bastante complejo que resulta engorroso obtener en tiempo razonable la apariencia esperada de la tabla. En esos casos; es posible elaborar la tabla en entorno diferente a LaTeX; grabarla como imagen png, o jpg, o pdf; e insertarla enmascarada como tabla para ser contada como una de ellas por el contador de tablas: esto se logra con incluir la imagen dentro del entorno “table”, como se ejemplifica con la tabla 4.3 que sigue.

Tabla 4.3: Imagen de tabla, en reemplazo de la tabla anterior.

Edad	Tamaño de las muestras			
	San Lorenzo	Asunción	Villarrica	Encarnación
$e < 20$	93	74	68	87
$19 < e < 40$	52	48	69	70
$39 < e < 60$	47	85	81	64
$59 < e < 80$	28	36	16	23
$79 < e$	9	5	6	12

# Capítulo 5

## Discusión

- 5.1. Logros alcanzados
- 5.2. Solución del problema de investigacin
- 5.3. Sugerencias para futuras investigaciones



## **Anexo A.**

Los apéndices y anexos resultan útiles para describir con mayor profundidad ciertos materiales, sin distraer la lectura del texto principal del reporte o evitar que rompan con el formato de éste. Algunos ejemplos serían el cuestionario utilizado, un código de programa computacional, análisis estadísticos adicionales, la demostración matemática de un teorema complicado, fotografías testimoniales, etc.

# Referencias bibliográficas

- [1] [En línea]. Disponible: <https://decidesoluciones.es/modelo-de-prediccion-de-demanda-aplicacion-y-beneficios/>
- [2] Raúl Pino Díez, Alberto Gómez Gómez, y Nicolás de Abajo Martínez, *Introducción a la inteligencia artificial: sistemas expertos, redes neuronales artificiales y computación evolutiva*. Universidad de oviedo, 2001.
- [3] Raquel Flórez López y José Miguel Fernández Fernández, *Las redes neuronales artificiales*. Netbiblo, 2008.
- [4] Jimmy Alexander Romero Miranda, Víctor Alberto Lizcano Portilla *et al.*, “Predicción de ventas futuras,” 2021.
- [5] Ana Ortega Marqués, Sandy Patricia Padilla Domínguez, Johana Isabel Torres Durán, y Alexander Ruz Gómez, “Nivel de importancia del control interno de los inventarios dentro del marco conceptual de una empresa,” *Liderazgo estratégico*, vol. 7, no. 1, pp. 71–82, 2017.
- [6] Kenneth E Kendall y Julie E Kendall, *Análisis y diseño de sistemas*. Pearson educación, 2005, obtenido el 20 de mayo de 2023 de. [En línea]. Disponible: [https://scholar.google.es/scholar?hl=es&as\\_sdt=0%2C5&q=K.+E.+Kendall+y+J.+E.+Kendall%2C+An%C2%B4alisis+y+dise%C2%B4on%2C+2005&btnG=](https://scholar.google.es/scholar?hl=es&as_sdt=0%2C5&q=K.+E.+Kendall+y+J.+E.+Kendall%2C+An%C2%B4alisis+y+dise%C2%B4on%2C+2005&btnG=)
- [7] Xabier Basogain Olabe, “Redes neuronales artificiales y sus aplicaciones,” *Publicaciones de la Escuela de Ingenieros*, 1998.
- [8] César Pérez López y Daniel Santin González, *Minería de datos. Técnicas y herramientas: técnicas y herramientas*. Ediciones Paraninfo, SA, 2007.
- [9] Beatriz Beltrán Martínez, “Minería de datos,” *Cómo hallar una aguja en un pajar. Ingenierías*, vol. 14, no. 53, pp. 53–66, 2001.

- [10] Alkis Simitsis y Panos Vassiliadis, “A method for the mapping of conceptual designs to logical blueprints for etl processes,” *Decision Support Systems*, vol. 45, no. 1, pp. 22–40, 2008, data Warehousing and OLAP. [En línea]. Disponible: <https://www.sciencedirect.com/science/article/pii/S0167923606002065>
- [11] Alexander Bustamante Martínez, Ernesto Amaru Galvis Lista, y Luis Carlos Gómez Flórez, “Técnicas de modelado de procesos de etl: una revisión de alternativas y su aplicación en un proyecto de desarrollo de una solución de bi,” *Scientia et technica*, vol. 18, no. 1, pp. 185–191, 2013.
- [12] Rodolfo H Villarroel, Yessica M Gómez, y Constanza B Krause, “Incorporación de seguridad en el modelado conceptual de procesos extracción-transformación-carga,” *Información tecnológica*, vol. 24, no. 6, pp. 101–110, 2013.
- [13] Batta Mahesh, “Machine learning algorithms-a review,” *International Journal of Science and Research (IJSR)*. [Internet], vol. 9, no. 1, pp. 381–386, 2020. [En línea]. Disponible: [https://scholar.google.es/scholar?hl=es&as\\_sdt=0%2C5&q=+machine+learning&btnG=](https://scholar.google.es/scholar?hl=es&as_sdt=0%2C5&q=+machine+learning&btnG=)
- [14] Dennys Fabian Herrera Cofre *et al.*, “Predicción para el mercado de acciones con redes neuronales lstm,” 2020.
- [15] I.B.M. Staff(es). (2017) Machine learning. [En línea]. Disponible: <https://www.ibm.com/mx-es/analytics/machine-learning>
- [16] Ian Goodfellow, Yoshua Bengio, y Aaron Courville, *Deep learning*. MIT press, 2016.
- [17] Carlos Arana, “Redes neuronales recurrentes: Análisis de los modelos especializados en datos secuenciales,” Serie Documentos de Trabajo, Tech. Rep., 2021.
- [18] Vahid Mirjalili y Sebastian Raschka, *Python machine learning*. Marcombo, 2020.
- [19] E De la Rosa Montero, “El aprendizaje profundo para la identificación de sistemas no lineales,” *Centro de Investigación y de estudios avanzados del Instituto Politécnico nacional*, 2014.
- [20] Xavier Basogain, “Redes neuronales artificiales y sus aplicaciones,” *Dpto. Ingeniería de Sistemas y Automática, Escuela Superior*

- de Ingeniería Bilbao. Open Course Ware.*[En línea] disponible en [http://ocw.ehu.es/enseñanzas-tecnicas/redes-neuronales-artificiales-y-sus-aplicaciones/Course\\_listing](http://ocw.ehu.es/enseñanzas-tecnicas/redes-neuronales-artificiales-y-sus-aplicaciones/Course_listing). [Consultada 20-09-2012], 2008.
- [21] Nicolás Sánchez Anzola, “Máquinas de soporte vectorial y redes neuronales artificiales en la predicción del movimiento usd/cop spot intradiario.” *ODEON-Observatorio de Economía y Operaciones Numéricas*, no. 9, 2015.
- [22] Andres Nacelle y E Mizraji, “Redes neuronales artificiales,” *Núcleo de ingeniería biomédica-Universidad de la Republica Uruguay*, 2009.
- [23] Besay Montesdeoca Santana, “Estudios de predicción en series temporales de datos meteorológicos utilizando redes neuronales recurrentes,” B.S. thesis, 2016.
- [24] Samuel Tomas, Oliver Saavedra, y Israel Espinoza, “Predicción del ciclo solar 25 mediante modelos arima y redes neuronales lstm,” *Revista de la Academia Colombiana de Ciencias Exactas, Físicas y Naturales*, 2023.
- [25] Juan José De Lucio Fernández, “Estimación adelantada del crecimiento regional mediante redes neuronales lstm,” *Investigaciones Regionales= Journal of Regional Research*, no. 49, pp. 45–64, 2021.
- [26] Carlos Andrés Sepúlveda Calle y Milton Tarsicio Benavides Posso, “Análisis predictivo de demanda de servicios bajo series temporales,” 2023.
- [27] Haward Miguel Chang Hidalgo, “Comparación de técnicas de estimación basadas en machine learning para predecir costos en los planes de adquisiciones de las entidades públicas del Perú,” 2023.
- [28] Eder Acevedo, Alexei Serna, y Edgar Serna, “Principios y características de las redes neuronales artificiales,” *Desarrollo e innovación en ingeniería*, vol. 173, 2017.
- [29] M Gestal Pose, “Introducción a las redes de neuronas artificiales,” *Departamento de Tecnologías de la Información y las Comunicaciones. Universidad da Coruña*, 2009.
- [30] F Alejandro Nava, *Procesamiento de series de tiempo*. Fondo de cultura económica, 2015.

- [31] Víctor Marcial Condorena Rondón, “Desarrollo de un sistema de control de inventario, para la gestión de compras de materia prima en el rubro de restaurantes,” 2017.
- [32] Nicole Pacheco Allende, “Rediseño del proceso de abastecimiento en el área de compras en dos empresas dedicadas al equipamiento gastronómico,” 2015.
- [33] Gabriel Vinicio Moreano Sánchez, Víctor Hugo Benítez Bravo, Wilmer Albarracín, y Álvaro Gabriel Benítez Bravo, “Sistemas inteligentes y colaborativos de administración global: Caso de estudio; establecimiento gastronómico,” *revistapuce*, 2018.
- [34] María Afanador Jiménez, Silvia Juliana Casadiegos Chaparro, Isabella Campo Maichel, Juan Sebastián Casallas Estrella *et al.*, “Diseño de un modelo de pronóstico de demanda basado en machine learning y un modelo multi-objetivo para planeación de la producción en una industria panificadora,” 2022.
- [35] Jose R SAURA, Ana Reyes-Menéndez, y Pedro PALOS-SANCHEZ, “Un análisis de sentimiento en twitter con machine learning: Identificando el sentimiento sobre las ofertas de# blackfriday,” *Revista Espacios*, vol. 39, no. 42, 2018.
- [36] Edwar Andrés Hincapié Herrera, “Predicción de la demanda usando modelos de machine learning,” 2021.
- [37] Roberto Hernández, C. Fernández, y M. P. Baptista, *Metodología de la investigación*, 5th ed. México D.F.: McGraw-Hill, 2010.