

Universidad Nacional del Este.
Facultad Politécnica.



Sistema de compra inteligente basado en el histórico de ventas.

Valeria Soledad Arevalos Arevalos
y Marcelo Andrés González Arias

Año 2023.

Universidad Nacional del Este
Facultad Politécnica

Carrera Ingeniería de Sistemas.
Cátedra Trabajo Final de Grado II.

Sistema de compra inteligente basado en el histórico de ventas.

Por: **Valeria Soledad Arevalos Arevalos**
y **Marcelo Andrés González Arias**

Profesor Orientador: **Lic. Roberto Alfredo Demestri Rigoni.**

Trabajo final de grado presentado a la Facultad Politécnica de la Universidad Nacional del Este como parte de los requisitos para optar al título de Ingeniero de Sistemas.

Ciudad del Este, Alto Paraná. Paraguay.

Julio 2023

FICHA CATALOGÁFICA
BIBLIOTECA DE LA FACULTAD POLITÉCNICA
DE LA UNIVERSIDAD NACIONAL DEL ESTE

Arevalos Arevalos, Valeria Soledad 1998.
Sistema de compra inteligente basado en el histórico de ventas
González Arias, Marcelo Andrés 1996
Ciudad del Este, Alto Paraná. Año: 2023.
Páginas: <cantidad de páginas>.

Orientador: Lic. Roberto Alfredo Demestri Rigoni.
Área de estudio: Tecnológica.
Carrera: Ingeniería de Sistemas.
Titulación: Ingeniero de Sistemas.
Trabajo Final de Grado. Universidad Nacional del Este,
Facultad Politécnica.

Descriptores: 1. Valeria Arevalos. 2. Marcelo González
Smart purchasing system based on sales history.
Key words: 1. *, 2. *
3. *.

Yo, <nombre del Profesor Orientador>, documento de identidad No. <No. de documento de identidad del Profesor Orientador>, Profesor Orientador del TFG titulado “<título del TFG>”, del Alumno <nombre del Alumno>, documento de identidad No. <No. de documento de identidad del Alumno>, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este; certifico que el mencionado Trabajo Final de Grado ha sido realizado por dicho Alumno, de lo cual doy fe y en mi opinión reúne las condiciones para su presentación y defensa ante la Mesa Examinadora designada por la institución.

<fecha>

<nombre del Profesor Orientador>

Nosotros, los miembros de la Mesa Examinadora del Trabajo Final de Grado titulado “<título del TFG>”, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este, hacemos constar que el citado trabajo ha sido evaluado en fondo y forma por esta Mesa, la que por _____ ha resuelto asignar la calificación _____

Ciudad del Este, ____ de _____ de ____

Profesor _____
Presidente de la Mesa Examinadora

Profesor _____

Miembro de la Mesa Examinadora

Profesor _____

Miembro de la Mesa Examinadora

Escribir aquí la dedicatoria.
Su extensión no debería exceder de una página.

<Escribir aquí los agradecimientos.>
<Su extensión no debería exceder de una página.>

<Escribir aquí el epígrafe (frase u oración favorita).>
<Su extensión no debería exceder de una página.>

Resumen

Este trabajo propone el desarrollo de un sistema inteligente de compras para restaurantes, que se basa en un modelo matemático de predicción de la demanda de insumos. Este modelo utiliza técnicas estadísticas avanzadas y métodos de pronóstico para analizar patrones de consumo pasados y prever con precisión las cantidades de insumos necesarias en el futuro. Además, se incorpora una red neuronal entrenada para mejorar aún más las estimaciones de demanda, permitiendo así reducir el desperdicio de alimentos, optimizar los niveles de inventario y mejorar la eficiencia operativa del restaurante. La metodología de investigación involucra la recopilación y análisis de datos históricos de ventas y compras, así como la exploración de diversas técnicas de pronóstico y algoritmos de redes neuronales. Se llevarán a cabo experimentos para evaluar la eficacia del sistema en términos de reducción de costos y gestión de inventario.

En última instancia, esta tesis busca contribuir al desarrollo de un sistema de compras efectivo que permita a los restaurantes tomar decisiones informadas y oportunas en cuanto a la adquisición de insumos. La combinación de un modelo matemático de predicción de demanda con redes neuronales representa un enfoque innovador para abordar los desafíos de la gestión de inventario en la industria gastronómica, con el objetivo de mejorar la eficiencia y sostenibilidad operativa.

Descriptores: 1. Predicción de la demanda de insumos, 2. Modelo matemático, 3. Redes neuronales artificiales.

Abstract

This work proposes the development of an intelligent purchasing system for restaurants, based on a mathematical demand prediction model. This model utilizes advanced statistical techniques and forecasting methods to analyze past consumption patterns and accurately forecast the quantities of inputs needed in the future. Additionally, a trained neural network is incorporated to further enhance demand estimations, thereby allowing for the reduction of food waste, optimization of inventory levels, and improvement in restaurant operational efficiency. The research methodology involves the collection and analysis of historical sales and purchasing data, as well as the exploration of various forecasting techniques and neural network algorithms. Experiments will be conducted to assess the system's effectiveness in terms of cost reduction, inventory management, and overall customer satisfaction.

Ultimately, this thesis aims to contribute to the development of an effective purchasing system that enables restaurants to make informed and timely decisions regarding input procurement. The combination of a mathematical demand prediction model with neural networks represents an innovative approach to addressing inventory management challenges in the gastronomy industry, with the goal of enhancing operational efficiency and sustainability.

Key words: 1. Input Demand Forecast , 2. Matematical Modelling, 3. Artificial Neural network.

Índice general

Resumen	IX
Abstract	X
Índice de figuras	XII
Índice de tablas	XIII
Acrónimos y símbolos	XIV
1. Introducción	1
1.1. Motivación	2
1.2. Definición del problema	2
1.3. Objetivos	3
1.3.1. General	3
1.3.2. Específico	3
1.4. Hipótesis	3
1.5. Fundamentación	3
1.6. Impacto de la investigación	4
1.7. Organización del trabajo.	4
2. Conceptos fundamentales, teorías y antecedentes	5
2.1. Predicciones de Compras	5
2.1.1. Relación de Demanda y Gestión de Suministro	5
2.1.2. Importancia de la Predicción de Compra de Insumos	5
2.1.3. Factores que Influyen en la Curva de Insumos Deman- dados	8
2.2. Sistema de información	9
2.2.1. Tipos de sistema de información	9
2.3. Tiempos Actuales en las Predicciones de Demanda	12
2.4. Minería de datos	13
2.5. El aprendizaje automático (<i>machine learning</i>)	13

2.6. Aprendizaje supervisado	15
2.7. Aprendizaje no supervisado	16
2.8. Aprendizaje de refuerzo	16
2.9. Redes Neuronales Artificiales	17
2.9.1. Capas de la neurona artificial	19
2.9.2. Modelo de redes neuronales artificiales	20
2.9.3. Arquitectura de una red neuronal	21
2.9.4. Los pesos sinápticos	22
2.10. Perceptron	22
2.10.1. Perceptrón multica	23
2.11. Series de Tiempo	23
2.12. Redes neuronales recurrentes (RNN)	24
2.13. Redes de Memoria Corta y Larga LSTM	24
2.14. Antecedentes	25
3. Método	29
3.1. Enfoque	29
3.2. Descripción de los datos	29
3.3. Librerías de uso común en Mching Learning	31
3.4. Alcance de la investigación cuantitativa	31
3.4.1. Alcance exploratorio.	31
3.4.2. Alcance descriptivo.	31
3.4.3. Alcance correlacional.	32
3.4.4. Alcance explicativo.	32
3.5. Diseño	32
3.6. Lenguajes de programación	35
3.6.1. Python	35
3.6.2. PHP	38
Anexo A.	39
Glosario	39
Anexos	39
Referencias bibliográficas	40

Índice de figuras

2.1. Predicción de demanda a corto, mediano y largo plazo [2]. . .	6
2.2. Proceso de Optimización de inventario [2].	7
2.3. Arquitectura de un sistema experto [5].	12
2.4. flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo	15
2.5. Aprendizaje supervisado [2].	16
2.6. Componentes de una neurona.	19
2.7. Tipos de neuronas artificiales [17].	20
2.8. Aplicación de la Red Perceptron	23
3.1. Diseño procedural.	30

Índice de Tablas

Acrónimos y símbolos

. 5

LAN Local Area Network. 9, 10, 12

SOR Sistema Operativo de Red. 10, 11

. 5

Capítulo 1

Introducción

En el dinámico entorno de la industria gastronómica, la gestión eficiente de recursos se erige como una prioridad estratégica para alcanzar el éxito operativo y financiero. Entre estos recursos, los insumos desempeñan un papel fundamental, y su manejo adecuado no solo impacta la calidad y la consistencia de los platillos ofrecidos, sino también la rentabilidad y sostenibilidad del negocio en su conjunto. En este contexto, emerge la necesidad de desarrollar soluciones innovadoras y tecnológicas que permitan anticipar y ajustar la demanda de insumos de manera inteligente y precisa.

La gestión de un restaurante, es la actividad de dirección coordinada, relacionada con la oferta y el servicio de alimentos y bebidas en empresas de restauración, cumpliendo los requisitos que exige dicha actividad, con el objetivo de satisfacer necesidades y expectativas de sus clientes.

En el contexto actual de competitividad, es común que las empresas de servicios busquen mejorar sus sistemas de gestión, y adopten métodos y principios gerenciales de empresas industriales para aumentar su productividad y calidad. Sin embargo, es importante tener en cuenta que cada tipo de empresa tiene sus particularidades y características únicas que deben ser consideradas para una gestión eficiente.

En el caso de las empresas de servicios de restauración, es esencial estudiar y analizar las características de su actividad, y las particularidades del servicio que ofrecen, para poder aplicar los métodos y principios gerenciales de manera efectiva. Esto permitirá una gestión óptima de la entidad, mejorando los resultados económicos y asegurando la permanencia del negocio.

Entre las particularidades de la actividad de restauración, se pueden mencionar la importancia de la atención al cliente, la gestión de la calidad de los alimentos y bebidas, el manejo adecuado de los costos y la gestión de inventarios, entre otros aspectos. Estas características deben ser consideradas al momento de aplicar métodos de mejora de la productividad y calidad, y

adaptarlos a las necesidades específicas de la empresa de servicios de restauración.

Es cierto que las empresas de restauración constituyen un sistema operativo empresarial que se compone de varios subsistemas interrelacionados que trabajan juntos para lograr los objetivos empresariales. Uno de estos subsistemas es el de compras, que es fundamental para garantizar la eficacia del sistema de aprovisionamiento y, por tanto, para la planificación, producción y servicio.

El subsistema de compras tiene la responsabilidad de satisfacer las necesidades del subsistema de aprovisionamiento, asegurándose de que los abastecedores con los que se firma convenios cumplan con las especificaciones de calidad establecidas por la empresa de restauración. Además, es importante que el subsistema de compras garantice el abastecimiento de los productos necesarios y de alta calidad para la empresa de restauración.

Mediante los sistemas computacionales se logran procesar cada vez más cantidad de información, y realizar cálculos y operaciones, complejas por lo que realizar predicciones con estos sistemas resultan más confiables. Esta precisión puede ser mejorada ampliamente utilizando varias técnicas de predicción.

1.1. Motivación

Mediante la aplicación de técnicas avanzadas de análisis de datos y aprendizaje automático, este sistema proporcionará recomendaciones precisas y estratégicas, contribuyendo así al avance de la inteligencia empresarial y ofreciendo una herramienta eficiente para la toma de decisiones informadas y fundamentadas. El objetivo final es mejorar la eficiencia operativa, reducir costos y alcanzar ventajas competitivas, permitiendo a las empresas adaptarse y prosperar en un entorno comercial dinámico y desafiante.

1.2. Definición del problema

Este sistema debe ser capaz de utilizar el histórico de ventas del local para predecir la demanda futura de los productos, y en consecuencia, realizar las compras de manera más eficiente y rentable para la gerencia del local.

Problema de investigación: *Necesidad de optimizar la gestión de compras de materia prima de un local gastronómico en Ciudad del Este, utilizando sistema inteligente computarizado basado en el histórico de ventas.*

1.3. Objetivos

1.3.1. General

Desarrollar un sistema de compra inteligente basado en histórico de ventas para optimizar la gestión de compras de una empresa gastronómica de Ciudad del Este mediante algoritmos y técnicas de análisis de datos para predecir la demanda de productos en función del comportamiento de los clientes.

1.3.2. Específico

1. Comprender en profundidad la lógica de negocio de la empresa gastronómica para identificar los procesos críticos que deben ser incluidos en el sistema informático a desarrollar.
2. Recabar los requisitos del sistema con los usuarios y partes interesadas.
3. Modelar la lógica del sistema informático, utilizando técnicas y herramientas adecuadas, para garantizar su integridad y eficiencia.
4. Codificar el modelo lógico definido en lenguajes de programación Python y PHP.
5. Depurar los datos cuantitativos recopilados sobre el comportamiento del consumidor.
6. Realizar pruebas de usabilidad, accesibilidad, multiplataforma, y escalabilidad.

1.4. Hipótesis

La implementación de un sistema inteligente en un local gastronómico de Ciudad del Este, posibilitará una gestión de compras cuya eficiencia posibilitará reducir el costo de materia prima en al menos 10 % y predecir al menos con 70 % de acierto, la variedad y cantidad de productos a ser comprados.

1.5. Fundamentación

En el entorno comercial actual, la toma de decisiones basada en información histórica puede ser un factor clave para el éxito de una empresa. Sin embargo, en muchos casos, esta información no se explota adecuadamente y la gestión de datos se convierte en una tarea compleja.

En el caso de una empresa gastronómica, es importante conocer el rendimiento en ventas y controlar los índices que reflejen el desempeño del negocio. Sin embargo, la simple gestión de estos índices no es suficiente, ya que la empresa puede planificar una determinada cantidad de ventas y adquirir una cantidad de materia prima en consecuencia, pero luego no lograr vender todo lo adquirido y mantener un exceso de stock, o incluso tener productos en inventario que no se rotan.

Es por eso que se plantea el desarrollo de una aplicación que permita proyectar las ventas, para tener un presupuesto real de compras que se adapte a la demanda del mercado y evite el exceso de stock o la falta de rotación de inventarios. De esta manera, la empresa podrá tomar decisiones informadas y maximizar su rendimiento.

1.6. Impacto de la investigación

La implementación del sistema inteligente de compra basado en el histórico de ventas permitirá al gerente de la empresa tomar decisiones informadas y estratégicas, lo que se traducirá en un mejor desempeño económico y financiero de la empresa gastronómica.

Además, la investigación realizada para el desarrollo del sistema también tendrá un impacto positivo en otros estudiantes y futuros proyectos, ya que se podrán utilizar los conocimientos y experiencias adquiridos para mejorar otros procesos y aplicaciones en el ámbito empresarial y tecnológico. En consecuencia, la investigación tendrá un impacto significativo tanto en la empresa como en el ámbito académico y profesional.

1.7. Organización del trabajo.

El presente trabajo está organizado de la siguiente manera:

Capítulo 2: Se presentan algunos conceptos relacionados con las predicciones de compras de insumos, cómo funciona la relación de demanda y gestión de suministro de un local gastronómico, por qué es importante la predicción de compra de insumos para el planeamiento futuro tanto a corto, mediano y largo plazo, los factores que influyen en el comportamiento de la curva de insumos demandados y tiempos actuales en las predicciones de demanda.

Capítulo 2

Conceptos fundamentales, teorías y antecedentes

2.1. Predicciones de Compras

La predicción es el proceso de anticipar la cantidad y tipo de insumos que un negocio gastronómico necesitará adquirir en el futuro, con el objetivo de asegurar un suministro adecuado y eficiente.

2.1.1. Relación de Demanda y Gestión de Suministro

La relación de demanda y gestión de suministro se refiere a la interacción entre la cantidad de productos o insumos que los clientes requieren (demanda) y cómo la empresa se asegura de tener suficientes suministros disponibles para satisfacer esa demanda de manera eficiente. En un negocio gastronómico, la gestión de suministros es crucial para evitar situaciones en las que falten ingredientes clave, lo que podría afectar negativamente la calidad del servicio y la satisfacción del cliente.

2.1.2. Importancia de la Predicción de Compra de Insumos

La mayoría de las empresas distribuidoras de productos sufren de manera recurrente al no conocer la cantidad o un aproximado de productos que debería mantener en stock ya que, por un lado, si el stock es demasiado grande se pueden producir pérdidas de mercancía y costos innecesarios de transporte y almacenamiento, por el contrario, si el stock es demasiado pequeño, este será insuficiente para cubrir la demanda de los diferentes productos y se verá

reflejado en la pérdida de clientes [1].

La aplicación de un modelo de predicción para planificar la demanda futura es un proceso circular de mejora continua. Eso significa que el modelo es enriquecido constantemente con datos en tiempo real para realizar predicciones más precisas y generar una planificación más acorde a la realidad [2].



Figura 2.1: Predicción de demanda a corto, mediano y largo plazo [2].

1. Utiliza la **Predicción de la demanda a largo plazo para la planificación estratégica**. Simula y compara diferentes escenarios hipotéticos de demanda, anticipa los cambios de mercado y planifica la contratación futura de recursos.
2. Utiliza la **Predicción de la demanda a corto plazo para la planificación operativa**. Planifica semanalmente las operaciones y recursos del día.
3. Utiliza la **Predicción de la demanda a medio plazo para la planificación táctica**. Conoce las capacidades con meses de antelación y compáralas con las actuales para detectar posibles necesidades.

La predicción de compra de insumos es vital para la planificación a corto, mediano y largo plazo en un negocio gastronómico por varias razones:

1. **Optimización de Inventario:** El inventario tiene como propósito fundamental proveer a la empresa de materiales necesarios, para su continuo y regular desenvolvimiento, es decir, el inventario tiene un papel vital para el funcionamiento acorde y coherente dentro del proceso de producción y de esta forma afrontar la demanda [3].

Al prever la demanda futura, el negocio puede mantener un nivel de inventario óptimo. Comprar en exceso puede llevar al desperdicio de alimentos, mientras que comprar muy poco puede resultar en escasez y pérdida de ventas.

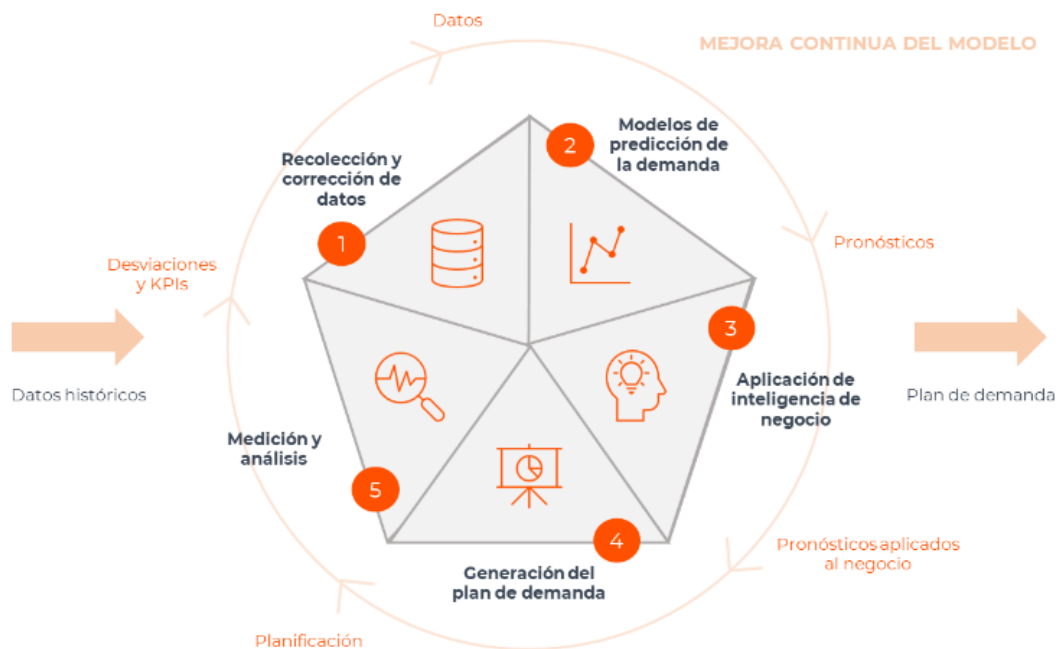


Figura 2.2: Proceso de Optimización de inventario [2].

2. **Reducción de Costos:** Una predicción precisa permite comprar solo lo necesario, lo que reduce los costos asociados con el almacenamiento y la conservación de productos perecederos.

Si se mantienen inventarios demasiado altos, el costo podría llevar a una empresa a tener problemas de liquidez financiera, esto ocurre porque un inventario “parado” inmoviliza recursos que podrían ser mejor utilizados en funciones más productivas de la organización [3].

3. **Eficiencia Operativa:** Saber qué insumos se necesitarán en el futuro permite planificar y programar las operaciones de manera más eficiente, evitando retrasos y problemas logísticos.

Es útil mantener los inventarios en las empresas porque, se tiene en cuenta la capacidad de predicción con el fin de planear la capacidad y establecer un cronograma de producción, también fluctuaciones en la demanda ósea una reserva de inventarios a la mano que supone protección, inestabilidad de los suministros, protección deprecios, descuentos por cantidad, menores costos de pedidos [3].

4. **Satisfacción del Cliente:** Mantener un suministro constante de productos esencial para el negocio, ya que los clientes esperan encontrar su elección preferida en el menú en todo momento.

2.1.3. Factores que Influyen en la Curva de Insumos Demandados

Varios factores pueden influir en el comportamiento de la curva de insumos demandados:

- **Día de la Semana y Estacionalidad:** Los patrones de consumo pueden variar según el día de la semana y la temporada. Por ejemplo, los fines de semana pueden tener una mayor demanda en comparación con los días laborables.
- **Eventos Especiales:** Eventos como días festivos, celebraciones locales o conciertos cercanos pueden aumentar la demanda de alimentos y bebidas.
- **Tendencias de Consumo:** Las tendencias gastronómicas y las preferencias cambiantes de los consumidores pueden afectar la demanda de ciertos productos.
- **Clima:** Las condiciones climáticas también pueden influir en la demanda. Por ejemplo, un día caluroso podría aumentar la demanda de bebidas frías.
- **Promociones y Ofertas:** Las promociones especiales pueden aumentar temporalmente la demanda de ciertos productos.

2.2. Sistema de información

Según [4] el sistema de información *“Es un conjunto de elementos que interactúan entre sí, con el fin de apoyar las actividades de una empresa o negocio”*.

Es importante tener en cuenta que la necesidad de información en las organizaciones es vital para alcanzar el éxito y que un sistema de información debe justificar su implementación desde el punto de vista costo/beneficio, basándose en el valor que se le otorga a la información dentro de la organización [4]. Los beneficios pueden ser tangibles e intangibles, y dependen de los objetivos y necesidades de la organización.

Los sistemas de información se desarrollan para diferentes propósitos, según las necesidades de los usuarios humanos y la empresa. En definitiva, el uso adecuado de la información y la implementación de sistemas de información efectivos pueden marcar una gran diferencia en el éxito de una organización.

2.2.1. Tipos de sistema de información

El propósito de un sistema de información, puede ser muy amplio, todo depende de las necesidades de la organización. Existen distintos tipos de sistemas de información, entre los que destacan los siguientes [4]:

Sistemas de procesamiento de transacciones Se define como transacción un suceso que implica o afecta a una organización, y que está compuesta por datos referentes a ellas y que son de importancia para la organización [4]. Estos sistemas se encargan del procesamiento de los datos referentes a las transacciones, además de permitir la automatización de tareas y procesos operativos.

La información que se obtiene como salida es utilizada posteriormente por los funcionarios de nivel operativo de la organización en la toma de decisiones. Las razones para el procesamiento de las transacciones son:

- **Clasificación:** Implica agrupar todos los datos de acuerdo con características comunes.
- **Operaciones de cálculo:** Consiste en realizar alguna operación para obtener resultados útiles.
- **Ordenamiento:** Consiste en disponerlos de alguna forma o secuencia, facilita el procesamiento y la búsqueda.

- Síntesis: Reduce los datos en información breve y concisa.
- Almacenamiento: Permite el registro de todas y cada una del suceso que afectan a la organización.

Sistema de información administrativa Los sistemas de información administrativa (MIS) no sustituyen a los sistemas de procesamiento de transacciones; más bien, todos los sistemas MIS incluyen el procesamiento de transacciones [4]. Los MIS son sistemas de información computarizados que funcionan debido a la decidida interacción entre las personas y las computadoras.

Al requerir que las personas, el software y el hardware funcionen en conjunto, los sistemas de información administrativa brindan soporte a los usuarios para realizar un espectro más amplio de tareas organizacionales que los sistemas de procesamiento de transacciones, incluyendo los procesos de análisis y toma de decisiones. Para acceder a la información, los usuarios del sistema de información administrativa comparten una base de datos común; esta almacena tanto los datos como los modelos que permiten al usuario interactuar con ellos, interpretarlos y aplicarlos. Los sistemas de información administrativa producen información que se utiliza en el proceso de toma de decisiones. También pueden ayudar a integrar algunas de las funciones de información computarizadas de una empresa.

Sistema de soporte de decisiones Son sistemas de información que tienen como propósito auxiliar al usuario con las decisiones únicas que no se repiten y que no tienen una estructura definida [4]. Además de estar hechos a la medida de la persona o grupo que los usa en comparación con los Sistemas de información Gerencial. El propósito de estos sistemas es el de responder correctamente a condiciones inesperadas y propias de la información. Esto permite que sean empleados en niveles altos de la organización.

Sistema de información gerencial Los Sistemas de Información Gerencial, también llamados Sistemas de Reportes de Gerencia, se dedican al apoyo de decisiones siempre que los requerimientos de información sean identificados, esto es, que la información que necesita para la toma de decisiones haya sido analizada anteriormente, y que esta misma decisión pueda tomarse nuevamente [4]. Estos sistemas pueden extraer la información necesaria de cualquier parte de la organización, por lo que la información necesaria ya se tiene almacenada al ser procesada por un sistema de transacciones.

Sistema experto e inteligencia artificial La inteligencia artificial (IA) puede ser considerada como el campo dominante de los sistemas expertos. La idea general de la IA ha sido desarrollar equipos que se comporten de manera inteligente [4].

Dos ramas de investigación de la IA son:

- La comprensión del lenguaje natural.
- El análisis de la habilidad para razonar un problema y llegar a una conclusión lógica.

Los sistemas expertos utilizan las metodologías de razonamiento de la IA para resolver los problemas que los usuarios de negocios (y otros tipos de usuarios) les presentan. Los sistemas expertos son una clase muy especial de sistema de información que ha demostrado su utilidad comercial gracias a la disponibilidad extendida de hardware y software como las computadoras personales (PC) y las interfaces de sistemas expertos.

Un sistema experto (también conocido como sistema basado en el conocimiento) captura y utiliza en forma efectiva el conocimiento de uno o varios expertos humanos para resolver un problema específico al que una organización se enfrenta. Cabe mencionar que a diferencia de los sistemas DSS, que en última instancia dejan la decisión a la persona encargada de la toma de decisiones, un sistema experto selecciona la mejor solución para un problema o una clase específica de problemas. Los componentes básicos de un sistema experto son la base de conocimiento, un motor de inferencia que conecta al usuario con el sistema mediante el proceso de consultas en lenguajes, como el lenguaje de consulta estructurado (SQL), y la interfaz de usuario. Las personas conocidas como ingenieros del conocimiento capturan la experiencia de los expertos, crean un sistema computacional que incluye este conocimiento y después lo implementan [4].

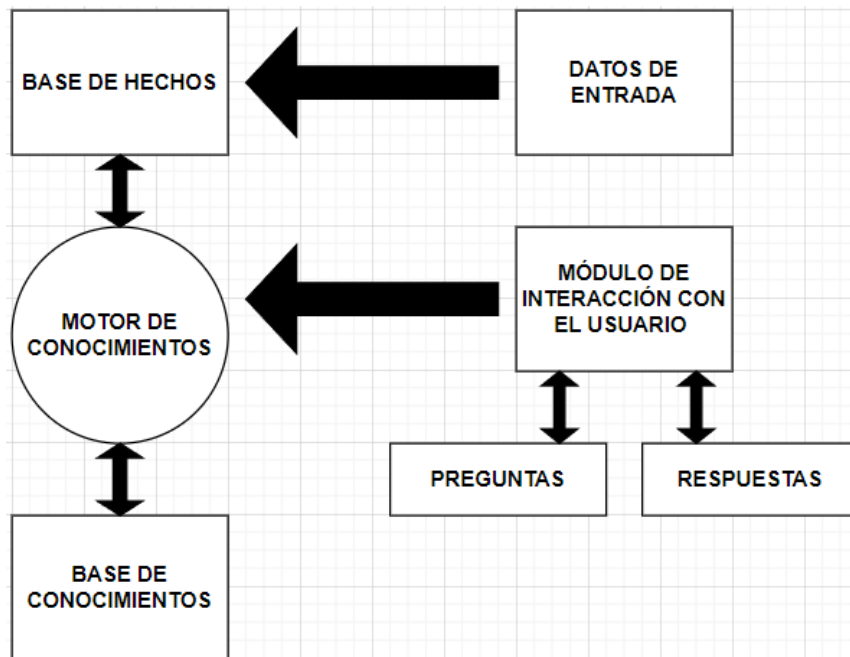


Figura 2.3: Arquitectura de un sistema experto [5].

En los Sistemas Expertos el conocimiento se hace explícito en forma de reglas, en la computación neuronal las ANN generan sus propias reglas aprendiendo de los ejemplos que se les muestran en la fase de entrenamiento [6].

2.3. Tiempos Actuales en las Predicciones de Demanda

En la actualidad, las predicciones de demanda se benefician ampliamente de las tecnologías avanzadas y el análisis de datos. Las empresas pueden aprovechar sistemas de gestión de inventario y software de análisis de datos para recopilar y procesar información histórica y en tiempo real. Estas herramientas les permiten aplicar técnicas estadísticas y modelos de pronóstico para anticipar con mayor precisión los patrones de demanda futura.

En tiempos recientes, se ha observado la aplicación de diversas técnicas en el campo de la inteligencia artificial, como sistemas expertos, y más recientemente, algoritmos genéticos. Sin embargo, a pesar de esta evolución, los modelos que han captado una atención destacada son los basados en Redes Neuronales Artificiales (RNAs). Con el transcurso del tiempo, se han

desarrollado múltiples arquitecturas de RNAs para abordar una variedad de problemas en el ámbito de la predicción de demanda.

2.4. Minería de datos

La minería de datos puede definirse inicialmente como un proceso de descubrimiento de nuevas y significativas relaciones, patrones y tendencias al examinar grandes cantidades de datos [7].

El análisis de datos, potenciado por herramientas informáticas, ha dado lugar a la minería de datos. Esta disciplina busca descubrir automáticamente conocimiento en grandes bases de datos, identificando patrones, tendencias y perfiles a través de tecnologías avanzadas como el reconocimiento de patrones, redes neuronales y algoritmos genéticos.

Inicialmente, los sistemas de información se centraban en recopilar datos para apoyar la toma de decisiones. Con la informatización de las organizaciones, se amplió su función para respaldar los procesos esenciales. Ahora, se buscan prestaciones adicionales, como sistemas de información para la toma de decisiones.

La Minería de Datos se puede ubicar en el nivel más alto de la evolución de los procesos tecnológicos de análisis de datos [8].

2.5. El aprendizaje automático (*machine learning*)

Según Arthur Samuel, el aprendizaje automático se define como el campo de estudio que otorga a las computadoras la capacidad de aprender sin ser programadas explícitamente [9].

El aprendizaje automático se utiliza para enseñar a las máquinas a manejar los datos de manera más eficiente. A veces, después de ver los datos, no podemos interpretar la información extraída de los mismos. En ese caso, aplicamos el aprendizaje automático.

Es decir, el aprendizaje automático como área de las ciencias computacionales aplicadas, desarrolla algoritmos capaces de tomar datos numéricos y alfanuméricos almacenados en un computador [10].

Con la abundancia de conjuntos de datos disponibles, la demanda de aprendizaje automático está en aumento. Muchas industrias aplican el aprendizaje automático para extraer datos relevantes. El propósito del aprendizaje automático es aprender de los datos. Se han realizado muchos estudios sobre cómo hacer que las máquinas aprendan por sí mismas sin ser programadas

explícitamente. Muchos matemáticos y programadores aplican varios enfoques para encontrar la solución a este problema que implica conjuntos de datos enormes [9].

El Aprendizaje Automático se basa en diferentes algoritmos para resolver problemas de datos. A los científicos de datos les gusta señalar que no existe un único tipo de algoritmo que sea universal y mejor para resolver todos los problemas. El tipo de algoritmo utilizado depende del tipo de problema que se desee resolver, el número de variables, el tipo de modelo que se adapte mejor, entre otros factores.

Las técnicas de machine learning son necesarias para mejorar la precisión de los modelos predictivos. Dependiendo de la naturaleza del problema empresarial que se está atendiendo, existen diferentes enfoques basados en el tipo y volumen de los datos [11].

En el contexto de la aplicación de algoritmos de Machine Learning en el cálculo de pronósticos de demanda, es esencial comprender que el objetivo principal de estos algoritmos es encontrar una función que tome un conjunto de variables como entrada y produzca una estimación del valor deseado, en este caso, la demanda. Esta función se ajusta a través del aprendizaje a partir de observaciones pasadas donde los datos de demanda son conocidos. Por ejemplo, utilizando datos de demanda de los últimos años, el modelo se entrena para desarrollar una función que pueda hacer predicciones precisas sobre la demanda futura, lo que implica una tarea de regresión, ya que el resultado esperado es un valor numérico real. Esta metodología se basa en el libro “Deep Learning” de Ian Goodfellow, Yoshua Bengio y Aaron Courville [12].

Una forma común de describir a un conjunto de datos u observaciones (dataset) es con una matriz de diseño. Una matriz de diseño es una matriz que contiene un ejemplo diferente en cada fila. Cada columna de la matriz corresponde a una característica diferente. Los algoritmos de aprendizaje se diferencian en función de la forma de operar y procesa los datos contenidos en una matriz de diseño [13].

El siguiente diagrama muestra un flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo [14]:

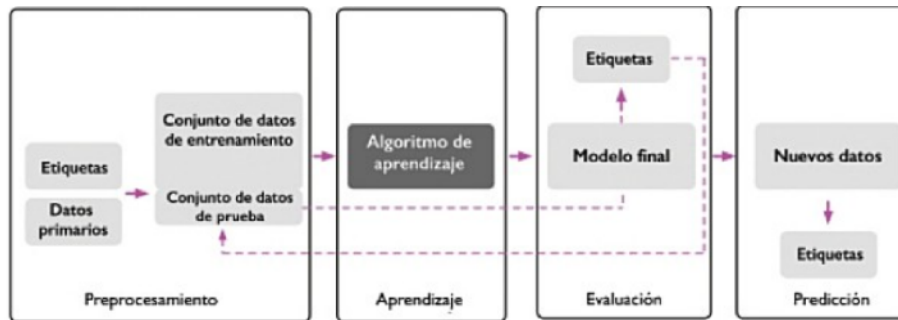


Figura 2.4: flujo de trabajo típico para el uso del aprendizaje automático en modelado predictivo

Procesamiento:

- Extracción y escalado de características.
- Selección de características.
- Reducción de la dimensionalidad.
- Muestreo.

Aprendizaje:

- Selección del modelo.
- Validación cruzada.
- Medición del rendimiento.
- Optimización de hiperparametro.

2.6. Aprendizaje supervisado

El aprendizaje supervisado comienza típicamente con un conjunto establecido de datos y una cierta comprensión de cómo se clasifican estos datos. El aprendizaje supervisado tiene la intención de encontrar patrones en datos que se pueden aplicar a un proceso de analítica. Estos datos tienen características etiquetadas que definen el significado de los datos. Por ejemplo, se puede crear una aplicación de machine learning con base en imágenes y descripciones escritas que distinga entre millones de animales [11].

El objetivo principal del aprendizaje supervisado es aprender un modelo, a partir de datos de entrenamiento etiquetados, que nos permite hacer predicciones sobre datos futuros o no vistos [14]. Aquí, el término supervisado se refiere a un conjunto de muestras donde las señales de salida deseadas (etiquetas) ya se conocen.




Figura 2.5: Aprendizaje supervisado [2].

2.7. Aprendizaje no supervisado

El aprendizaje no supervisado se utiliza cuando el problema requiere una cantidad masiva de datos sin etiquetar. Por ejemplo, las aplicaciones de redes sociales, tales como Twitter, Instagram y Snapchat, tienen grandes cantidades de datos sin etiquetar. La comprensión del significado detrás de estos datos requiere algoritmos que clasifican los datos con base en los patrones o clústeres que encuentra. El aprendizaje no supervisado lleva a cabo un proceso iterativo, analizando los datos sin intervención humana [11].

Los métodos de aprendizaje no supervisados son utilizados durante el preprocesamiento de los datos antes de ser utilizados por algoritmos de característica supervisada. Estos algoritmos también son muy utilizados en la compresión de datos. Todos los métodos son implícita o explícitamente basados en la distribución de probabilidad en el espacio definido por las variables de entrada [15].

2.8. Aprendizaje de refuerzo

El aprendizaje de refuerzo es un modelo de aprendizaje conductual. El algoritmo recibe retroalimentación del análisis de datos, conduciendo el usuario

hacia el mejor resultado. El aprendizaje de refuerzo difiere de otros tipos de aprendizaje supervisado, porque el sistema no está entrenado con el conjunto de datos de ejemplo. Más bien, el sistema aprende a través de la prueba y el error. Por lo tanto, una secuencia de decisiones exitosas conduce al fortalecimiento del proceso, porque es el que resuelve el problema de manera más efectiva [11].

2.9. Redes Neuronales Artificiales

Las Redes Neuronales Artificiales (RNA) son un componente esencial de la Inteligencia Artificial que emula el funcionamiento de las neuronas biológicas. Estas redes, entrenadas con entradas de escenarios internos o externos multiplicadas por pesos aleatorios, destacan en la resolución de funciones altamente no lineales, lo que las convierte en herramientas poderosas para la predicción. Inspiradas en el sistema nervioso biológico, encuentran aplicaciones en áreas como neurociencias, matemáticas, estadísticas y más. Su capacidad para aprender de datos de entrada las hace especialmente valiosas en la predicción de patrones complejos en diversos campos, como finanzas, ciencia de datos y análisis de mercado.

Es un algoritmo basado en una red de alimentación de múltiples capas entrenadas inspirado en las neuronas del cerebro humano, estos sistemas aprenden y se forman a sí mismos ya que sus neuronas artificiales están conectadas, en lugar de ser programados de forma explícita [10].

En el desarrollo de una red neuronal no hay que programar ni el conocimiento ni las reglas del procesamiento del conocimiento. La red neuronal aprende las reglas del procesamiento del conocimiento mediante el ajuste de las conexiones ponderadas entre las neuronas de distintas capas de la red. El aprendizaje se consigue a través de una regla de aprendizaje que adapta o cambia los pesos de las conexiones en respuesta a los ejemplos de entrada, y opcionalmente también en respuesta a las salidas deseadas. Esta característica de las ANN es lo que permite decir que las redes neuronales aprenden de la experiencia [6].

La neurona artificial fue diseñada para “emular” las características del funcionamiento básico de la neurona biológica [16]. En esencia, se aplica un conjunto de entradas a la neurona, cada una de las cuales representa una salida de otra neurona. Cada entrada se multiplica por su “peso” o ponderación correspondiente análogo al grado de conexión de la sinapsis. Todas las entradas ponderadas se suman y se determina el nivel de excitación

o activación de la neurona.

Representación vectorial del funcionamiento básico de una neurona artificial se indica según la siguiente expresión de la ecuación.

$$NET = X \cdot W$$

Siendo NET la salida, X el vector de entrada y W el vector de pesos.

La representación del modelo matemático es el siguiente

$$y = H \left(\sum_{j=1}^n w_j x_j - u \right) \quad (2.1)$$

Donde H es la función de activación (en este caso la función escalón de Heaviside) con el umbral u , x_j es la señal de entrada y w_j es el peso asociado con $j = 1, 2, \dots, n$, donde n corresponde al número de entradas. La salida de esta unidad es 1 cuando la suma está por encima del umbral u , y es 0 en caso contrario [13].

El elemento fundamental de los sistemas neuronales biológicos es la neurona, una célula viva que, como tal contiene todos los elementos que integran las células biológicas, si bien incorpora otros elementos que la diferencian (Figura 2.6). De forma genérica, una neurona consta de un cuerpo celular o soma más o menos esférico (de entre 10 y 80 micras de longitud), del que parten una rama principal o axón (cuya longitud varía desde las 100 micras hasta el metro en el caso de las neuronas motoras que constituyen los nervios) y un denso árbol de ramificaciones más cortas (árbol dendrítico), compuesto por dendritas. A su vez, el axón puede ramificarse en su punto de arranque, y con frecuencia presenta múltiples ramas en su extremo. La forma final de la neurona depende de la función que cumple, esto es, de la posición que ocupa en el conjunto del sistema y de los estímulos que recibe [17].




Figura 2.6: Componentes de una neurona.

2.9.1. Capas de la neurona artificial

Desde un punto de vista funcional, las neuronas constituyen procesadores de información sencillos, integrados por: Un canal de recepción de información, las dendritas, que reciben señales de entrada (inputs) procedentes de otras células (interneuronas) o del exterior (neuronas receptoras o sensoras, como los conos y bastones de la retina) [18].

Un órgano de cómputo, el soma, que combina e integra los inputs recibidos (generalmente a través de funcionales no lineales), emitiendo señales de salida en forma de estímulos nerviosos [18].

Un canal de salida, el axón, que envía la salida generada por el soma a otras neuronas o bien, en el caso de las neuronas motoras, directamente al músculo. Para transmitir la información, el axón se conecta a través de sus ramificaciones a las dendritas de otras neuronas, que reciben las señales y las combinan para producir nuevas salidas. Una neurona del córtex cerebral recibe información, por término medio, de unas 10.000 neuronas (convergencia), y envía impulsos a varios cientos de ellas (divergencia) [18].




Figura 2.7: Tipos de neuronas artificiales [17].

Características de tres tipos de neuronas artificiales: unidades de entrada, de salida y unidades ocultas(Figura 2.7) [17].

- Las neuronas de entrada reciben señales desde el entorno, provenientes de sensores o de otros sectores del sistema (como archivos de almacenamiento de patrones de aprendizaje).
- Las neuronas de salida envían su señal directamente fuera del sistema una vez finalizado el tratamiento de la información (salidas de la red).
- Las neuronas ocultas reciben estímulos y emiten salidas dentro del sistema, sin mantener contacto alguno con el exterior. En ellas se lleva a cabo el procesamiento básico de la información, estableciendo la representación interna de ésta.

2.9.2. Modelo de redes neuronales artificiales

Las redes neuronales artificiales son motivadas por ciertas cualidades de su modelo real, por lo cual el desafío es producir un modelo que tenga [19]:

- Una estructura de procesamiento distribuida y paralela (opuestamente al CPU de una computadora).

La arquitectura de las ANN parte de la organización de los sistemas de procesado en paralelo, es decir, sistemas en los que distintos procesadores están interconectados. No obstante los procesadores son unidades procesadoras simples, diseñadas para la suma de muchas entradas y con un ajuste automático de las conexiones ponderadas.

- Alto grado de conexion entre las unidades basicas.

- Conexiones modificables en función de la experiencia.
- Un proceso de aprendizaje constante y de ser posible uno no supervisado
- Aprendizaje basado en información local.
- Robustez en la performance si algunas unidades son removidas.

2.9.3. Arquitectura de una red neuronal

La topología o arquitectura hace referencia a la organización y disposición de las neuronas en la red formando capas de procesadores interconectados entre sí a través de sinapsis unidireccionales. La arquitectura de una RNA depende de cuatro parámetros principales [17]:

- el número de capas,
- el número de neuronas por capa,
- el grado de conectividad entre las neuronas y
- el tipo de conexiones neuronales.

Las arquitecturas neuronales pueden clasificarse atendiendo a distintos criterios [17]:

- Según su estructura en capas
 - Redes monocapa, compuestas por una única capa de neuronas, entre las que se establecen conexiones laterales y, en ocasiones, autorrecurrentes. Este tipo de redes suele utilizarse para la resolución de problemas de autoasociación y clusterización.
 - Redes multicapa (layered networks), cuyas neuronas se organizan en varias capas (de entrada, oculta(s) y de salida). La capa a la que pertenece la neurona puede distinguirse mediante la observación del origen de las señales que recibe y el destino de la señal que genera.
- Según el flujo de datos en la red

- Redes unidireccionales o de propagación hacia adelante (feedforward), en las que ninguna salida neuronal es entrada de unidades de la misma capa o de capas precedentes. La información circula en un único sentido, desde las neuronas de entrada hacia las neuronas de salida de la red.
- Redes de propagación hacia atrás (feedback), en las que las salidas de las neuronas pueden servir de entradas a unidades del mismo nivel (conexiones laterales) o de niveles previos. Las redes de propagación hacia atrás que presentan lazos cerrados se denominan sistemas recurrentes.

2.9.4. Los pesos sinápticos

A una neurona artificial se le asigna un peso sináptico a las entradas que provienen desde otras neuronas. Este procedimiento es similar al que se realiza en una neurona de un ser humano, a lo que normalmente en la medicina se le conoce como sinapsis. El peso sináptico entonces es un valor numérico y que puede ir cambiando durante la fase de entrenamiento [20]. Este peso hace que la red neural tenga una utilidad y es allí donde se almacena la información.

En una red de neuronas existe un peso o fuerza sináptica que va a ser un valor numérico que pondera las señales que se reciben por sus entradas. Este peso será un valor que determina la fuerza de conexión entre 2 neuronas. Cuando se evalúa una neurona se debe calcular el conjunto de todas las fuerzas o valores (denominado NET) que se reciben por sus entradas. Una vez calculado el valor conjunto de todas las entradas se aplica una función de activación (FA) que determinará el valor del estado interno de la neurona y que será lo que se transmita a su salida [21].

2.10. Perceptron

En 1957, Frank Rosenblatt publicó el mayor trabajo de investigación en computación neuronal realizado hasta esas fechas. Su trabajo consistía en el desarrollo de un elemento llamado “Perceptron” [6].

El perceptron es un sistema clasificador de patrones que puede identificar patrones geométricos y abstractos. El primer perceptron era capaz de aprender algo y era robusto, de forma que su comportamiento variaba sólo si resultaban dañados los componentes del sistema. Además presentaba la característica de ser flexible y comportarse correctamente después de que

algunas celdas fueran destruidas. El perceptron fue originalmente diseñado para el reconocimiento óptico de patrones. Una rejilla de 400 fotocélulas, correspondientes a las neuronas de la retina sensibles a la luz, recibe el estímulo óptico. Estas fotocélulas están conectadas a elementos asociativos que recogen los impulsos eléctricos emitidos desde las fotocélulas. Las conexiones entre los elementos asociativos y las fotocélulas se realizan de forma aleatoria. Si las células presentan un valor de entrada superior a un umbral predeterminado entonces el elemento asociativo produce una salida [6].




Figura 2.8: Aplicación de la Red Perceptron

2.10.1. Perceptrón multicapa

Una Perceptrón multicapa (MLP) puede ser interpretada como una extensión del algoritmo de regresión logística donde primero la entrada es transformada utilizando una transformación no lineal [15]. El propósito de esta transformación es proyectar los datos de entrada a un espacio donde sean linealmente separables. Esta capa intermedia es conocida como capa oculta y es característica de una MLP poseer dos o mas de ellas. Una capa oculta única es suficiente para hacer de una MLP un aproximador universal.

2.11. Series de Tiempo

Las series de tiempo, son datos estadísticos que se recopilan, observan o registran en intervalos de tiempo regulares (diario, semanal, semestral, anual, entre otros) [10].

Conviene recalcar que una serie de tiempo es un conjunto ordenado de valores, no una función, y que no debe ser tratada como tal [22].

2.12. Redes neuronales recurrentes (RNN)

Las redes neuronales recurrentes (RNNs) son un tipo de modelo de aprendizaje profundo que se utiliza para analizar datos secuenciales, como el procesamiento del lenguaje natural o la predicción de series de tiempo [23].

A diferencia de las redes neuronales artificiales ya vistas, que asumen la independencia entre los datos de entrada, las RNN capturan activamente sus dependencias secuenciales y temporales [13].

Las RNN generalmente aumentan la arquitectura de red multicapa convencional con la adición de ciclos que conectan nodos adyacentes o pasos de tiempo.

Estos ciclos constituyen la memoria interna de la red que se utiliza para evaluar las propiedades del dato actual con respecto a los datos del pasado inmediato.

Sin embargo, la capacidad de las RNNs para manejar datos a largo plazo se ve comprometida por el problema del gradiente que desaparece, que ocurre cuando el gradiente se hace cada vez más pequeño a medida que se propaga hacia atrás en la red [23].

Para superar este problema, Hochreiter & Schmidhuber, propusieron la memoria a corto y largo plazo (LSTM), una variante de las RNNs que ha demostrado ser efectiva para el procesamiento de datos secuenciales a largo plazo [23].

2.13. Redes de Memoria Corta y Larga LSTM

Las redes de “larga memoria de corto plazo” (LSTM, por sus siglas en inglés Long Short-Term Memory) propuestas por Hochreiter y Schmidhuber. Es una de las arquitecturas de aprendizaje profundo más avanzadas y exitosas para predicción de series temporales, reconocimiento de escritura y análisis de discurso [24].

El modelo matemático de LSTM se define como una función no lineal que transforma la entrada actual, el estado anterior y la memoria a largo plazo en una salida y un estado actualizado.

El cálculo de esta función implica la operación de multiplicación de matrices y la aplicación de funciones de activación, como la función sigmoide o la tangente hiperbólica [23].

El objetivo es mejorar la memoria de la RNN de los eventos pasados entrenándola para que recuerde lo importante y olvide el resto. Para ello, las LSTM procesan dos versiones del pasado [13].

2.14. Antecedentes

En el proyecto titulado ***“Desarrollo de un Sistema de Control de Inventario para la Gestión de Compras de Materia Prima en el Rubro de Restaurantes”*** [25]. Se empleó el modelo de desarrollo de ciclo de vida en cascada para desarrollar un sistema de control de inventario para un restaurante con el objetivo de mejorar la gestión de los procesos de almacén y reducir los tiempos innecesarios en la entrega del producto final al cliente. El sistema se divide en los módulos de almacén, que ofrecen diferentes funcionalidades para el desarrollo y gestión del restaurante. Como resultado, el sistema moderniza los procesos de la empresa en el rubro de restaurantes, aportando una mejora significativa en la gestión y reducción de tiempos innecesarios en el almacén.

Este antecedente presenta un estudio de caso relevante en el ámbito de la gestión de inventario y compras en la industria de restaurantes. Se describe cómo se implementó con éxito un sistema de control de inventario utilizando el modelo de desarrollo de ciclo de vida en cascada. El objetivo principal de esta implementación fue mejorar la gestión de los procesos de almacén y reducir los tiempos innecesarios en la entrega de productos a los clientes. El sistema se dividió en módulos específicos, centrándose en el almacén y ofreciendo diversas funcionalidades para la gestión eficiente del restaurante. Los resultados obtenidos demuestran una modernización efectiva de los procesos de la empresa en el rubro de restaurantes, con mejoras significativas en la gestión y una reducción sustancial de los tiempos de almacenamiento. Este antecedente sirve como base para la presente tesis, que se enfoca en el desarrollo de un sistema de compra inteligente basado en el historial de ventas, aprovechando la experiencia exitosa de la implementación previa para impulsar la eficiencia operativa en la industria de alimentos

En el trabajo titulado ***“Optimización de la cadena de abastecimiento a través de un sistema inteligente de pronósticos de demanda y gestión de inventario multiproducto”*** [26]. Se propone un método de seis pasos para optimizar el área de compras y reducir costos en dos empresas del sector gastronómico: EV e IS. El objetivo general del proyecto es construir una aplicación web que semiautomatice las actividades del área de compras y optimice la cadena de abastecimiento a través de un sistema inteligente de pronósticos de demanda y gestión de inventario multiproducto. Se logró una mejora en los errores de pronóstico de 22 % en 2 meses, 16 % en 8 meses y 10 % en 12 meses. Los resultados económicos indican un VAN de \$61 millones en 3 años y una TIR de 280 %.

El objetivo principal del proyecto fue desarrollar una aplicación web que automatizara parcialmente las actividades del área de compras y mejorara la cadena de abastecimiento mediante un sistema inteligente de pronósticos de demanda y gestión de inventario multiproducto. Este antecedente se presenta como una sólida prueba de concepto para la implementación de sistemas inteligentes de gestión de compras basados en pronósticos de demanda en la industria gastronómica, lo que respalda y valida la relevancia de la presente tesis sobre un sistema de compra inteligente basado en historial de ventas.

En el artículo titulado ***“Plan de gestión para la creación de una plataforma tecnológica en un establecimiento gastronómico”*** [27]. Los autores proponen la implementación de una plataforma tecnológica en un restaurante, combinando metodologías de gestión tradicionales y ágiles. El objetivo es mejorar la eficiencia y eficacia en las tareas de atención, supervisión, control y administración del establecimiento gastronómico. La metodología SCRUM se utilizará para la gestión del desarrollo, utilizando las estimaciones previas como métricas de evolución para identificar posibles retrasos e inconvenientes. El plan de proyecto estima los alcances, costos y duración de las tareas de desarrollo, definiendo planes de gestión de calidad y mitigación de riesgos. La combinación de metodologías utilizada busca generar una solución eficiente para la administración del desarrollo de la plataforma tecnológica.

El plan de proyecto detalla estimaciones de alcance, costos y duración de las actividades de desarrollo, y establece planes para la gestión de calidad y mitigación de riesgos. La combinación de enfoques metodológicos adoptada en este proyecto busca ofrecer una solución eficaz para la administración y desarrollo exitoso de la plataforma tecnológica en el contexto de la industria gastronómica.

El artículo ***“Reducing Food Waste in the Food Industry with Deep Learning”*** [28]. Escrito por Esteban David Romero Pérez aborda el objetivo de reducir el desperdicio de alimentos en la industria alimentaria utilizando la tecnología de Deep Learning. El enfoque del artículo es ayudar a la industria alimentaria a predecir la cantidad de platos que se pueden vender en una semana específica, lo que ayudará a minimizar los desperdicios de alimentos y cumplir con el objetivo número 12 de la Organización de las Naciones Unidas para el desarrollo sostenible. Los resultados obtenidos muestran una disminución significativa en la cantidad de alimentos desperdiciados en la industria alimentaria, lo que contribuye a un futuro más sostenible.

El autor, Esteban David Romero Pérez, se centra en la importante tarea de ayudar a la industria alimentaria a anticipar con precisión la demanda de sus productos y, por lo tanto, reducir los excedentes no vendidos, lo que está alineado con el Objetivo de Desarrollo Sostenible número 12 de las Naciones Unidas. Los resultados obtenidos en este estudio demuestran de manera convincente que la aplicación de Deep Learning puede conducir a una disminución sustancial en la cantidad de alimentos desperdiciados en la industria alimentaria, contribuyendo significativamente a un futuro más sostenible y eficiente en el uso de recursos. Este antecedente resalta la relevancia de la tecnología de aprendizaje profundo en la optimización de procesos en la industria alimentaria, lo que puede ser de gran utilidad para el enfoque de la presente tesis.

En un estudio llevado a cabo en Móstoles, España titulado ***“Un análisis de sentimiento en Twitter con Machine Learning: Identificando el sentimiento sobre las ofertas de #BlackFriday”*** [29]. Se estableció una conexión con la API de Twitter para recopilar un total de 2204 tweets relacionados con los comentarios e interacciones de los usuarios acerca de las ofertas proporcionadas por empresas en la muestra. Posteriormente, se aplicó un algoritmo de análisis de sentimiento desarrollado en Python utilizando la biblioteca MonkeyLearn para categorizar estos tweets en positivos y negativos. Se centró en evaluar la percepción de los usuarios sobre las ofertas del Black Friday a través del análisis automatizado de los comentarios en Twitter.

Tesis ***“Predicción de la demanda usando modelos de machine Learning”*** [30] Para aquellas empresas dedicadas a la venta en retail o venta directa donde su portafolio de productos es muy amplio, la planeación de la demanda se convierte en un área determinante para la correcta administración del flujo de caja, rentabilidad y efectividad en ventas por varias razones: la primera de ellas es la gestión de compra de insumos por medio de negociación de precio por volumen con sus proveedores; el control de inventario donde se cuida un equilibrio entre uso efectivo del espacio de almacenamiento y reducción de obsolescencia contra la disponibilidad para distribución y por último en la venta efectiva respetando las estacionalidades, tendencias del mercado y satisfacción del cliente.

La planeación de la demanda en empresas minoristas con una amplia gama de productos es crucial para gestionar la compra de insumos, controlar el inventario y maximizar las ventas. Se emplean modelos de regresión, como Random Forest Regressor y H2O AutoML, junto con análisis de tipicidad,

para predecir con precisión las unidades de productos a vender y optimizar la gestión de categorías, lo que mejora la eficiencia y rentabilidad.

Tesis “*Estudios de predicción en series temporales de datos meteorológicos utilizando redes neuronales recurrentes*” [31] En los últimos años, en el campo de las energías renovables, la energía eólica ha sido una de las que mas se ha desarrollado e invertido. La importancia de las predicciones de viento radica en la ayuda que aportan para planificar y anticiparse a los valores futuros que afectarán al sistema, ayudando a gestionar la adquisición de los recursos necesarios con antelación suficiente. Recientemente se han desarrollado nuevas arquitecturas de redes recurrentes que resultan muy prometedoras para realizar predicción. En este trabajo se probará y experimentará con dichas arquitecturas para realizar distintas predicciones de la velocidad del viento en un horizonte de corto y muy corto plazo a partir de datos de series temporales de viento.

Capítulo 3

Método

En esta sección, se describirán los métodos utilizados para llevar a cabo la investigación sobre la predicción de compras a partir de un historial de ventas.

3.1. Enfoque

El desarrollo de un sistema de compras inteligentes que utiliza un historial de ventas como fuente principal de información. El objetivo principal es optimizar la gestión de insumos gastronómicos.

- Recopilación y análisis de datos cuantitativos de ventas históricas para desarrollar un modelo predictivo. Esto abarcaría la identificación de patrones de ventas, el uso de algoritmos de aprendizaje automático para predecir futuras compras y la evaluación de la precisión del sistema.
- Aplicación de métricas cuantitativas para evaluar el rendimiento del sistema en términos de eficiencia, impacto en las ventas y beneficios para la entidad objeto de estudio.

3.2. Descripción de los datos

Se empleó un conjunto de datos recopilados a partir del número diario de productos vendidos, obtenido de la empresa gastronómica que provee los datos para el análisis y predicción de la misma, es importante destacar que el conjunto de datos es continuamente actualizado, sin embargo, para los propósitos de esta investigación, se consideró un conjunto de datos con XXX registros que cubren el período desde MES de XXX hasta MES de XXX.

Posteriormente, se dividió el conjunto de datos en dos grupos: entrenamiento y validación. El grupo de entrenamiento comprendió XXX registros que cubren desde MES de XXX hasta MES de XXX. El grupo de validación incluyó XXX registros, desde MES de XXX hasta MES de XXX.

Lista de requisitos:

- Registro de productos (Alta, Baja, Modificaciones).
- Registro de insumos(materia prima) (Alta, Baja,Modificaciones).
- Registro de pedidos/ventas (Alta, Baja, Modificaciones).
- Generación de Informes Personalizados: Debe permitir la creación de informes personalizados que muestren datos específicos para análisis.
- Análisis de Tendencias: Debe ser capaz de identificar tendencias y patrones en las ventas de insumos, lo que facilita la toma de decisiones basadas en datos.




Figura 3.1: Diseño procedural.

3.3. Librerías de uso común en Mching Learning

A continuación se instalara y actualizaran las principales librerías mas utilizadas cuando se realizan programas de inteligencia artificial

3.4. Alcance de la investigación cuantitativa

El alcance de la investigación consiste en una medida de causalidad de la misma, entendida la causalidad como la relación causa efecto existente entre las variables, siendo el alcance; el grado de identificación de esta relación. La medida de causalidad puede variar dentro de límites de un continuo con varios grados caracterizados, estos grados de alcance bien caracterizados son: exploratorio, descriptivo, correlacional y explicativo. Las investigaciones exploratorias sirven para preparar el terreno y por lo común anteceden a investigaciones con alcances más profundos. Las investigaciones descriptivas pueden ser base de investigaciones correlacionales, si no explicativas; y así también las investigaciones correlacionales pueden proporcionar información para llevar a cabo investigaciones explicativas. Las investigaciones explicativas explicitan relaciones causa efecto, generan un sentido de entendimiento y son altamente estructurados. Es posible que una investigación se inicie como exploratoria, después puede ser descriptiva, luego correlacional y terminar siendo explicativa. El alcance depende fundamentalmente de dos factores: el estado del conocimiento sobre el problema de investigación, mostrado por la revisión de la literatura, así como la perspectiva que se pretenda dar a la investigación.

3.4.1. Alcance exploratorio.

La medida de este alcance abarca la exploración de problemas generalmente poco conocidos, a veces difíciles de conocer.

3.4.2. Alcance descriptivo.

La medida de este alcance abarca la descripción del fenómeno, situación, contexto o evento; detalla cómo es y cómo se manifiesta. Busca especificar propiedades, características y rasgos importantes. Describe tendencias de un grupo o población. Es útil para mostrar con precisión los ángulos o dimensiones de un fenómeno, suceso, comunidad, contexto o situación.

3.4.3. Alcance correlacional.

La profundidad de este alcance busca establecer relaciones entre variables sin precisar sentido de causalidad, es decir, no analiza relación causal.

Un ejemplo de este alcance es una investigación que busca averiguar cómo se relacionan las calificaciones de los alumnos de un grado, en las asignaturas: Castellano y Matemática.

3.4.4. Alcance explicativo.

La profundidad de este alcance busca establecer relaciones entre variables precisando sentido de causalidad, es decir, analiza relación entre causa y efecto entre variables.

Un ejemplo de este alcance es una investigación que busca averiguar la relación entre urbanización y alfabetismo en un país, para ver qué variables macrosociales definen el grado de alfabetización de la población del país.

3.5. Diseño

Es el plan o estrategia que se desarrolla para obtener la información que se requiere en una investigación, generalmente para verificar la hipótesis. La precisión, amplitud y profundidad de la información obtenida varía en función del diseño elegido [32].

En la literatura sobre investigación cuantitativa es posible encontrar diferentes clasificaciones de los diseños; los autores [32] adoptan la siguiente clasificación: investigación experimental e investigación no experimental. A su vez, la primera puede dividirse de acuerdo con las clásicas categorías de Campbell y Stanley (1966) en: preexperimentos, experimentos “puros” y cuasiexperimentos. La investigación no experimental, siempre de acuerdo con [32], se subdivide en diseños transversales y diseños longitudinales.

Ejemplo de diseño en una investigación tecnológica formativa.

Aún más que en la investigación en ciencias básicas, es en la investigación tecnológica donde se puede apreciar la importancia del diseño para obtener un buen producto o servicio. Cabe entonces ilustrarlo con un ejemplo tomado dentro de esta última forma de investigación desde la referencia [?].

Metodología para implementar red de área local. (Local Area Network (LAN))¹

¹Por brevedad, solo se desarrolla la etapa de diseño.

Hoy en día, como nunca antes, el ser social necesita estar informado. Para estudiar problemas y tomar decisiones es necesario disponer de datos precisos, en el lugar y en el instante preciso. En gran medida se logra lo anterior con las redes de computadoras, cuyo objetivo fundamental es compartir recursos e información pues ofrecen acceso a servicios universales de datos tales como: bases de datos, correo electrónico, transmisión de archivos y boletines electrónicos; eliminando el desplazamiento de los individuos en la búsqueda de información y aumentando la capacidad de almacenamiento disponible por cada usuario en un momento determinado.

Un gran porcentaje de las redes de computadoras se usan para la transmisión de información científica siendo una vía rápida y económica de divulgar resultados y de discutir con otros especialistas afines sobre un tema en cuestión. En este trabajo en particular se aborda la metodología a seguir para la implementación de redes de computadoras de área local; las cuales cumplen todos los objetivos planteados a una escala reducida ya que son propiedad de una sola organización (un solo centro administrativo o fabril) abarcando zonas geográficas de algunos kilómetros como máximo. La experiencia en el campo de LANs en el ámbito universitario, donde las mismas se emplean para la gestión administrativa y económica, para la transmisión de información científica y para la enseñanza; ha dejado claro que el diseño, la instalación y puesta a punto de una LAN suele ser un proceso cuidadoso del cual depende en grado sumo que se cumplan los objetivos para los que se invirtió en dicha red.

Para su comprensión el trabajo se divide en cinco partes o etapas:

- Etapa de estudio,
- Etapa de diseño.²
- Etapa de elaboración de la solicitud de oferta y selección del vendedor,
- Etapa de instalación y puesta en funcionamiento,
- Etapa de análisis de las prestaciones y evaluación de los resultados.

Una vez concluida la primera etapa y aprobado el presupuesto de la red es necesario realizar la etapa del *diseño* de la LAN para lo cual se deben seguir los siguientes pasos:

- Seleccionar la(s) topología(s) y norma(s) de red a emplear,
- Seleccionar el soporte de transmisión a utilizar,

²Solo se desarrolla esta etapa.

- Analizar la necesidad de emplear técnicas de conectividad,
- Considerar ampliaciones futuras de la red,
- Realizar una evaluación primaria del tráfico,
- Contemplar las necesidades del personal involucrado en la red,
- Modificar, de ser necesario, el flujo de la información y seleccionar el software de aplicación.

Seleccionar la topología. Este paso, el cual es dependiente de los resultados del anterior. Las tres topologías más empleadas son: bus, estrella y anillo; mientras que las normas más comunes son: Ethernet, Token Ring y ArcNet. La selección de los aspectos anteriores trae aparejado escoger la velocidad de transmisión, la distancia máxima a emplear, el método de control de acceso al medio, etc. La elección se realiza a partir de la necesidad particular y de un amplio conocimiento de las topologías y normas existentes.

Seleccionar el Soporte de Transmisión. Esto está muy relacionado con la norma a emplear y con las características de los puntos a conectar. Es vital realizar una selección adecuada pues una opción equivocada comprometería la eficacia y la velocidad de la transferencia de datos. Para la elección de uno u otro medio de transmisión se debe tomar entre otras cosas las dimensiones de la instalación, el costo, la evolución tecnológica estimada, la facilidad de instalación y el grado de hostilidad electromagnética presente en el entorno.

Seleccionar el Sistema Operativo de Red (SOR).

Aunque el SOR (del inglés NOS: Netware Operating System) NetWare predomina en el mundo, éste no es siempre la elección adecuada, debido a sus costos y características. En el mercado existen otros SORs tales como: LAN Manager, LANServer, LANtastic, Vines, LINUX, Windows NT Server, Windows 2000 Server, etc.; los cuales poseen una determinada cuota de mercado. Para seleccionar el SOR adecuado se debe tener en cuenta:

- El nivel de confidencialidad que brinda a los datos,
- Si es del tipo cliente-servidor o de igual a igual,
- Grado de tolerancia a fallos que posee,
- Memoria RAM necesaria en el servidor y en las estaciones de trabajo,
- Facilidades de administración y diagnóstico que brinda,
- Si posee o no sistema de correo electrónico,

- Características de manipulación de colas de impresión.

Analizar la necesidad de emplear técnicas de conectividad. Esto estará en función de las dimensiones de la organización, del tráfico a cursar y el tipo de equipamiento a interconectar entre otros aspectos. Es necesario conocer en profundidad dichas técnicas para realizar una adecuada selección entre repetidores, puentes, ruteadores, compuertas, servidores de acceso, etc. y lograr su correcta ubicación. La mejor solución muchas veces hace uso de más de un tipo de dispositivo de interconexión.

Considerar ampliaciones futuras de la red. Aún cuando de forma inmediata no sea necesario extender la red ni conectarse a otros, ésta debe poseer la base para que a partir de ella, y en cualquier momento sea posible una ampliación o llegar a formar parte de otras redes.

Realizar una evaluación primaria del tráfico. Aquí debe estimarse el tráfico que circulará en la red y analizar si el mismo no afecta el tiempo de acceso a la información ya otros recursos compartidos. Es importante que una vez instalada y puesta en funcionamiento la LAN se efectúen periódicamente estudios de este tipo.

Contemplar las necesidades del personal involucrado en la red. Esto es muy importante pues en última instancia éste será el personal que utilizará la red y por lo tanto deben quedar satisfechas sus necesidades de forma tal que la nueva red sea un elemento que facilite su trabajo.

Modificar de ser necesario el flujo de información y seleccionar el software de aplicación. Esto implica la modificación, como última opción, de la manera en que la información circula dentro de la organización y la definición del software de aplicación necesario, ya sea comercial o aquél que se encargará al personal especializado; que conozca las particularidades de la programación en ambiente multiusuario. El software encargado o adquirido debe ser de fácil instalación y aprendizaje. Además se debe velar porque sea posible tener acceso a posteriores actualizaciones y que éstas no sean caras.

3.6. Lenguajes de programación

3.6.1. Python

Python es un lenguaje de programación potente y elegante que sea fácil de leer y de entender [33].

Tiene estructuras de datos de alto nivel eficientes y un simple pero efectivo sistema de programación orientado a objetos. La elegante sintaxis de Python y su tipado dinámico, junto a su naturaleza interpretada lo convierten en un

lenguaje ideal para scripting y desarrollo rápido de aplicaciones en muchas áreas, para la mayoría de plataformas.

Python se destaca en el ámbito de la inteligencia artificial debido a su capacidad para gestionar conjuntos de datos voluminosos y su facilidad de programación. Su sintaxis concisa y legible lo convierte en una elección ideal para crear prototipos de forma rápida, dinámica y comprensible. Además de su amplia popularidad, la razón principal para adentrarse en Python en el contexto del aprendizaje automático es, indiscutiblemente, su vasto ecosistema de recursos previamente desarrollados.

Pandas: Es una biblioteca de código abierto que proporciona estructuras de datos flexibles y herramientas de análisis de datos para Python. Su principal estructura de datos es el DataFrame, que permite organizar datos en tablas bidimensionales. Pandas es ampliamente utilizado para la limpieza, manipulación y análisis de datos tabulares, lo que lo hace esencial en el análisis de datos.

NumPy: Es una biblioteca fundamental para el cálculo numérico en Python. Proporciona soporte para arreglos multidimensionales (llamados ndarrays) y una amplia gama de funciones matemáticas para operaciones en estos arreglos. NumPy es crucial para realizar cálculos numéricos eficientes y es la base de muchas otras bibliotecas de análisis de datos en Python.

Matplotlib: Es una biblioteca de visualización que permite crear gráficos estáticos de alta calidad. Proporciona una variedad de tipos de gráficos, desde gráficos de líneas y barras hasta histogramas y gráficos de dispersión. Matplotlib es ampliamente utilizado para visualizar datos y resultados en el análisis de datos.

Seaborn: Es una biblioteca de visualización basada en Matplotlib que simplifica la creación de gráficos estadísticos atractivos. Ofrece una interfaz de alto nivel para crear fácilmente visualizaciones complejas y atractivas, lo que la hace útil para el análisis exploratorio de datos y la presentación de resultados.

Scikit-learn: Es una biblioteca de aprendizaje automático que proporciona herramientas para tareas comunes de aprendizaje automático, como clasificación, regresión, clustering y selección de modelos. También incluye utilidades

para la evaluación de modelos y el preprocesamiento de datos, lo que la convierte en una biblioteca esencial para el análisis de datos relacionados con el aprendizaje automático.

StatsModels: Es una biblioteca que se utiliza para realizar análisis estadísticos y modelado en Python. Está especialmente orientada a tareas como la regresión lineal y logística, análisis de series temporales y pruebas estadísticas. Es útil para realizar análisis estadísticos rigurosos en el contexto del análisis de datos.

SciPy: Es una extensión de NumPy que proporciona funcionalidades adicionales para cálculos científicos y técnicos. Incluye módulos para optimización, interpolación, integración numérica, álgebra lineal, transformadas y más. Es una biblioteca esencial para aplicaciones científicas y de ingeniería que involucran cálculos numéricos.

Plotly: Es una biblioteca que permite crear gráficos interactivos y visualizaciones web en Python. Es útil para crear visualizaciones interactivas para el análisis exploratorio de datos y la presentación de resultados en aplicaciones web.

Bokeh: Es otra biblioteca para crear gráficos interactivos y aplicaciones web basadas en datos. Ofrece una amplia gama de herramientas para crear visualizaciones interactivas y es especialmente útil para proyectos que requieren interfaces de usuario interactivas.

Dask: Es una biblioteca que se utiliza para el procesamiento paralelo y distribuido de datos en Python. Permite trabajar con conjuntos de datos grandes y realizar operaciones complejas de manera eficiente en clústeres de computadoras.

TensorFlow y PyTorch: Si bien estas bibliotecas son conocidas principalmente por el aprendizaje profundo, también se utilizan en tareas de procesamiento y análisis de datos cuando se trabajan con modelos de redes neuronales. Proporcionan herramientas para construir, entrenar y evaluar modelos de aprendizaje automático y profundo.

Estas bibliotecas forman la base del ecosistema de análisis de datos en Python y son esenciales para una variedad de tareas en ciencia de datos, análisis de datos y aprendizaje automático.

3.6.2. PHP

Es un lenguaje de programación ampliamente utilizado en el desarrollo web. Se destaca por su capacidad para crear aplicaciones web dinámicas e interactivas [34].

Ofrece diversas ventajas que lo hacen atractivo en el desarrollo web:

Facilidad de aprendizaje: Tiene una sintaxis simple y legible, lo que facilita su aprendizaje, especialmente para principiantes en programación.

Amplia comunidad y soporte: Cuenta con una gran comunidad de desarrolladores y abundantes recursos en línea, incluyendo bibliotecas y frameworks, lo que agiliza el desarrollo.

Interacción con bases de datos: Brinda soporte integrado para la mayoría de las bases de datos populares, lo que lo hace ideal para aplicaciones que gestionan datos.

Versatilidad: Se integra fácilmente con HTML y otros lenguajes web, permitiendo una amplia gama de aplicaciones y funcionalidades.

Plataforma cruzada: Es compatible con varias plataformas y sistemas operativos, lo que lo hace altamente portátil.

Anexo A.

Los apéndices y anexos resultan útiles para describir con mayor profundidad ciertos materiales, sin distraer la lectura del texto principal del reporte o evitar que rompan con el formato de éste. Algunos ejemplos serían el cuestionario utilizado, un código de programa computacional, análisis estadísticos adicionales, la demostración matemática de un teorema complicado, fotografías testimoniales, etc.

Referencias bibliográficas

- [1] Jimmy Alexander Romero Miranda, Víctor Alberto Lizcano Portilla *et al.*, “Predicción de ventas futuras,” 2021.
- [2] [En línea]. Disponible: <https://decidesoluciones.es/modelo-de-prediccion-de-demanda-aplicacion-y-beneficios/>
- [3] Ana Ortega Marqués, Sandy Patricia Padilla Domínguez, Johana Isabel Torres Durán, y Alexander Ruz Gómez, “Nivel de importancia del control interno de los inventarios dentro del marco conceptual de una empresa,” *Liderazgo estratégico*, vol. 7, no. 1, pp. 71–82, 2017.
- [4] Kenneth E Kendall y Julie E Kendall, *Análisis y diseño de sistemas*. Pearson educación, 2005, obtenido el 20 de mayo de 2023 de. [En línea]. Disponible: https://scholar.google.es/scholar?hl=es&as_sdt=0%2C5&q=K.+E.+Kendall+y+J.+E.+Kendall%2C+An%C2%B4alisis+y+dise%C2%B4on%2C+2005&btnG=9Cno+de+sistemas.+Pearson+educaci%C2%B4on%2C+2005&btnG=
- [5] Raúl Pino Díez, Alberto Gómez Gómez, y Nicolás de Abajo Martínez, *Introducción a la inteligencia artificial: sistemas expertos, redes neuronales artificiales y computación evolutiva*. Universidad de oviedo, 2001.
- [6] Xabier Basogain Olabe, “Redes neuronales artificiales y sus aplicaciones,” *Publicaciones de la Escuela de Ingenieros*, 1998.
- [7] César Pérez López y Daniel Santin González, *Minería de datos. Técnicas y herramientas: técnicas y herramientas*. Ediciones Paraninfo, SA, 2007.
- [8] Beatriz Beltrán Martínez, “Minería de datos,” *Cómo hallar una aguja en un pajar. Ingenierías*, vol. 14, no. 53, pp. 53–66, 2001.
- [9] Batta Mahesh, “Machine learning algorithms-a review,” *International Journal of Science and Research (IJSR)*. [Internet], vol. 9, no. 1, pp. 381–386, 2020. [En línea]. Disponible: https://scholar.google.es/scholar?hl=es&as_sdt=0%2C5&q=+machine+learning&btnG=

- [10] Dennys Fabian Herrera Cofre *et al.*, “Predicción para el mercado de acciones con redes neuronales lstm,” 2020.
- [11] I.B.M. Staff(es). (2017) Machine learning. [En línea]. Disponible: <https://www.ibm.com/mx-es/analytics/machine-learning>
- [12] Ian Goodfellow, Yoshua Bengio, y Aaron Courville, *Deep learning*. MIT press, 2016.
- [13] Carlos Arana, “Redes neuronales recurrentes: Análisis de los modelos especializados en datos secuenciales,” Serie Documentos de Trabajo, Tech. Rep., 2021.
- [14] Vahid Mirjalili y Sebastian Raschka, *Python machine learning*. Marcombo, 2020.
- [15] E De la Rosa Montero, “El aprendizaje profundo para la identificación de sistemas no lineales,” *Centro de Investigación y de estudios avanzados del Instituto Politécnico nacional*, 2014.
- [16] Xavier Basogain, “Redes neuronales artificiales y sus aplicaciones,” *Dpto. Ingeniería de Sistemas y Automática, Escuela Superior de Ingeniería Bilbao. Open Course Ware.*[En línea] disponible en http://ocw.ehu.es/enseñanzas-tecnicas/redes-neuronales-artificiales-y-sus-aplicaciones/Course_listing. [Consultada 20-09-2012], 2008.
- [17] Raquel Flórez López y José Miguel Fernández Fernández, *Las redes neuronales artificiales*. Netbiblo, 2008.
- [18] Nicolás Sánchez Anzola, “Máquinas de soporte vectorial y redes neuronales artificiales en la predicción del movimiento usd/cop spot intradiario.” *ODEON-Observatorio de Economía y Operaciones Numéricas*, no. 9, 2015.
- [19] Andres Nacelle y E Mizraji, “Redes neuronales artificiales,” *Núcleo de ingeniería biomédica-Universidad de la Republica Uruguay*, 2009.
- [20] Eder Acevedo, Alexei Serna, y Edgar Serna, “Principios y características de las redes neuronales artificiales,” *Desarrollo e innovación en ingeniería*, vol. 173, 2017.
- [21] M Gestal Pose, “Introducción a las redes de neuronas artificiales,” *Departamento de Tecnologías de la Información y las Comunicaciones. Universidad da Coruña*, 2009.

- [22] F Alejandro Nava, *Procesamiento de series de tiempo*. Fondo de cultura económica, 2015.
- [23] Samuel Tomas, Oliver Saavedra, y Israel Espinoza, “Predicción del ciclo solar 25 mediante modelos arima y redes neuronales lstm,” *Revista de la Academia Colombiana de Ciencias Exactas, Físicas y Naturales*, 2023.
- [24] Juan José De Lucio Fernández, “Estimación adelantada del crecimiento regional mediante redes neuronales lstm,” *Investigaciones Regionales= Journal of Regional Research*, no. 49, pp. 45–64, 2021.
- [25] Víctor Marcial Condorena Rondón, “Desarrollo de un sistema de control de inventario, para la gestión de compras de materia prima en el rubro de restaurantes,” 2017.
- [26] Nicole Pacheco Allende, “Rediseño del proceso de abastecimiento en el área de compras en dos empresas dedicadas al equipamiento gastronómico,” 2015.
- [27] Gabriel Vinicio Moreano Sánchez, Víctor Hugo Benítez Bravo, Wilmer Albarracín, y Álvaro Gabriel Benítez Bravo, “Sistemas inteligentes y colaborativos de administración global: Caso de estudio; establecimiento gastronómico,” *revistapuce*, 2018.
- [28] María Afanador Jiménez, Silvia Juliana Casadiegos Chaparro, Isabella Campo Maichel, Juan Sebastián Casallas Estrella *et al.*, “Diseño de un modelo de pronóstico de demanda basado en machine learning y un modelo multi-objetivo para planeación de la producción en una industria panificadora,” 2022.
- [29] Jose R SAURA, Ana Reyes-Menéndez, y Pedro PALOS-SANCHEZ, “Un análisis de sentimiento en twitter con machine learning: Identificando el sentimiento sobre las ofertas de# blackfriday,” *Revista Espacios*, vol. 39, no. 42, 2018.
- [30] Edwar Andrés Hincapié Herrera, “Predicción de la demanda usando modelos de machine learning,” 2021.
- [31] Besay Montesdeoca Santana, “Estudios de predicción en series temporales de datos meteorológicos utilizando redes neuronales recurrentes,” B.S. thesis, 2016.
- [32] Roberto Hernández, C. Fernández, y M. P. Baptista, *Metodología de la investigación*, 5th ed. México D.F.: McGraw-Hill, 2010.

- [33] Why Python, “Python,” *Python Releases for Windows*, vol. 24, 2021. [En línea]. Disponible: https://scholar.google.es/scholar?hl=es&as_sdt=0%2C5&q=Python+&btnG=
- [34] Ángel Cobo, *PHP y MySQL: Tecnología para el desarrollo de aplicaciones web*. Ediciones Díaz de Santos, 2005.